

论文标题

马文杰

李传浩

张可欣

摘要

本文针对 < 题目主题 > 问题展开研究。首先对附件数据进行预处理与统计分析，提出了...模型。

针对问题一，本文...（简述方法），得到...（简述关键结果）。

针对问题二，本文...（简述方法），得到...（简述关键结果）。

针对问题三，本文...（简述方法），得到...（简述关键结果）。

针对问题四，本文...（简述方法），得到...（简述关键结果）。

综上所述，本文所建立的模型...（总结模型适用性与优点）。

关键词：关键字 1；关键字 2；关键字 3；关键字 4

1 问题重述

随着人工智能算力规模的持续扩张，数据中心的用电需求、碳排放及其与电网的交互影响不断增强，电力成本已成为数据中心运营成本的核心组成部分。在此背景下，”算电协同”成为了算力负荷与电力系统实时耦合优化的现实需求。由于东部地区时延低、实时业务需求高，而西部地区具备电价低、新能源丰富的优势，跨区域算力迁移与能源调度构成一个多目标协同优化问题。赛题设定六个典型区域：区域 A、区域 B、区域 C 为东部高负荷区域，区域 D 为西部算力中心，区域 E、区域 F 分别为光伏与风电资源富集区域。任务到达主时域为第 0-2399 小时，第 2400-2405 小时用于结清末端任务，第 2406 小时不安排任务，仅进行电力与储能终端状态结算。任务分为实时推理、批量推理与人工智能训练三类，均不可抢占、不可拆分或中途迁移。赛题要求基于附件提供的 GPU 容量、任务轨迹、网络时延、电价、碳强度、新能源出力与储能等数据，依次解决以下四个问题：

问题一是算力需求分析与短期预测。对不同区域、不同任务类型的 GPU 需求进行统计分析并构建短期预测模型，进而建立基础算力调度模型，给出第 2376-2399 小时实际到达任务的调度方案，并展示最后 24 小时的调度甘特图与区域 GPU 利用率；问题二是碳感知任务调度。以第 0-2399 小时实际到达任务及逐时电力参数为输入，以任务迁移与开工时段为决策变量，以运行成本、碳排放、网络时延和新能源利用率为目标或评价指标，建立碳感知任务调度模型并给出调度策略；问题三是储能协同优化。在给定任务调度与逐时负荷的基础上，建立储能协同优化模型，设计储能充放电策略，分析储能系统对运行成本、碳排放、区域峰值净购电功率和负荷波动程度的影响；问题四是多区域协同优化。建立多区域”算一储一电”协同优化模型，统一考虑任务迁移、电价、碳排放、可用新能源、储能、区域购售电边界、网络时延及任务异构性，在系统运行成本、碳排放、网络时延、服务质量、新能源利用率和区域峰值净购电之间进行权衡，并比较不同碳约束、电价机制和新能源波动场景下的策略变化。

2 问题分析

问题一首先对 GPU 需求按区域、任务类型进行统计分析，刻画需求分布特征；其次利用历史到达数据构建短期预测模型，为第 2376-2399 小时提供前瞻性需求输入；最后在算力容量、网络时延与任务完成时限约束下建

立基础算力调度模型，输出调度方案、最后 24 小时调度甘特图与区域 GPU 利用率；问题二是碳感知任务调度，以任务迁移决策与开工时段为决策变量，在满足时延、容量与完成时限约束的前提下，权衡运行成本、碳排放、网络时延与新能源利用率四类目标。利用西部低电价、低碳强度与新能源优势实现降本减排，训练任务作为主要迁移对象；问题三是储能协同优化：在给定任务调度与逐时负荷的基础上，优化储能充放电策略，利用峰谷电价差异实现削峰填谷与套利、平抑负荷波动、促进新能源消纳，并定量分析储能对运行成本、碳排放、区域峰值净购电功率与负荷波动的影响。问题四是多区域协同优化：将任务调度、电力交易、储能运行统一纳入多区域“算一储一电”协同优化模型，综合考虑任务异构性、网络时延、算力容量、购售电边界与新能源波动，在系统运行成本、碳排放、网络时延、服务质量、新能源利用率与区域峰值净购电等多目标间权衡，并通过碳约束、电价机制与新能源波动等场景对比进行敏感性分析。

3 数据预处理

首先应该保证数据质量与口径一致。对各数据表进行完整性、取值范围与内部勾稽关系校验，确认数据无缺失、无越界，且各字段间的逻辑关系，如任务类型与最大网络时延、设施侧总负荷与信息技术侧负荷及能源使用效率之间，应该保持一致，避免因数据问题导致模型结果失真；其次是统一数据粒度与计量单位：将任务连续执行时长由分钟统一换算为小时，与小时级调度时段对齐；明确主时域（第 0-2399 小时）与收尾时域（第 2400-2406 小时）的边界，保证任务、负荷、电价、储能等数据在同一时间坐标系下可比、可算；最终构造建模所需的标准化输入：按区域、任务类型对图形处理器需求进行聚合，形成小时级需求序列，并按赛题给定口径切分为训练集、调参集与测试集，为需求统计分析、短期预测与基础算力调度提供直接可用的数据输入。依据任务轨迹数据校验的结果显示：附件数据完整、口径自洽，可直接用于后续建模，无需额外清洗。

本文全部数据均取自赛题附件，未引入外部数据。其原因在于附件数据为赛题量身设计，涵盖任务轨迹、区域算力容量、网络时延、功率映射、区域逐时电力数据与储能信息，四个问题所需的全部输入均已具备；另一方面，赛题要求各问题以附件给出的实际数据作为统一优化输入以保证结果可比性，外部数据与题目口径不一致，反而会影响模型结果的一致性。对于问题四中的碳约束、电价机制与新能源波动等场景对比，本文在附件数据基础上构造相应的扰动情景加以分析，亦无需外部数据。因此，附件数据在数量上与覆盖面上均足以支撑本文的全部建模工作。

4 模型假设

基于赛题给定口径与附件数据特征，本文在建模时作如下假设：任务均不可抢占、不可拆分或在中途转移至其他区域，各任务相互独立、不存在依赖关系，其中实时推理任务到达即开工，批量推理与人工智能训练任务允许延迟调度但最迟须在第 2406 小时前完成；区域间通信仅考虑附件给定的单向等效网络时延，忽略网络带宽、迁移数据量、传输能耗及传输费用，跨区域调度的可行性由任务的最大网络时延约束决定；各区域逐时电价、碳强度、可用新能源出力及负荷均视为附件给定的确定性参数，即本文建立确定性优化模型；各类任务每等效图形处理器产生的信息技术功率按附件功率映射统一取值，且任务在执行时段内功率恒定，设施侧总负荷按“总信息技术负荷 $\times$ 区域能源使用效率”计算；储能充放电效率在运行周期内视为常数，荷电状态按线性递推关系更新，且储能仅服务于所在区域、不进行跨区域调用；附件数据经质量校验确认完整、口径自洽，可直接用于建模；各区域任意时段的可调度图形处理器容量、信息技术侧最大功率与设施侧最大功率均构成硬约束，调度方案不得违反。

5 问题一：算力需求分析与短期预测

5.1 图形处理器需求统计分析

对工作负载轨迹中的 50000 个人工智能任务，按区域与任务类型统计其图形处理器需求分布，结果如表 1、表 2 所示。

表 1: 不同任务类型的 GPU 需求统计

任务类型	任务数	需求量均值	最大值	GPU-小时总量
实时推理任务	16724	4.0	7	228150
批量推理任务	16717	13.5	23	769098
人工智能训练任务	16559	71.3	127	4023539

三类任务的需求特征分层明显：实时推理任务单任务图形处理器需求小、数量多、时延敏感；人工智能训练任务单任务需求量最大，是算力消耗的主体，其图形处理器-小时总量约占全部任务的 80%；批量推理任务介于两者之间。

表 2: 不同区域的 GPU 需求统计

区域	任务数	需求量均值	GPU-小时总量
区域 A	10062	13.1	448452
区域 B	9200	13.8	430758
区域 C	7559	14.6	374934
区域 D	9560	47.6	1548858
区域 E	6912	46.9	1087748
区域 F	6707	48.5	1130035

分区域看，东部高负荷区域 A、B、C 以实时推理与批量推理任务为主，任务数量大但单任务需求小，需求量均值约 13-15；西部区域 D、E、F 承接大量人工智能训练任务，单任务需求大，需求量均值约 47-49，其中区域 D 的图形处理器-小时总量最大（约 155 万）。上述特征表明：训练任务是跨区域调度与新能源协同的主要调节对象，东部存在较大的可迁移算力空间，与后文基础调度及碳感知调度的分析结果一致。

5.2 算力需求短期预测模型

赛题要求利用历史到达数据构建短期预测模型，为第 2376-2399 小时的调度提供前瞻性的图形处理器需求输入。小时级图形处理器需求序列具有较强的波动性，传统时间序列模型（如 ETS、ARIMA）对该类序列的预测精度有限。文献研究表明，变分模态分解（VMD）等自适应信号分解方法可将原始序列拆分为若干相对平稳的模态分量，对各分量分别建模预测、最后叠加得到整体预测，从而降低序列复杂度、提升预测精度^[1-2]。受此思路启发，本文在 R 环境下以自适应集合经验模态分解（CEEMDAN）实现信号分解。

自适应集合经验模态分解（CEEMDAN）模型

CEEMDAN 在经验模态分解（EMD）的基础上，通过向残差信号逐次叠加自适应高斯白噪声并进行集合平

均以抑制模态混叠，将原始图形处理器需求序列 $x(t)$ 分解为 K 个模态分量 $\text{IMF}_k(t)$ 与残差项 $r(t)$ ：

$$x(t) = \sum_{k=1}^K \text{IMF}_k(t) + r(t) \quad (1)$$

与变分模态分解（VMD）等同属自适应信号分解方法，CEEMDAN 无需预设中心频率，依靠迭代筛分自适应确定各模态分量，更适用于近似平稳且无明显周期结构的波动序列。将所得分量按频率特征划分为低频趋势分量、中频波动分量与高频随机分量，分别采用适用的模型预测后叠加重构：

$$\hat{x}(t+h) = \sum_{k \in \mathcal{L}} \widehat{\text{IMF}}_k(t+h) + \sum_{k \in \mathcal{M}} \widehat{\text{IMF}}_k(t+h) + \sum_{k \in \mathcal{H}} \widehat{\text{IMF}}_k(t+h) \quad (2)$$

其中 $\mathcal{L}$ 、 $\mathcal{M}$ 、 $\mathcal{H}$ 分别为低频、中频、高频分量下标集合。

为量化预测精度，本文采用均方根误差（RMSE）、平均绝对误差（MAE）与平均绝对百分比误差（MAPE）三项指标，其定义为：

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{t=1}^N (y_t - \hat{y}_t)^2}, \quad (3)$$

$$\text{MAE} = \frac{1}{N} \sum_{t=1}^N |y_t - \hat{y}_t|, \quad (4)$$

$$\text{MAPE} = \frac{1}{N} \sum_{t=1}^N \frac{|y_t - \hat{y}_t|}{y_t} \times 100\% \quad (5)$$

其中 y_t 为第 t 小时图形处理器需求实际值， $\hat{y}_t$ 为模型预测值， $N = 24$ 为预测步数。以第 0–2375 小时逐时图形处理器总需求为训练数据，向前预测第 2376–2399 小时共 24 步，与测试集实际值比较，结果如表 3 所示。

实验结果未实现预期的精度提升。分析认为，“分解 + 预测 + 重构”在本数据上未带来提升的原因主要有：预测误差累积。序列被分解为 11 个分量，需对各分量分别进行 24 步向前预测，高频随机分量几乎不可预测，各分量误差叠加后重构总误差显著增大；序列结构不匹配。逐时图形处理器需求序列波动相对平稳、无明显趋势与季节周期，分解方法更适用于具有明确趋势或季节结构的序列，对近似平稳的波动序列难以提供结构增益；多步预测挑战。一次性向前 24 步预测对高频分量的可预测性提出了过高要求。

5.3 组合预测与最终模型选择

针对上述问题，文献研究表明，单一时间序列模型的预测能力存在上限，将 ARIMA 与 ETS 等模型的预测结果进行组合，可综合各自优势、降低预测风险^[3]。受此思路启发，本文进一步考察了 ETS 与 ARIMA 的组合预测策略：

指数平滑（ETS）模型

指数平滑将序列分解为水平、趋势与季节三个成分，通过指数递减权重递推更新，其状态空间递推方程为：

$$l_t = \alpha y_t + (1 - \alpha)(l_{t-1} + b_{t-1}), \quad (6)$$

$$b_t = \beta(l_t - l_{t-1}) + (1 - \beta)b_{t-1}, \quad (7)$$

$$s_t = \gamma(y_t - l_{t-1} - b_{t-1}) + (1 - \gamma)s_{t-m} \quad (8)$$

h 步预测为 $\hat{y}_{t+h|t} = l_t + hb_t + s_{t+h-m}$ ，其中 $\alpha, \beta, \gamma \in (0, 1)$ 为平滑参数， m 为季节周期长度。本文采用 ETS 自动定阶，其在当前序列上自动选择“加性误差、无趋势、无季节”（A,N,N），退化为简单指数平滑 $l_t = \alpha y_t + (1 - \alpha)l_{t-1}$ ，即仅对序列水平作指数加权平均。

ARIMA 模型

自回归积分滑动平均模型 (ARIMA(p, d, q)) 先对序列作 d 阶差分 $\nabla^d y_t = (1 - B)^d y_t$ 以消除非平稳性, 再建立自回归与移动平均的混合模型:

$$\phi(B)\nabla^d y_t = c + \theta(B)\varepsilon_t$$

其中 B 为滞后算子 ($By_t = y_{t-1}$), $\phi(B) = 1 - \phi_1 B - \dots - \phi_p B^p$ 为自回归系数多项式, $\theta(B) = 1 + \theta_1 B + \dots + \theta_q B^q$ 为移动平均系数多项式, c 为常数项, ε_t 为零均值白噪声。本文 ARIMA 自动定阶结果为 (0,0,0), 即 $y_t = c + \varepsilon_t$, 退化为“常数均值 + 白噪声”的水平模型。

以调参集 (第 2352-2375 小时) 对二者的预测结果进行组合权重寻优, 考察等权组合与最优权重组合两种方式, 向前预测第 2376-2399 小时共 24 步, 组合结果与单模型一并汇总于表 3。

表 3: 各模型短期预测性能对比

模型	RMSE	MAE	MAPE
ETS	221.0	176.7	23.39%
ARIMA	221.1	176.7	23.39%
分解 + ARIMA	383.2	277.4	36.37%
分解 + LightGBM	261.1	207.9	27.12%
等权组合 (ETS+ARIMA)	221.0	176.7	23.39%
最优权重组合 (ETS+ARIMA)	221.1	176.7	23.39%

实验结果显示, 分解-预测-重构模型的精度反而低于直接采用 ETS/ARIMA 的基准模型, 未实现预期的精度提升。其内在原因是: 预测误差累积——序列被分解为 11 个分量, 需对各分量分别进行 24 步向前预测, 高频随机分量几乎不可预测, 各分量误差叠加后重构总误差显著增大; 序列结构不匹配——逐时图形处理器需求序列波动相对平稳、无明显趋势与季节周期, 分解方法更适用于具有明确趋势或季节结构的序列, 对近似平稳的波动序列难以提供结构增益; 多步预测挑战——一次性向前 24 步预测对高频分量的可预测性提出了过高要求。

5.4 基础算力调度模型

本节在图形处理器容量、网络时延与完成时限约束下, 以任务开工时段与执行区域为决策变量, 建立第 2376-2399 小时实际到达任务的基础算力调度模型。

以最小化任务总开工延迟与迁移惩罚之和为目标, 基础算力调度模型可写为如下混合整数规划形式:

$$\left\{ \begin{array}{l} \text{argmin}_{s_i, y_{i,r}} \sum_{i \in \mathcal{I}} (s_i - a_i) + \theta \sum_{i \in \mathcal{I}} \sum_{r \in \mathcal{R} \setminus \{o_i\}} y_{i,r} \\ \text{s.t. } \sum_{r \in \mathcal{R}} y_{i,r} = 1, \quad \forall i \in \mathcal{I} \\ s_i \geq a_i, \quad \forall i \in \mathcal{I} \\ s_i + d_i \leq L_i, \quad \forall i \in \mathcal{I} \\ \ell_{o_i, r} y_{i,r} \leq l_i^{\max}, \quad \forall i \in \mathcal{I}, r \in \mathcal{R} \\ \sum_{i \in \mathcal{I}} g_i \text{overlap}(i, r, t) \leq C_r, \quad \forall r \in \mathcal{R}, t \in \mathcal{T} \\ y_{i,r} \in \{0, 1\}, \quad s_i \in \mathbb{Z}_{\geq 0}, \quad \forall i \in \mathcal{I}, r \in \mathcal{R} \end{array} \right. \quad (9)$$

其中 $\mathcal{I}$ 为第 2376-2399 小时实际到达的任务集合， $\mathcal{R}$ 为区域集合， $\mathcal{T}$ 为调度时段集合； o_i 为任务 i 的来源区域， $y_{i,r} \in \{0,1\}$ 为任务 i 是否调度至区域 r 执行的二值指派变量， s_i 为任务 i 的开工小时， a_i 为任务到达小时， d_i 为连续执行时长（小时）， L_i 为最晚完成小时， $\ell_{o_i,r}$ 为来源区域 o_i 到区域 r 的单向网络时延， $l_i^{\max}$ 为任务的最大网络时延， g_i 为任务图形处理器需求量， $\text{overlap}(i,r,t)$ 为任务 i 在区域 r 时段 t 的实际占用小时数， C_r 为区域 r 的可调度图形处理器容量， θ 为迁移惩罚系数。目标中的第二项 $\theta \sum_{i \in \mathcal{I}} \sum_{r \in \mathcal{R} \setminus \{o_i\}} y_{i,r}$ 为迁移惩罚，惩罚任务离开来源区域执行，从而在容量可行时优先本地调度、抑制不必要的跨区迁移，与下述贪心求解策略一致。

在上述模型与贪心算法下，第 2376-2399 小时实际到达的 538 个任务全部按时完成，仅 1 个实时推理任务因容量冲突就近调度至相邻区域，可延迟任务平均开工延迟 0.04 小时。第 2376-2399 小时区域平均图形处理器利用率：区域 E、F 分别达 0.718、0.794（峰值接近满载），区域 A、B、C 为 0.24-0.38，东部存在较大剩余算力空间，可为后续跨区域调度提供迁移方向。调度甘特图与区域图形处理器利用率如图 1、图 2 所示。




图 1: 第 2376-2406 小时基础调度甘特图

图 2 按执行区域分面展示第 2376-2406 小时的调度甘特图，每个色条表示一个任务的图形处理器占用区间，颜色区分任务类型：实时推理任务到达即开工、区间较短；批量推理与人工智能训练任务区间较长，部分任务跨越第 2399 小时并在收尾时域内结清；西部区域 E、F 任务条密集，东部区域 A、B、C 相对稀疏。




图 2: 六区域逐时 GPU 利用率

图 3 展示六区域逐时图形处理器利用率：区域 E、F 长期处于高位并接近满载（峰值约 0.997、0.995），区域 D 处于中等水平，区域 A、B、C 整体偏低，利用率随时间的起伏反映了任务到达的随机性与批量、训练任务调度的时序特征。

6 问题二：碳感知任务调度

6.1 碳感知任务调度模型

问题二要求以第 0-2399 小时实际到达任务及对应逐时电力参数为输入，以任务迁移与开工时段为决策变量，在满足图形处理器容量、网络时延与完成时限约束下，最小化由运行成本、碳排放与网络时延构成的综合代价，并将新能源利用率作为评价指标对调度效果进行事后评估。文献研究表明，绿色云数据中心普遍采用“空间迁移 + 时间迁移”的碳感知调度策略，即将可延迟工作负载迁移至电价低、碳强度低或新能源富余的区域与时段，从而在不牺牲服务质量的前提下降低运行成本与碳排放^[4]；算电协同实践同样表明，利用西部低电价、低碳强度与新能源优势，将计算负荷调度至适宜区域与时段，可有效促进新能源消纳与降本减排^[5]。受此思路启发，本文构建碳感知任务调度模型：批量推理与人工智能训练任务允许跨区域迁移并选择开工时段，实时推理任务到达即开工、不迁移；目标函数为最小化“购电成本 + 碳权重 × 碳排放 + 时延惩罚”的综合代价，约束包括区域可调度容量、跨区域网络时延与任务完成时限。

模型的核心思想是：在东部算力紧张、西部绿电充足且电价低廉的现实约束下，把时延不敏感的任务看作可迁移、可时移的“算力负荷包”，通过决策其执行区域与开工时段，将算力负荷引导至低电价、低碳强度的西部区域，同时以时延惩罚与硬性时延约束保证服务质量不因迁移而显著劣化。目标函数的三项各有其作用机制：购电成本项 $\sum_{r,t} \pi_{r,t} P_{r,t}^{grid} \Delta t$ 直接反映区域电价差异对运营成本的影响；碳排放项 $\beta \sum_{r,t} \kappa_{r,t} P_{r,t}^{grid} \Delta t$ 按区域逐时碳强度对购电电量加权，正是“迁移降碳”的本质——将负荷从高碳强度区域（如区域 A，0.62 tCO₂/MWh）迁往低碳区域（如区域 E，0.22 tCO₂/MWh）即可降低碳排放；时延惩罚项 $\gamma \sum_{i,r} \ell_{o_i,r} y_{i,r}$ 对跨区迁移产生的单向网络时延计价，抑制无谓的长距离迁移。

需要说明的是，目标函数三项分量的量纲不同（购电成本为元、碳排放为吨、时延为毫秒），权重系数 β 、 γ

除体现决策偏好外还承担量纲协调作用，其取值使各分量处于相近量级，从而实现加权标量化；如需严格统一，可先对各分量归一化至 $[0, 1]$ 再加权，本文通过 β 、 γ 的标定实现等效效果。约束条件保证任何调度方案均不违反区域算力容量、网络时延上限与任务完成时限，其中实时任务强制就地、即到即开，使模型在兼顾经济性与低碳性的同时保证方案可行。需要说明的是，新能源利用率在本问题中作为评价指标而非优化目标：任务迁移仅改变人工智能负荷的时空分布，不改变各区域的新能源可用量与消纳路径（新能源的消纳、储能与购售电策略属于问题三、问题四的优化范畴），故其不计入本模型的目标函数。

以最小化综合运行代价为目标，碳感知任务调度模型可写为如下混合整数规划形式：

$$\left\{ \begin{array}{l} \underset{y_{i,r}, s_i}{\text{argmin}} \sum_{r \in \mathcal{R}} \sum_{t \in \mathcal{T}} [\pi_{r,t} + \beta \kappa_{r,t}] P_{r,t}^{grid} \Delta t + \gamma \sum_{i \in \mathcal{I}} \sum_{r \in \mathcal{R} \setminus \{o_i\}} \ell_{o_i,r} y_{i,r} \\ \text{s.t.} \sum_{r \in \mathcal{R}} y_{i,r} = 1, \quad \forall i \in \mathcal{I} \\ s_i \geq a_i, \quad \forall i \in \mathcal{I} \\ s_i + d_i \leq L_i, \quad \forall i \in \mathcal{I} \\ \ell_{o_i,r} y_{i,r} \leq l_i^{\max}, \quad \forall i \in \mathcal{I}, r \in \mathcal{R} \\ \sum_{i \in \mathcal{I}} g_i \text{overlap}(i, r, t) \leq C_r, \quad \forall r \in \mathcal{R}, t \in \mathcal{T} \\ P_{r,t}^{grid} = \text{PUE}_r \left(N_{r,t}^{nonAI} + \sum_{i \in \mathcal{I}} w_{\text{type}_i} g_i \text{overlap}(i, r, t) \right), \quad \forall r \in \mathcal{R}, t \in \mathcal{T} \\ y_{i,o_i} = 1, s_i = a_i, \quad \forall i \in \mathcal{I}_{RT} \\ y_{i,r} \in \{0, 1\}, s_i \in \mathbb{Z}_{\geq 0}, P_{r,t}^{grid} \geq 0, \quad \forall i \in \mathcal{I}, r \in \mathcal{R}, t \in \mathcal{T} \end{array} \right. \quad (10)$$

其中 $\mathcal{I}$ 为第 0-2399 小时实际到达的任务集合， $\mathcal{I}_{RT} \subseteq \mathcal{I}$ 为实时推理任务集合， $\mathcal{R}$ 为区域集合， $\mathcal{T}$ 为调度时段集合； o_i 为任务 i 的来源区域， $y_{i,r} \in \{0, 1\}$ 为任务 i 是否调度至区域 r 执行的二值指派变量， s_i 为任务 i 的开工小时， a_i 为任务到达小时， d_i 为连续执行时长（小时）， L_i 为最晚完成小时（批量与训练任务统一取 $L_i = 2406$ ）， $\ell_{o_i,r}$ 为来源区域 o_i 到区域 r 的单向网络时延， $l_i^{\max}$ 为任务的最大网络时延， g_i 为任务图形处理器需求量， $\text{overlap}(i, r, t)$ 为任务 i 在区域 r 时段 t 的实际占用小时数， C_r 为区域 r 的可调度图形处理器容量； $\pi_{r,t}$ 、 $\kappa_{r,t}$ 分别为区域 r 时段 t 的购电价格与碳强度， $P_{r,t}^{grid}$ 为调度形成的区域电网购电功率， Δt 为时段长度（取 1 小时）， β 、 γ 分别为碳排放与网络时延的权重系数。约束中的 $\mathcal{I}_{RT}$ 一项强制实时推理任务固定在其来源区域 o_i 执行、到达即开工且不迁移。

其中购电功率 $P_{r,t}^{grid}$ 作为由调度决策确定的辅助变量，其定义式已作为约束纳入上述模型：

$$P_{r,t}^{grid} = \text{PUE}_r \left(N_{r,t}^{nonAI} + \sum_{i \in \mathcal{I}} w_{\text{type}_i} g_i \text{overlap}(i, r, t) \right)$$

式中 w_{type_i} 为任务 i 所属类型对应的每等效图形处理器平均信息技术功率（实时推理任务取 0.08、批量推理任务取 0.10、人工智能训练任务取 0.16 兆瓦）， $N_{r,t}^{nonAI}$ 为区域 r 时段 t 给定的非人工智能信息技术负荷， PUE_r 为区域 r 的能源使用效率。由该式可见，任务迁移与开工时段通过 $\text{overlap}(i, r, t)$ 改变各区域逐时购电功率，进而影响目标函数中的购电成本与碳排放项。

由于任务规模大（第 0-2399 小时共 5 万个任务）、调度空间高维且目标函数具有多峰性，直接精确求解不可行。文献研究表明，模拟退火作为一类全局优化算法，通过随机扰动与温度退火机制，可在多峰、计算昂贵的优化问题中跳出局部最优并逐步收敛到全局较优解，且无需梯度信息，适合工程中的大规模组合优化问题^[6]。受此思路启发，本文采用模拟退火算法求解：以“不迁移、到达后尽早执行”的方案为初始解，通过随机“迁移 + 时移”扰动产生新解，依据 Metropolis 准则随温度下降逐步逼近较优解。

6.1.1 模拟退火的数学原理

模拟退火通过引入”温度”参数 T 控制随机扰动的接受程度，使算法在搜索前期充分探索解空间、后期逐步收敛。设当前解 x 经邻域扰动得到新解 x' ，目标函数增量为 $\Delta f = f(x') - f(x)$ ，则依据 Metropolis 接受准则^[7]，新解被接受的概率为：

$$P(\Delta f, T) = \min \left\{ 1, \exp \left(-\frac{\Delta f}{T} \right) \right\}$$

当 $\Delta f \leq 0$ （新解不劣于当前解）时恒接受；当 $\Delta f > 0$ （新解更差）时以概率 $\exp(-\Delta f/T)$ 接受。该机制使算法在温度较高时可接受劣解、从而跳出局部最优；随温度降低，接受劣解的概率趋近于零，保证算法逐步收敛。温度按退火计划逐步降低，本文采用几何降温：

$$T_{k+1} = \alpha T_k, \quad \alpha \in (0, 1)$$

其中 k 为外层迭代次数， α 为降温系数（通常取 $0.85 \sim 0.99$ ）。在足够缓慢的降温条件下，系统稳态解服从玻尔兹曼分布：

$$\pi_T(x) = \frac{\exp(-f(x)/T)}{\sum_{x'} \exp(-f(x')/T)}$$

温度 $T \rightarrow 0$ 时概率质量集中于目标函数最小的状态，从而理论上可收敛到全局最优^[8]。针对本文问题，解 x 对应一个”任务迁移 + 开工时段”的完整调度方案，目标函数 f 为上述综合运行代价，初始解取”不迁移、到达后尽早执行”，邻域扰动为随机”迁移 + 时移”操作。算法参数设置如下：初始温度 $T_0 = 10^6$ （使初始接受概率接近 1）、降温系数 $\alpha = 0.95$ 、每个温度下的迭代次数 $L = 500$ 、终止条件为连续三代温度目标无改进或温度低于 $T_{\min} = 10^{-4}$ ；每次扰动随机选取 $k = 5$ 个可延迟任务执行”迁移 + 时移”操作。

6.2 模型运行结果

以第 0-2399 小时全部实际到达任务为输入，将”不迁移基准”与”碳感知调度”两种方案对比，购电成本与碳排放如表 4 所示。

表 4: 两种调度方案的购电成本与碳排放对比

方案	购电成本（万元）	碳排放（吨）	新能源利用率
不迁移基准	219076.1	2055224	0.192
碳感知调度	217763.2	2049585	0.192

碳感知调度共迁移 2529 个可延迟任务至电价与碳强度更低的区域并优化开工时段，使全时域购电成本降低 1312.9 万元，降幅 0.60%、碳排放降低 5639 吨，降幅 0.27%，在满足时延与容量约束下实现了降本减排的协同优化。

降幅相对有限的原因主要有：可迁移的仅为批量推理与人工智能训练任务，而实时推理任务占比高且不可迁移，实际迁移任务仅占全部任务的约 5%；跨区迁移受最大网络时延与区域容量的双重约束，能够迁往低成本区域的负荷有限；同时西部区域本身已承接大量训练任务，消纳与扩容空间受限。尽管如此，碳感知调度在不改变服务质量的前提下仍实现了降本减排，验证了”空间迁移 + 时间迁移”策略的有效性。

两种方案的新能源利用率均为 0.192，其原因在于：新能源利用率按”（直接消纳新能源 + 新能源充电 + 新能源外送）/可用新能源”计算，其分子与分母均由区域时间数据给定且不随任务调度改变——任务迁移仅改变负荷的时空分布，不改变各区域新能源的可用量与消纳路径，故该指标在本问题中保持不变；若需进一步提升新能源消纳，需在问题三、问题四中通过储能与购售电协同优化实现。




图 3: 模拟退火求解过程收敛曲线

图 3 为模拟退火求解过程中目标函数随迭代次数变化的收敛曲线。目标函数由初始解的约 4.85×10^8 单调下降至 4.74×10^8 ，灰色虚线为初始解水平。曲线全程单调、无发散，说明模拟退火能够稳定逼近该大规模调度问题的较优解。

7 问题三：储能协同优化

7.1 储能协同优化模型

问题三要求在给定任务调度与逐时负荷的基础上，建立储能协同优化模型，设计储能充放电策略，分析储能系统对运行成本、碳排放、区域峰值净购电功率和负荷波动程度的影响。文献研究表明，数据中心共享储能可通过削峰填谷与峰谷套利平抑负荷波动、降低购电成本，其运营模型给出了储能充放电功率与荷电状态递推的规范建模方法^[9]；源网荷储算协同框架将储能纳入算力园区整体优化，兼顾调峰与新能源消纳^[10]；算电协同实践进一步表明，利用峰谷电价差异安排储能充放电可实现削峰填谷与降本优化^[5]；计及风光不确定性的研究则强调储能对提升新能源消纳率、保障运行经济性的积极作用^[11]。受此思路启发，本文建立储能协同优化模型：以给定的逐时设施负荷、新能源可用量与购售电价、碳强度为输入，决策各区域逐时的储能充电功率、放电功率、电网购电功率、外送售电功率与新能源消纳功率，在功率平衡、荷电状态递推与上下限、充放电功率与互斥、购售电边界及终端荷电状态不低于初始值等约束下，采用“削峰填谷 + 电价引导”相结合的充放电策略，并对比无储能与有储能两种方案的运行指标。

模型的核心思想是：在电价与碳强度逐时波动、新能源出力受限的现实约束下，把储能看作可在时间轴上“搬运”电量的缓冲装置，通过低谷充电、高峰放电的削峰填谷与峰谷套利，平抑净购电波动、降低高峰购电并提升新能源消纳。目标函数各部分各有其作用机制：购电成本项 $\sum_{r,t} \pi_{r,t} P_{r,t}^{grid} \Delta t$ 反映区域逐时电价与购电量对运营成本的影响；售电收益项 $-\sum_{r,t} \pi_{r,t}^{sell} P_{r,t}^{sell} \Delta t$ 对外送售电计价，鼓励新能源富余时段外送；碳排放项 $\omega_{\kappa} \sum_{r,t} \kappa_{r,t} P_{r,t}^{grid} \Delta t$

按区域逐时碳强度对购电加权，刻画储能”以谷期低碳电替代峰期高碳电”的降碳作用；峰值净购电项 $\omega_p V$ 与负荷波动项 $\omega_f(Q^{max} - Q^{min})$ 通过辅助变量刻画储能削峰填谷的直接收益——放电替代高峰购电使峰值净购电下降，充电平抑低谷使净购电峰谷差缩小。

需要说明的是，目标函数各分量的量纲不同，购电成本与售电收益为元、碳排放为吨、峰值净购电与负荷波动为兆瓦，权重系数 ω_κ 、 ω_p 、 ω_f 除体现决策偏好外还承担量纲协调作用，其取值使各分量处于相近量级，从而实现加权标量化。约束条件保证任何充放电方案均不违反荷电状态安全区间、储能额定功率、购售电边界与新能源可用量，其中充放互斥约束禁止同一时段同时充放电，终端荷电状态约束保证储能系统可持续运行。

储能系统的物理机理由荷电状态的逐时能量守恒刻画：时段 t 的荷电状态 $SOC_{r,t}$ 由上一时段递推得到，充电功率按充电效率 η_c 折减后存入储能、放电功率按 $1/\eta_d$ 折减后放出，充放效率损耗使储能循环存在固有能量损失；充放功率受额定功率 P_r^{ess} 限制且不能同时进行，荷电状态须维持在其安全区间 $[SOC^{min}, SOC^{max}]$ 内，终端荷电状态不低于初始值则防止储能以”期末放空”投机在时域末透支电量，保证削峰填谷的收益来自真实的负荷时移而非期末套利。上述机理通过下述混合整数线性规划中的荷电状态递推、充放互斥与安全区间约束精确刻画。

以最小化综合指标为目标，储能协同优化模型可写为如下混合整数线性规划形式：

$$\left\{ \begin{array}{l} \text{argmin} \quad \sum_{r \in \mathcal{R}} \sum_{t \in \mathcal{T}} [\pi_{r,t} + \omega_\kappa \kappa_{r,t}] P_{r,t}^{grid} \Delta t \\ \quad - \sum_{r \in \mathcal{R}} \sum_{t \in \mathcal{T}} \pi_{r,t}^{sell} P_{r,t}^{sell} \Delta t + \omega_p V + \omega_f (Q^{max} - Q^{min}) \\ \text{s.t.} \quad P_{r,t}^{grid} + P_{r,t}^{new} + P_{r,t}^{dis} = P_{r,t}^{load} + P_{r,t}^{ch} + P_{r,t}^{sell} + P_{r,t}^{cur}, \quad \forall r \in \mathcal{R}, t \in \mathcal{T} \\ P_{r,t}^{new} + P_{r,t}^{cur} = P_{r,t}^{avail}, \quad \forall r \in \mathcal{R}, t \in \mathcal{T} \\ SOC_{r,t} = SOC_{r,t-1} + \frac{\eta_c P_{r,t}^{ch} \Delta t}{S_r^{cap}} - \frac{P_{r,t}^{dis} \Delta t}{\eta_d S_r^{cap}}, \quad \forall r \in \mathcal{R}, t \in \mathcal{T} \\ SOC^{min} \leq SOC_{r,t} \leq SOC^{max}, \quad \forall r \in \mathcal{R}, t \in \mathcal{T} \\ 0 \leq P_{r,t}^{ch} \leq P_r^{ess} u_{r,t}^{ch}, \quad 0 \leq P_{r,t}^{dis} \leq P_r^{ess} u_{r,t}^{dis}, \quad \forall r \in \mathcal{R}, t \in \mathcal{T} \\ u_{r,t}^{ch} + u_{r,t}^{dis} \leq 1, \quad \forall r \in \mathcal{R}, t \in \mathcal{T} \\ 0 \leq P_{r,t}^{grid} \leq P_{r,t}^{buy,max}, \quad 0 \leq P_{r,t}^{sell} \leq P_{r,t}^{sell,max}, \quad \forall r \in \mathcal{R}, t \in \mathcal{T} \\ P_{r,t}^{net} = P_{r,t}^{grid} - P_{r,t}^{sell}, \quad \forall r \in \mathcal{R}, t \in \mathcal{T} \\ V \geq P_{r,t}^{net}, \quad Q^{max} \geq P_{r,t}^{net}, \quad Q^{min} \leq P_{r,t}^{net}, \quad \forall r \in \mathcal{R}, t \in \mathcal{T} \\ SOC_{r,T} \geq SOC_{r,0}, \quad \forall r \in \mathcal{R} \\ u_{r,t}^{ch}, u_{r,t}^{dis} \in \{0, 1\}, \quad P_{r,t}^{ch}, P_{r,t}^{dis}, P_{r,t}^{grid}, P_{r,t}^{sell}, P_{r,t}^{new}, P_{r,t}^{cur}, SOC_{r,t} \geq 0, \quad \forall r \in \mathcal{R}, t \in \mathcal{T} \end{array} \right. \quad (11)$$

其中 $\mathcal{R}$ 为区域集合， $\mathcal{T}$ 为调度时段集合（取第 0 ~ 2406 小时， $T = 2406$ 为终端时段）； $P_{r,t}^{ch}$ 、 $P_{r,t}^{dis}$ 分别为区域 r 时段 t 的储能充电、放电功率， $u_{r,t}^{ch}$ 、 $u_{r,t}^{dis} \in \{0, 1\}$ 为对应的充、放状态二值变量， $P_{r,t}^{grid}$ 为区域 r 时段 t 的电网购电功率， $P_{r,t}^{sell}$ 为外送售电功率， $P_{r,t}^{new}$ 、 $P_{r,t}^{cur}$ 分别为新能源消纳与弃电功率， $SOC_{r,t}$ 为荷电状态， V 、 Q^{max} 、 Q^{min} 分别为峰值净购电与净购电上、下界的辅助变量； $P_{r,t}^{load}$ 为设施负荷， $P_{r,t}^{avail}$ 为新能源可用功率， $\pi_{r,t}$ 、 $\pi_{r,t}^{sell}$ 分别为购电价格与售电价格， $\kappa_{r,t}$ 为碳强度， η_c 、 η_d 分别为储能充、放电效率， S_r^{cap} 为储能额定容量， P_r^{ess} 为储能额定功率， SOC^{min} 、 SOC^{max} 为荷电状态上下限， $SOC_{r,0}$ 为初始荷电状态， $P_{r,t}^{buy,max}$ 、 $P_{r,t}^{sell,max}$ 分别为购电与外送功率上限， Δt 为时段长度（取 1 小时）， ω_κ 、 ω_p 、 ω_f 分别为碳排放、峰值净购电与负荷波动的权重系数。

设施负荷与新能源可用量均为给定输入。设施负荷按 $P_{r,t}^{load} = PUE_r (N_{r,t}^{AI} + N_{r,t}^{nonAI})$ 计算，其中 $N_{r,t}^{AI}$ 、 $N_{r,t}^{nonAI}$ 分别为给定任务调度下区域 r 时段 t 的人工智能与非人工智能信息技术负荷， PUE_r 为区域 r 的能源使用效率；

新能源可用功率 $P_{r,t}^{avail}$ 由区域时间数据给定，约束 $P_{r,t}^{new} + P_{r,t}^{cur} = P_{r,t}^{avail}$ 保证可用新能源要么被消纳（直接消纳、储能充电或外送）、要么以弃电形式损失。模型在”有储能”方案中启用全部储能决策与约束，在”无储能”方案中令储能容量与充放功率置零，两方案在相同负荷与价格输入下求解，从而隔离出储能对各项运行指标的贡献。

该模型为混合整数线性规划，时段一区域组合共 6×2406 个，每组合含两个二值变量（充、放状态）与若干连续变量，整数变量规模约 3×10^4 个，属于规模适中的混合整数规划，采用商业求解器 Gurobi 的分支定界法直接求解至全局最优。

从经济机理看，储能通过”低谷充电、高峰放电”同时实现峰谷套利与削峰填谷：设高峰与低谷购电价分别为 π^{hi} 、 π^{lo} ，则每兆瓦时以谷时购电替代峰时购电可节约购电成本 $\pi^{hi} - \pi^{lo}$ ；同时放电功率替代高峰时段的电网购电，降低峰值净购电 V ，充电功率平抑低谷净购电，缩小净购电峰谷差 $Q^{max} - Q^{min}$ ，从而降低目标中的峰值与波动惩罚项。储能还可在新能源富余时段充电、将弃电转化为可用电量，提升新能源消纳。目标函数中 $\omega_p V + \omega_f(Q^{max} - Q^{min})$ 两项使模型在”降本”与”削峰平波”之间权衡：储能越积极削峰，峰值与峰谷差下降越多，但因充放损耗导致的购电总量与成本上升也越多，最优策略由各项权重共同决定。

7.2 模型运行结果

以第 0-2406 小时为优化时域，各区域”无储能”与”有储能”两种方案的运行指标如表 5 所示。

表 5: 各区域无储能与有储能方案的运行指标对比

区域	方案	购电成本（万元）	碳排放（吨）	峰值净购电（MW）	负荷波动
区域 A	无储能	64446.6	592294	479.0	82.12
区域 A	有储能	64605.7	594017	479.0	73.85
区域 B	无储能	59064.2	529023	451.7	75.46
区域 B	有储能	59197.1	530411	451.7	68.39
区域 C	无储能	56335.2	492169	440.0	72.37
区域 C	有储能	56454.7	493411	440.0	65.73
区域 D	无储能	26535.3	280384	408.9	72.10
区域 D	有储能	26617.2	281408	408.9	63.43
区域 E	无储能	14580.2	92489	283.6	53.30
区域 E	有储能	14636.3	92701	283.6	49.92
区域 F	无储能	17825.3	121648	280.9	42.89
区域 F	有储能	17819.5	122297	268.2	35.93

由表可见，配置储能后各区域负荷波动均明显下降（区域 F 由 42.89 降至 35.93），区域 F 峰值净购电由 280.9 MW 降至 268.2 MW、其余区域峰值净购电不增加；购电成本基本持平（区域 F 略有下降），碳排放小幅上升，主要源于充放电效率损耗使购电总量略有增加。这表明在该电价一负荷结构下，储能的核心价值体现为削峰填谷、平抑净购电波动，而峰谷套利空间受电价峰谷与负荷峰谷不同步的限制而较为有限。




图 4: 储能协同优化前后净购电功率对比（第 0-336 小时）

图 4 展示第 0-336 小时配置储能前后净购电功率的逐时对比（灰色虚线为无储能、蓝色实线为有储能）：有储能方案在净购电尖峰时段放电削峰、在低谷时段充电填谷，使净购电曲线更为平滑，其中区域 F、D 的平抑效果最明显，区域 F 峰值净购电由 280.9 MW 降至 268.2 MW；区域 E 因自身净负荷波动较小，平抑幅度相对有限。直观反映了储能系统削峰填谷、平抑负荷波动的作用。

8 问题四：多区域”算一储一电”协同优化

8.1 协同优化模型

问题四要求在前三问基础上，建立多区域”算一储一电”协同优化模型，统一考虑任务迁移、电价、碳排放、可用新能源、储能、区域购售电边界、网络时延及任务异构性，在系统运行成本、碳排放、网络时延、服务质量、新能源利用率和区域峰值净购电之间权衡，并比较不同碳约束、电价机制和新能源波动场景下的策略变化。文献研究表明，多数据中心时空协调调度将任务迁移与开工时段联合决策，能够兼顾算力与电力资源的时空耦合^[12]；多集群异构算力调度建立了面向异构任务的迁移决策与容量、时延约束建模框架^[13]；电算协同研究将新能源不确定性与多目标优化相结合，通过场景化分析刻画不同运行情景下的策略差异^[11]；源网荷储算协同与共享储能模型给出了储能充放电与购售电边界统一优化的建模方法^[9-10]；算电协同实践进一步说明利用区域电价与新能源差异可实现跨区域协同降本^[5]。受此思路启发，本文建立多区域”算一储一电”协同优化模型：以任务迁移与开工时段为决策变量实现算力时空调度，叠加各区域储能充放电与购售电优化，形成”调度—储能—购售电”一体化的多目标优化框架。

模型的核心思想是：将时延不敏感的计算任务看作可在时空维度平移的”算力负荷包”，通过跨区域迁移与开工时段选择，把算力负荷引导至电价低、碳强度低、新能源富余的区域与时段，同时以储能削峰填谷平抑净购

电波动、提升新能源消纳，从而在运行成本、碳排放、网络时延、服务质量、新能源利用率与区域峰值净购电之间取得平衡。目标函数以购电成本、售电收益、碳排放、网络时延、开工延迟（服务质量）、弃电（新能源利用率）、峰值净购电与负荷波动等加权项构成，各分量的作用机制与符号含义详见模型式及其参数说明，其中新能源利用率以弃电惩罚项体现并作为评价指标事后核算。

需要说明的是，目标函数各分量的量纲不同，权重系数 ω_κ 、 ω_ℓ 、 ω_q 、 ω_u 、 ω_p 、 ω_f 除体现决策偏好外还承担量纲协调作用，其取值使各分量处于相近量级，从而实现加权标量化。约束条件保证任何调度与充放电方案均不违反图形处理器容量、网络时延上限、任务完成时限、荷电状态安全区间、储能额定功率与购售电边界，其中实时任务强制就地即开、充放互斥与终端荷电状态约束保证方案可行、储能可持续运行。

以最小化加权综合指标为目标，多区域“算一储一电”协同优化模型可写为如下混合整数规划形式：

$$\begin{aligned}
 & \underset{\substack{y_{i,r}, s_i, P_{r,t}^{ch}, P_{r,t}^{dis}, u_{r,t}^{ch}, u_{r,t}^{dis} \\ P_{r,t}^{grid}, P_{r,t}^{sell}, P_{r,t}^{new}, P_{r,t}^{cur}, SOC}}{\operatorname{argmin}} \sum_{r \in \mathcal{R}} \sum_{t \in \mathcal{T}} [\pi_{r,t} + \omega_\kappa \kappa_{r,t}] P_{r,t}^{grid} \Delta t \\
 & - \sum_{r \in \mathcal{R}} \sum_{t \in \mathcal{T}} \pi_{r,t}^{sell} P_{r,t}^{sell} \Delta t \\
 & + \omega_\ell \sum_{i \in \mathcal{I}} \sum_{r \in \mathcal{R} \setminus \{o_i\}} \ell_{o_i, r} y_{i,r} + \omega_q \sum_{i \in \mathcal{I}} (s_i - a_i) + \omega_u \sum_{r \in \mathcal{R}} \sum_{t \in \mathcal{T}} P_{r,t}^{cur} \Delta t + \omega_p V + \omega_f (Q^{max} - Q^{min}) \\
 \text{s.t. } & \sum_{r \in \mathcal{R}} y_{i,r} = 1, \quad \forall i \in \mathcal{I} \\
 & s_i \geq a_i, \quad \forall i \in \mathcal{I} \\
 & s_i + d_i \leq L_i, \quad \forall i \in \mathcal{I} \\
 & \ell_{o_i, r} y_{i,r} \leq l_i^{max}, \quad \forall i \in \mathcal{I}, r \in \mathcal{R} \\
 & \sum_{i \in \mathcal{I}} g_i \text{overlap}(i, r, t) \leq C_r, \quad \forall r \in \mathcal{R}, t \in \mathcal{T} \\
 & y_{i, o_i} = 1, s_i = a_i, \quad \forall i \in \mathcal{I}_{RT} \\
 & P_{r,t}^{grid} + P_{r,t}^{new} + P_{r,t}^{dis} = P_{r,t}^{load} + P_{r,t}^{ch} + P_{r,t}^{sell} + P_{r,t}^{cur}, \quad \forall r \in \mathcal{R}, t \in \mathcal{T} \\
 & P_{r,t}^{new} + P_{r,t}^{cur} = P_{r,t}^{avail}, \quad \forall r \in \mathcal{R}, t \in \mathcal{T} \\
 & SOC_{r,t} = SOC_{r,t-1} + \frac{\eta_c P_{r,t}^{ch} \Delta t}{S_r^{cap}} - \frac{P_{r,t}^{dis} \Delta t}{\eta_d S_r^{cap}}, \quad \forall r \in \mathcal{R}, t \in \mathcal{T} \\
 & SOC^{min} \leq SOC_{r,t} \leq SOC^{max}, \quad \forall r \in \mathcal{R}, t \in \mathcal{T} \\
 & 0 \leq P_{r,t}^{ch} \leq P_r^{ess} u_{r,t}^{ch}, \quad 0 \leq P_{r,t}^{dis} \leq P_r^{ess} u_{r,t}^{dis}, \quad \forall r \in \mathcal{R}, t \in \mathcal{T} \\
 & u_{r,t}^{ch} + u_{r,t}^{dis} \leq 1, \quad \forall r \in \mathcal{R}, t \in \mathcal{T} \\
 & 0 \leq P_{r,t}^{grid} \leq P_r^{buy, max}, \quad 0 \leq P_{r,t}^{sell} \leq P_r^{sell, max}, \quad \forall r \in \mathcal{R}, t \in \mathcal{T} \\
 & P_{r,t}^{net} = P_{r,t}^{grid} - P_{r,t}^{sell}, \quad \forall r \in \mathcal{R}, t \in \mathcal{T} \\
 & V \geq P_{r,t}^{net}, \quad Q^{max} \geq P_{r,t}^{net}, \quad Q^{min} \leq P_{r,t}^{net}, \quad \forall r \in \mathcal{R}, t \in \mathcal{T} \\
 & SOC_{r,T} \geq SOC_{r,0}, \quad \forall r \in \mathcal{R} \\
 & P_{r,t}^{load} = \text{PUE}_r \left(N_{r,t}^{nonAI} + \sum_{i \in \mathcal{I}} w_{\text{type}_i} g_i \text{overlap}(i, r, t) \right), \quad \forall r \in \mathcal{R}, t \in \mathcal{T} \\
 & y_{i,r} \in \{0, 1\}, s_i \in \mathbb{Z}_{\geq 0}, u_{r,t}^{ch}, u_{r,t}^{dis} \in \{0, 1\}, \\
 & P_{r,t}^{ch}, P_{r,t}^{dis}, P_{r,t}^{grid}, P_{r,t}^{sell}, P_{r,t}^{new}, P_{r,t}^{cur}, SOC_{r,t} \geq 0, \quad \forall i \in \mathcal{I}, r \in \mathcal{R}, t \in \mathcal{T}
 \end{aligned} \tag{12}$$

其中 $\mathcal{I}$ 为第 0-2399 小时实际到达的任务集合， $\mathcal{I}_{RT} \subseteq \mathcal{I}$ 为实时推理任务集合， $\mathcal{R}$ 为区域集合， $\mathcal{T}$ 为调度时段集合（取第 0 ~ 2406 小时， $T = 2406$ 为终端结算时段）； o_i 为任务 i 的来源区域， $y_{i,r} \in \{0, 1\}$ 为任务 i 是否调度至区域 r 执行的二值变量， s_i 为任务 i 的开工小时， a_i 为任务到达小时， d_i 为连续执行时长（小时）， L_i

为最晚完成小时（统一取 $L_i = 2406$ ）， $\ell_{o_i,r}$ 为来源区域 o_i 到区域 r 的单向网络时延， $l_i^{\max}$ 为任务最大网络时延， g_i 为任务图形处理器需求量， $\text{overlap}(i,r,t)$ 为任务 i 在区域 r 时段 t 的实际占用小时数， C_r 为区域 r 的可调度图形处理器容量； $P_{r,t}^{ch}$ 、 $P_{r,t}^{dis}$ 分别为区域 r 时段 t 的储能充电、放电功率， $u_{r,t}^{ch}$ 、 $u_{r,t}^{dis} \in \{0,1\}$ 为对应的充、放状态二值变量， $P_{r,t}^{grid}$ 、 $P_{r,t}^{sell}$ 、 $P_{r,t}^{new}$ 、 $P_{r,t}^{cur}$ 分别为电网购电、外送售电、新能源消纳与弃电功率， $SOC_{r,t}$ 为荷电状态， V 、 Q^{max} 、 Q^{min} 分别为峰值净购电与净购电上、下界的辅助变量； $\pi_{r,t}$ 、 $\pi_{r,t}^{sell}$ 分别为购电价格与售电价格， $\kappa_{r,t}$ 为碳强度， η_c 、 η_d 分别为储能充、放电效率， S_r^{cap} 为储能额定容量， P_r^{ess} 为储能额定功率， SOC^{min} 、 SOC^{max} 为荷电状态上下限， $SOC_{r,0}$ 为初始荷电状态， $P_r^{buy,max}$ 、 $P_r^{sell,max}$ 分别为购电与外送功率上限， Δt 为时段长度（取 1 小时）， ω_κ 、 ω_ℓ 、 ω_q 、 ω_u 、 ω_p 、 ω_f 分别为碳排放、网络时延、服务质量（开工延迟）、弃电（新能源利用率）、峰值净购电与负荷波动的权重系数。

任务层与电力层通过设施负荷耦合：设施负荷 $P_{r,t}^{load} = \text{PUE}_r (N_{r,t}^{nonAI} + \sum_{i \in \mathcal{I}} w_{\text{type}_i} g_i \text{overlap}(i,r,t))$ 由任务调度确定，其中 $N_{r,t}^{nonAI}$ 为非人工智能信息技术负荷， w_{type_i} 为任务 i 所属类型对应的每等效图形处理器平均信息技术功率（实时推理取 0.08、批量推理取 0.10、人工智能训练取 0.16 兆瓦）， PUE_r 为区域 r 的能源使用效率；与问题二不同，本模型中的电网购电功率 $P_{r,t}^{grid}$ 不再是任务调度直接决定的辅助变量，而是储能与购售电可调下的决策变量——任务调度通过改变 $P_{r,t}^{load}$ 影响功率平衡与购电量，储能通过充放电与购售电进一步调整 $P_{r,t}^{grid}$ ，二者共同决定各项运行指标。新能源可用功率 $P_{r,t}^{avail}$ 由区域时间数据给定，约束 $P_{r,t}^{new} + P_{r,t}^{cur} = P_{r,t}^{avail}$ 保证可用新能源要么被消纳（直接消纳、储能充电或外送）、要么以弃电形式损失。服务质量在本模型中通过“网络时延硬约束 + 任务完成时限 + 目标中开工延迟惩罚项”三重机制保障：实时推理任务到达即开工、不迁移，其服务质量不受影响；批量推理与人工智能训练任务的可迁移性与开工延迟由时延上限 $l_i^{\max}$ 、完成时限 L_i 与惩罚项 $\omega_q \sum_i (s_i - a_i)$ 共同约束。碳约束、电价机制与新能源波动场景分别通过调整碳权重 ω_κ 或增设碳排上限约束、改变购售电价 $\pi_{r,t}$ 、 $\pi_{r,t}^{sell}$ 以及新能源可用功率 $P_{r,t}^{avail}$ 的场景取值实现情景化对比。

8.2 模型运行结果

在前三问基础上，分别考察“基准”“碳约束”“电价机制”“新能源波动”四类场景，各场景多目标指标如表 6 所示。

表 6: 多区域协同优化四类场景的多目标指标对比

场景	购电成本（万元）	碳排放（吨）	迁移时延（ms）	迁移任务数	峰值净购电（MW）	负荷波动
基准	217952.1	2040307	807712	17029	638.5	718.4
碳约束（碳价 500）	216837.8	2024652	753385	15929	639.3	702.8
电价机制（峰谷差放大）	216994.9	2039373	804159	16916	638.2	717.2
新能源波动（出力降 30%）	247006.6	2276159	807712	17029	706.6	757.3

由表可见：碳约束场景（碳价由 50 元/吨提至 500 元/吨）引导调度更精准地向低碳区域迁移，迁移任务数由 17029 降至 15929，碳排放降低 15655 吨（降幅 0.77%）、购电成本降低 1114 万元；电价机制场景（峰谷价差放大）激励可延迟任务更多利用低谷电价时段，购电成本降低 957 万元；新能源波动场景（可用新能源出力降低 30%）使系统更多依赖电网购电，购电成本上升 13.3%、碳排放上升 11.6%，峰值净购电与负荷波动均明显恶化，凸显新能源与储能协同对系统经济性、低碳性与安全性的支撑作用。




图 5: 多区域协同优化四类场景多目标对比

图 5 按指标分面展示四类场景的多目标对比：新能源波动场景在购电成本、碳排放、峰值净购电与负荷波动各指标上均明显偏高，反映新能源出力下降对系统各维度的不利影响；碳约束场景的碳排放与负荷波动最低，体现高碳价对低碳调度的引导作用；电价机制场景的购电成本较低，表明峰谷价差扩大带来的时移套利空间。

参考文献

- [1] 张行, 田权, 张静波, 等. 基于变分模态分解与 LightGBM 的改扩建道路沉降预测模型研究[J]. 公路工程, 2026, 51(4).
- [2] 胡宏, 许晶, 姜德宏, 等. 基于 IDBO-VMD-TCN-ESN 的短期电力负荷预测方法[J]. 陕西科技大学学报, 2026, 44(6).
- [3] WANG M. US semiconductor stock forecast based on ARIMA and ETS models[Z]. 2025.
- [4] DAO T K, NGUYEN T T. Carbon-aware VM placement via surrogate-guided adaptive swarm optimization in green cloud data centers[J]. Sustainability, 2026, 18(12):6092.
- [5] 付智, 郑博文, 刘效辰, 等. 基于闲时算力调度的算电协同方法与实践[J]. 电力系统自动化, 2026.
- [6] JOSEPH V R. Experimental design for data science and engineering[M]. Boca Raton: CRC Press, 2024.
- [7] METROPOLIS N, ROSENBLUTH A W, ROSENBLUTH M N, et al. Equation of state calculations by fast computing machines[J]. The Journal of Chemical Physics, 1953, 21(6):1087-1092.
- [8] KIRKPATRICK S, GELATT C D, VECCHI M P. Optimization by simulated annealing[J]. Science, 1983, 220(4598):671-680.

- [9] QIE X, WANG F, ZHAO Q, et al. Bi-level Stackelberg game-based optimization model for shared energy storage in data centers considering computational flexibility[J]. *Energies*, 2026, 19(15): 3681.
- [10] 樊小朝, 张志豪, 王子龙, 等. 新疆绿色算力园区源网荷储算协同容量优化[J]. *综合智慧能源*, 2026, 48(8/9).
- [11] 王一航, 张靖, 何宇, 等. 计及风光不确定性的数据中心电算协同多目标优化策略[J]. *电力工程技术*, 2026, 45(5): 40-49.
- [12] LIU Y, ZHOU B, NING L, et al. Spatiotemporally coordinated operation in multiple data centers based on adaptive large neighborhood search algorithm with hierarchical collaboration[J]. *Mathematics*, 2026, 14(12): 2225.
- [13] 杨守瞻. 多集群异构算力调度优化技术研究 with 实现[D]. 贵阳: 贵州大学, 2024.