

论文标题

马文杰

李传浩

张可欣

摘要

本文针对 < 题目主题 > 问题展开研究。首先对附件数据进行预处理与统计分析，提出了...模型。

针对问题一，本文...（简述方法），得到...（简述关键结果）。

针对问题二，本文...（简述方法），得到...（简述关键结果）。

针对问题三，本文...（简述方法），得到...（简述关键结果）。

针对问题四，本文...（简述方法），得到...（简述关键结果）。

综上所述，本文所建立的模型...（总结模型适用性与优点）。

关键词：关键字 1；关键字 2；关键字 3；关键字 4

1 问题重述

随着人工智能算力规模的持续扩张，数据中心的用电需求、碳排放及其与电网的交互影响不断增强，电力成本已成为数据中心运营成本的核心组成部分。在此背景下，“算电协同”成为了算力负荷与电力系统实时耦合优化的现实需求。由于东部地区时延低、实时业务需求高，而西部地区具备电价低、新能源丰富的优势，跨区域算力迁移与能源调度构成一个多目标协同优化问题。赛题设定六个典型区域：区域 A、区域 B、区域 C 为东部高负荷区域，区域 D 为西部算力中心，区域 E、区域 F 分别为光伏与风电资源富集区域。任务到达主时域为第 0-2399 小时，第 2400-2405 小时用于结清末端任务，第 2406 小时不安排任务，仅进行电力与储能终端状态结算。任务分为实时推理、批量推理与人工智能训练三类，均不可抢占、不可拆分或中途迁移。赛题要求基于附件提供的 GPU 容量、任务轨迹、网络时延、电价、碳强度、新能源出力与储能等数据，依次解决以下四个问题：

问题一是算力需求分析与短期预测。对不同区域、不同任务类型的 GPU 需求进行统计分析并构建短期预测模型，进而建立基础算力调度模型，给出第 2376-2399 小时实际到达任务的调度方案，并展示最后 24 小时的调度甘特图与区域 GPU 利用率；问题二是碳感知任务调度。以第 0-2399 小时实际到达任务及逐时电力参数为输入，以任务迁移与开工时段为决策变量，以运行成本、碳排放、网络时延和新能源利用率为目标或评价指标，建立碳感知任务调度模型并给出调度策略；问题三是储能协同优化。在给定任务调度与逐时负荷的基础上，建立储能协同优化模型，设计储能充放电策略，分析储能系统对运行成本、碳排放、区域峰值净购电功率和负荷波动程度的影响；问题四是多区域协同优化。建立多区域“算一储一电”协同优化模型，统一考虑任务迁移、电价、碳排放、可用新能源、储能、区域购售电边界、网络时延及任务异构性，在系统运行成本、碳排放、网络时延、服务质量、新能源利用率和区域峰值净购电之间进行权衡，并比较不同碳约束、电价机制和新能源波动场景下的策略变化。

2 问题分析

问题一首先对 GPU 需求按区域、任务类型进行统计分析，刻画需求分布特征；其次利用历史到达数据构建短期预测模型，为第 2376-2399 小时提供前瞻性需求输入；最后在算力容量、网络时延与任务完成时限约束下建

立基础算力调度模型，输出调度方案、最后 24 小时调度甘特图与区域 GPU 利用率；问题二是碳感知任务调度，以任务迁移决策与开工时段为决策变量，在满足时延、容量与完成时限约束的前提下，权衡运行成本、碳排放、网络时延与新能源利用率四类目标。利用西部低电价、低碳强度与新能源优势实现降本减排，训练任务作为主要迁移对象；问题三是储能协同优化：在给定任务调度与逐时负荷的基础上，优化储能充放电策略，利用峰谷电价差异实现削峰填谷与套利、平抑负荷波动、促进新能源消纳，并定量分析储能对运行成本、碳排放、区域峰值净购电功率与负荷波动的影响。问题四是多区域协同优化：将任务调度、电力交易、储能运行统一纳入多区域“算一储一电”协同优化模型，综合考虑任务异构性、网络时延、算力容量、购售电边界与新能源波动，在系统运行成本、碳排放、网络时延、服务质量、新能源利用率与区域峰值净购电等多目标间权衡，并通过碳约束、电价机制与新能源波动等场景对比进行敏感性分析。

3 数据预处理

首先应该保证数据质量与口径一致。对各数据表进行完整性、取值范围与内部勾稽关系校验，确认数据无缺失、无越界，且各字段间的逻辑关系，如任务类型与最大网络时延、设施侧总负荷与信息技术侧负荷及能源使用效率之间，应该保持一致，避免因数据问题导致模型结果失真；其次是统一数据粒度与计量单位：将任务连续执行时长由分钟统一换算为小时，与小时级调度时段对齐；明确主时域（第 0-2399 小时）与收尾时域（第 2400-2406 小时）的边界，保证任务、负荷、电价、储能等数据在同一时间坐标系下可比、可算；最终构造建模所需的标准化输入：按区域、任务类型对图形处理器需求进行聚合，形成小时级需求序列，并按赛题给定口径切分为训练集、调参集与测试集，为需求统计分析、短期预测与基础算力调度提供直接可用的数据输入。依据任务轨迹数据校验的结果显示：附件数据完整、口径自洽，可直接用于后续建模，无需额外清洗。

本文全部数据均取自赛题附件，未引入外部数据。其原因在于附件数据为赛题量身设计，涵盖任务轨迹、区域算力容量、网络时延、功率映射、区域逐时电力数据与储能信息，四个问题所需的全部输入均已具备；另一方面，赛题要求各问题以附件给出的实际数据作为统一优化输入以保证结果可比性，外部数据与题目口径不一致，反而会影响模型结果的一致性。对于问题四中的碳约束、电价机制与新能源波动等场景对比，本文在附件数据基础上构造相应的扰动情景加以分析，亦无需外部数据。因此，附件数据在数量上与覆盖面上均足以支撑本文的全部建模工作。

4 模型假设

基于赛题给定口径与附件数据特征，本文在建模时作如下假设：任务均不可抢占、不可拆分或在中途转移至其他区域，各任务相互独立、不存在依赖关系，其中实时推理任务到达即开工，批量推理与人工智能训练任务允许延迟调度但最迟须在第 2406 小时前完成；区域间通信仅考虑附件给定的单向等效网络时延，忽略网络带宽、迁移数据量、传输能耗及传输费用，跨区域调度的可行性由任务的最大网络时延约束决定；各区域逐时电价、碳强度、可用新能源出力及负荷均视为附件给定的确定性参数，即本文建立确定性优化模型；各类任务每等效图形处理器产生的信息技术功率按附件功率映射统一取值，且任务在执行时段内功率恒定，设施侧总负荷按“总信息技术负荷 $\times$ 区域能源使用效率”计算；储能充放电效率在运行周期内视为常数，荷电状态按线性递推关系更新，且储能仅服务于所在区域、不进行跨区域调用；附件数据经质量校验确认完整、口径自洽，可直接用于建模；各区域任意时段的可调度图形处理器容量、信息技术侧最大功率与设施侧最大功率均构成硬约束，调度方案不得违反。

5 问题一：算力需求分析与短期预测

5.1 图形处理器需求统计分析

对工作负载轨迹中的 50000 个人工智能任务，按区域与任务类型统计其图形处理器需求分布，结果如表 1、表 2所示。

表 1: 不同任务类型的 GPU 需求统计

任务类型	任务数	需求量均值	最大值	GPU-小时总量
实时推理任务	16724	4.0	7	228150
批量推理任务	16717	13.5	23	769098
人工智能训练任务	16559	71.3	127	4023539

三类任务的需求特征分层明显：实时推理任务单任务图形处理器需求量大、数量多、时延敏感；人工智能训练任务单任务需求量最大，是算力消耗的主体，其图形处理器-小时总量约占全部任务的 80%；批量推理任务介于两者之间。

表 2: 不同区域的 GPU 需求统计

区域	任务数	需求量均值	GPU-小时总量
区域 A	10062	13.1	448452
区域 B	9200	13.8	430758
区域 C	7559	14.6	374934
区域 D	9560	47.6	1548858
区域 E	6912	46.9	1087748
区域 F	6707	48.5	1130035

分区域看，东部高负荷区域 A、B、C 以实时推理与批量推理任务为主，任务数量大但单任务需求小，需求量均值约 13-15；西部区域 D、E、F 承接大量人工智能训练任务，单任务需求大，需求量均值约 47-49，其中区域 D 的图形处理器-小时总量最大（约 155 万）。上述特征表明：训练任务是跨区域调度与新能源协同的主要调节对象，东部存在较大的可迁移算力空间，与后文基础调度及碳感知调度的分析结果一致。分区域、分任务类型的图形处理器需求分布如图 1 所示。

5.2 算力需求短期预测模型

赛题要求利用历史到达数据构建短期预测模型，为第 2376-2399 小时的调度提供前瞻性的图形处理器需求输入。小时级图形处理器需求序列具有较强的波动性，传统时间序列模型（如 ETS、ARIMA）对该类序列的预测精度有限。文献研究表明，变分模态分解（VMD）等自适应信号分解方法可将原始序列拆分为若干相对平稳的模态分量，对各分量分别建模预测、最后叠加得到整体预测，从而降低序列复杂度、提升预测精度（张行等，2026；胡宏等，2026）。受此思路启发，本文在 R 环境下以自适应集合经验模态分解（CEEMDAN）实现信号分解。

自适应集合经验模态分解（CEEMDAN）模型

CEEMDAN 在经验模态分解 (EMD) 的基础上, 通过向残差信号逐次叠加自适应高斯白噪声并进行集合平均以抑制模态混叠, 将原始图形处理器需求序列 $x(t)$ 分解为 K 个模态分量 $\text{IMF}_k(t)$ 与残差项 $r(t)$:

$$x(t) = \sum_{k=1}^K \text{IMF}_k(t) + r(t) \quad (1)$$

与变分模态分解 (VMD) 等同属自适应信号分解方法, CEEMDAN 无需预设中心频率, 依靠迭代筛分自适应确定各模态分量, 更适用于近似平稳且无明显周期结构的波动序列。将所得分量按频率特征划分为低频趋势分量、中频波动分量与高频随机分量, 分别采用适用的模型预测后叠加重构:

$$\hat{x}(t+h) = \sum_{k \in \mathcal{L}} \widehat{\text{IMF}}_k(t+h) + \sum_{k \in \mathcal{M}} \widehat{\text{IMF}}_k(t+h) + \sum_{k \in \mathcal{H}} \widehat{\text{IMF}}_k(t+h) \quad (2)$$

其中 $\mathcal{L}$ 、 $\mathcal{M}$ 、 $\mathcal{H}$ 分别为低频、中频、高频分量下标集合。

为量化预测精度, 本文采用均方根误差 (RMSE)、平均绝对误差 (MAE) 与平均绝对百分比误差 (MAPE) 三项指标, 其定义为:

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{t=1}^N (y_t - \hat{y}_t)^2}, \quad (3)$$

$$\text{MAE} = \frac{1}{N} \sum_{t=1}^N |y_t - \hat{y}_t|, \quad (4)$$

$$\text{MAPE} = \frac{1}{N} \sum_{t=1}^N \frac{|y_t - \hat{y}_t|}{y_t} \times 100\% \quad (5)$$

其中 y_t 为第 t 小时图形处理器需求实际值, $\hat{y}_t$ 为模型预测值, $N = 24$ 为预测步数。以第 0–2375 小时逐时图形处理器总需求为训练数据, 向前预测第 2376–2399 小时共 24 步, 与测试集实际值比较, 结果如表 3 所示。

实验结果未实现预期的精度提升。分析认为, “分解 + 预测 + 重构” 在本数据上未带来提升的原因主要有: 预测误差累积。序列被分解为 11 个分量, 需对各分量分别进行 24 步向前预测, 高频随机分量几乎不可预测, 各分量误差叠加后重构总误差显著增大; 序列结构不匹配。逐时图形处理器需求序列波动相对平稳、无明显趋势与季节周期, 分解方法更适用于具有明确趋势或季节结构的序列, 对近似平稳的波动序列难以提供结构增益; 多步预测挑战。一次性向前 24 步预测对高频分量的可预测性提出了过高要求。

5.3 组合预测与最终模型选择

针对上述问题, 文献研究表明, 单一时间序列模型的预测能力存在上限, 将 ARIMA 与 ETS 等模型的预测结果进行组合, 可综合各自优势、降低预测风险 (Wang, 2025)。受此思路启发, 本文进一步考察了 ETS 与 ARIMA 的组合预测策略:

指数平滑 (ETS) 模型

指数平滑将序列分解为水平、趋势与季节三个成分, 通过指数递减权重递推更新, 其状态空间递推方程为:

$$l_t = \alpha y_t + (1 - \alpha)(l_{t-1} + b_{t-1}), \quad (6)$$

$$b_t = \beta(l_t - l_{t-1}) + (1 - \beta)b_{t-1}, \quad (7)$$

$$s_t = \gamma(y_t - l_{t-1} - b_{t-1}) + (1 - \gamma)s_{t-m} \quad (8)$$

h 步预测为 $\hat{y}_{t+h|t} = l_t + hb_t + s_{t+h-m}$, 其中 $\alpha, \beta, \gamma \in (0, 1)$ 为平滑参数, m 为季节周期长度。本文采用 ETS 自动定阶, 其在当前序列上自动选择 “加性误差、无趋势、无季节” (A,N,N), 退化为简单指数平滑 $l_t = \alpha y_t + (1 - \alpha)l_{t-1}$, 即仅对序列水平作指数加权平均。

ARIMA 模型

自回归积分滑动平均模型（ARIMA(p, d, q)）先对序列作 d 阶差分 $\nabla^d y_t = (1 - B)^d y_t$ 以消除非平稳性，再建立自回归与移动平均的混合模型：

$$\phi(B)\nabla^d y_t = c + \theta(B)\varepsilon_t$$

其中 B 为滞后算子（ $By_t = y_{t-1}$ ）， $\phi(B) = 1 - \phi_1 B - \dots - \phi_p B^p$ 为自回归系数多项式， $\theta(B) = 1 + \theta_1 B + \dots + \theta_q B^q$ 为移动平均系数多项式， c 为常数项， ε_t 为零均值白噪声。本文 ARIMA 自动定阶结果为 (0,0,0)，即 $y_t = c + \varepsilon_t$ ，退化为“常数均值 + 白噪声”的水平模型。

以调参集（第 2352-2375 小时）对二者的预测结果进行组合权重寻优，考察等权组合与最优权重组合两种方式，向前预测第 2376-2399 小时共 24 步，组合结果与单模型一并汇总于表 3。

表 3: 各模型短期预测性能对比

模型	RMSE	MAE	MAPE
ETS	221.0	176.7	23.39%
ARIMA	221.1	176.7	23.39%
分解 + ARIMA	383.2	277.4	36.37%
分解 + LightGBM	261.1	207.9	27.12%
等权组合（ETS+ARIMA）	221.0	176.7	23.39%
最优权重组合（ETS+ARIMA）	221.1	176.7	23.39%

实验结果显示，分解-预测-重构模型的精度反而低于直接采用 ETS/ARIMA 的基准模型，未实现预期的精度提升。其内在原因是：预测误差累积——序列被分解为 11 个分量，需对各分量分别进行 24 步向前预测，高频随机分量几乎不可预测，各分量误差叠加后重构总误差显著增大；序列结构不匹配——逐时图形处理器需求序列波动相对平稳、无明显趋势与季节周期，分解方法更适用于具有明确趋势或季节结构的序列，对近似平稳的波动序列难以提供结构增益；多步预测挑战——一次性向前 24 步预测对高频分量的可预测性提出了过高要求。

5.4 基础算力调度模型

本节在图形处理器容量、网络时延与完成时限约束下，以任务开工时段与执行区域为决策变量，建立第 2376-2399 小时实际到达任务的基础算力调度模型。

以最小化任务总开工延迟与迁移惩罚之和为目标，基础算力调度模型可写为如下混合整数规划形式：

$$\left\{ \begin{array}{l} \text{argmin}_{s_i, y_{i,r}} \sum_{i \in \mathcal{I}} (s_i - a_i) + \theta \sum_{i \in \mathcal{I}} \sum_{r \in \mathcal{R} \setminus \{o_i\}} y_{i,r} \\ \text{s.t. } \sum_{r \in \mathcal{R}} y_{i,r} = 1, \quad \forall i \in \mathcal{I} \\ s_i \geq a_i, \quad \forall i \in \mathcal{I} \\ s_i + d_i \leq L_i, \quad \forall i \in \mathcal{I} \\ \ell_{o_i, r} y_{i,r} \leq l_i^{\max}, \quad \forall i \in \mathcal{I}, r \in \mathcal{R} \\ \sum_{i \in \mathcal{I}} g_i \text{overlap}(i, r, t) \leq C_r, \quad \forall r \in \mathcal{R}, t \in \mathcal{T} \\ y_{i,r} \in \{0, 1\}, \quad s_i \in \mathbb{Z}_{\geq 0}, \quad \forall i \in \mathcal{I}, r \in \mathcal{R} \end{array} \right. \quad (9)$$

其中 $\mathcal{I}$ 为第 2376-2399 小时实际到达的任务集合, $\mathcal{R}$ 为区域集合, $\mathcal{T}$ 为调度时段集合; o_i 为任务 i 的来源区域, $y_{i,r} \in \{0,1\}$ 为任务 i 是否调度至区域 r 执行的二值指派变量, s_i 为任务 i 的开工小时, a_i 为任务到达小时, d_i 为连续执行时长 (小时), L_i 为最晚完成小时, $\ell_{o_i,r}$ 为来源区域 o_i 到区域 r 的单向网络时延, $l_i^{\max}$ 为任务的最大网络时延, g_i 为任务图形处理器需求量, $\text{overlap}(i,r,t)$ 为任务 i 在区域 r 时段 t 的实际占用小时数, C_r 为区域 r 的可调度图形处理器容量, θ 为迁移惩罚系数。目标中的第二项 $\theta \sum_{i \in \mathcal{I}} \sum_{r \in \mathcal{R} \setminus \{o_i\}} y_{i,r}$ 为迁移惩罚, 惩罚任务离开来源区域执行, 从而在容量可行时优先本地调度、抑制不必要的跨区迁移, 与下述贪心求解策略一致。

在上述模型与贪心算法下, 第 2376-2399 小时实际到达的 538 个任务全部按时完成, 仅 1 个实时推理任务因容量冲突就近调度至相邻区域, 可延迟任务平均开工延迟 0.04 小时。第 2376-2399 小时区域平均图形处理器利用率: 区域 E、F 分别达 0.718、0.794 (峰值接近满载), 区域 A、B、C 为 0.24-0.38, 东部存在较大剩余算力空间, 可为后续跨区域调度提供迁移方向。调度甘特图与区域图形处理器利用率如图 2、图 3 所示。




图 1: 第 2376-2406 小时基础调度甘特图

图 2 按执行区域分面展示第 2376-2406 小时的调度甘特图, 每个色条表示一个任务的图形处理器占用区间, 颜色区分任务类型: 实时推理任务到达即开工、区间较短; 批量推理与人工智能训练任务区间较长, 部分任务跨越第 2399 小时并在收尾时域内结清; 西部区域 E、F 任务条密集, 东部区域 A、B、C 相对稀疏。



图 2: 六区域逐时 GPU 利用率

图 3 展示六区域逐时图形处理器利用率：区域 E、F 长期处于高位并接近满载（峰值约 0.997、0.995），区域 D 处于中等水平，区域 A、B、C 整体偏低，利用率随时间的起伏反映了任务到达的随机性与批量、训练任务调度的时序特征。