

陕西科技大学学报

Journal of Shaanxi University of Science & Technology

ISSN 2096-398X, CN 61-1080/TS

《陕西科技大学学报》网络首发论文

题目: 基于 IDBO-VMD-TCN-ESN 的短期电力负荷预测方法
作者: 胡宏, 许晶, 姜德宏, 郑云, 徒有锋, 王鹏程
DOI: 10.19481/j.cnki.issn2096-398x.20260826.002
收稿日期: 2026-07-28
网络首发日期: 2026-08-26
引用格式: 胡宏, 许晶, 姜德宏, 郑云, 徒有锋, 王鹏程. 基于 IDBO-VMD-TCN-ESN 的短期电力负荷预测方法[J/OL]. 陕西科技大学学报.
<https://doi.org/10.19481/j.cnki.issn2096-398x.20260826.002>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

基于 IDBO-VMD-TCN-ESN 的短期电力负荷预测方法

胡 宏¹, 许 晶^{2*}, 姜德宏¹, 郑 云¹, 徒有锋¹, 王鹏程¹

(1. 江苏鑫顺能源发展有限公司, 江苏 南京 210024; 2. 中国矿业大学 信息与控制工程学院, 江苏 徐州 221008)

摘 要: 准确的电力负荷预测是保障电网安全稳定调度的重要依据。针对电力负荷数据非线性强、波动剧烈等特点导致预测精度不足的问题, 本研究提出了一种融合改进蜣螂优化器(Improved dung beetle optimizer, IDBO)、变分模态分解(Variational mode decomposition, VMD)、时间卷积网络(Temporal convolutional network, TCN)和回声状态网络(Echo state network, ESN)的短期电力负荷预测算法 IDBO-VMD-TCN-ESN。首先, 对原始数据进行清洗并筛选重要特征; 然后, 融合 Cubic 混沌映射、协同搜索和自适应 T 分布策略提出改进的 DBO 算法 IDBO, 增强模型的寻优能力; 其次, 依托 IDBO 优化 VMD 参数, 对原始负荷序列进行模态分解; 再次, 利用 TCN 捕捉数据中存在的长期依赖关系, 结合经 IDBO 优化后的 ESN 实现准确预测; 最后, 基于真实数据集开展对比验证。实验结果表明, 所提模型相较基线模型在 MSE 等评价指标上均提高了 10% 以上, 具备优异的预测性能。

关键词: 电力负荷预测; 蜣螂优化器; 变分模态分解; 回声状态网络

中图分类号: TM715; TP183

文献标识码: A

Short-term power load forecasting method based on IDBO-VMD-TCN-ESN

HU Hong¹, XU Jing^{2*}, JIANG De-hong¹, ZHENG Yun¹, TU You-feng¹, WANG Peng-cheng¹

(1. Jiangsu Xinshun Energy Development Co., Ltd., Nanjing 210024, China; 2. School of Information and Control Engineering, China University of Mining and Technology, Xuzhou 221008, China)

Abstract: Accurate power load forecasting is essential for the safe and stable dispatching of power grids. To address low prediction accuracy stemming from strong nonlinearity and drastic fluctuations in power load data, this work presents IDBO-VMD-TCN-ESN, a short-term power load forecasting algorithm integrating improved dung beetle optimizer (IDBO), variational mode decomposition (VMD), temporal convolutional network (TCN) and echo state network (ESN). Firstly, raw data are preprocessed for data cleansing, followed by screening of critical features. Secondly, an improved DBO algorithm is developed by incorporating cubic chaotic mapping, collaborative search, and an adaptive T-distribution strategy to enhance the optimization ability of the model. Then, the IDBO is employed to optimize VMD parameters and perform modal decomposition on the original load sequence; Subsequently, TCN is adopted to capture the long-term dependencies in data. With the ESN optimized by IDBO, accurate prediction is further achieved; Finally, comparative validations are carried out on real-world datasets. Experimental results show that the proposed model obtains

收稿日期: 2026-07-28

基金项目: 国家科技重大专项项目(2025ZD1700804); 国网江苏省电力有限公司科技项目(XSNY25-26H01)

作者简介: 胡 宏 (1970-), 男, 江苏连云港人, 高级工程师, 硕士, 研究方向: 电力电子技术

通讯作者: 许 晶 (1976-), 男, 江苏徐州人, 高级工程师, 在读博士研究生, 研究方向: 人工智能应用、电力电子技术, 3084205116@qq.com

over 10% gains in MSE and other metrics compared with baseline models, demonstrating its superior prediction performance.

Key words: power load forecasting; dung beetle optimizer; variational mode decomposition; echo state network

0 引言

随着电力系统规模不断扩大和用电需求持续增长, 负荷预测已成为电力系统规划、运行与管理的重要基础^[1,2]。准确的负荷预测结果不仅能够为电力调度、容量配置和需求响应提供决策依据, 而且对于提高电力系统运行的安全性和经济性具有重要意义^[3]。然而, 实际电力负荷数据具有较强的非线性、非平稳性和随机波动特征, 传统预测方法难以充分挖掘其时序规律, 导致预测精度受限。因此, 研究高精度短期电力负荷预测方法具有重要的理论意义和工程价值。

近年来, 深度神经网络被广泛应用于电力负荷预测任务^[4,5]。其中, 循环神经网络(recurrent neural networks, RNNs) 能够有效建模负荷数据的时序特征, 但难以捕捉长期依赖关系^[6,7], 但是 RNNs 难以建模负荷数据的长期依赖关系。为提高负荷预测准确性, 研究人员提出基于经验模态分解(empirical mode decomposition, EMD)的方法^[8,9]。然而, EMD 难以确定最优模态分解数; 同时, 现有优化算法虽可缓解超参数人工设定问题^[10], 但是在迭代优化过程中容易陷入局部最优, 造成预测精度不够准确。

为解决上述问题, 本文提出 IDBO-VMD-TCN-ESN 模型。在真实数据集上的实验验证了该模型的有效性。本文主要贡献如下:

(1) 提出了改进型蜣螂优化算法 IDBO, 通过引入 Cubic 混沌映射、协同搜索和自适应 T 分布策略, 提升了算法的收敛速度, 减少了人工设定超参数的成本问题, 缓解了容易陷入局部最优解的问题。

(2) 提出了一种 IDBO-VMD-TCN-ESN 的负荷预测模型, 有效捕捉负荷数据中存在的长期依赖关系, 提高预测精度。

(3) 在真实数据集上进行了大量实验, 并与其它基线模型进行了比较。实验结果表明, 所提模型性能最优, 具有较高的预测准确率。

1 相关工作

机器学习和深度学习算法在预测能源需求和电力消耗领域得到了广泛应用^[6]。大量研究人员使用深度学习算法对时序负荷数据进行探索、解释和分析。面对随时间变化的复杂负荷数据, 传统方法多采用简单的 RNNs 模型。例如, Kong 等^[11]提出一种基于 LSTM 的负荷预测方法, 能够对单个家庭的负荷情况进行预测。Hua 等^[12]通过集成 CNN 和 GRU 并行提取负荷数据的空间特征和时序特征, 并利用改进的残差网络实现负荷数据的有效预测。传统基于 RNNs 的负荷预测模型虽然能够捕获负荷数据的时序特征, 并对负荷的变化进行预测, 但是在捕获长期依赖关系上存在困难, 造成预测负荷变化的准确度下降。相比传统 RNNs 结构, TCN 通过扩张卷积和因果卷积能够有效扩大感受野, 增强长期依赖关系建模能力, 同时具有并行计算效率高的优势。因此, TCN 在复杂时序预测任务中展现出良好的性能^[13]。然而, 仅依赖深度神经网络进行负荷预测, 仍难以充分处理负荷数据中的非平稳性与高频波动特征, 从而限制了预测精度。

近年来, 由于电力负荷序列具有较强的非线性和非平稳特性, 研究人员利用信号分解方法将原始负荷数据分解为多个分量^[14,15], 以提高预测性能。EMD 作为一种经典的自适应信号分解方法, 被广泛应用于负荷预测领域。然而, 基于 EMD 的方法模态划分不清晰, 易造成模态混叠问题, 影响预测性能^[16]。而基于 VMD 的方法能够缓解 EMD 带来的模态混叠问题, 提高预测的准确性^[17-19]。农高海^[20]利用 VMD 将负荷数据分解为多个具有不同频率的模态分量, 即本征模态函数(intrinsic mode functions, IMF), 然后利用双向 LSTM 捕获数据间的依赖关系, 实现对每个模态分量的预测。实验结果证明, 基于 VMD 分解的方法能够有效捕捉到负荷数据的规律, 提高模型的预测精度。然而, VMD 在确定模态最优分解数上存在困难, 限制模型的表现能力。

为缓解人工经验设定超参数带来的预测精度下降问题, 研究人员提出在模型中引入优化算法。Duan 等^[21]利用 VMD 分解原始负荷数据为多个模

态分量, 然后对每个模态利用粒子群算法(particle swarm optimization, PSO)优化向量机参数, 最后对预测的序列进行重构, 获得了较好的性能。Tan等^[22]利用布谷鸟搜索算法有效提取时序特性, 并获得 VMD 的最优参数, 从而将时序信号分解为一组最优分量。实验结果表明, 优化后的 VMD 算法能够有效提升模型的预测精度。因此, 优化算法能够自适应寻找最优参数, 提高模型性能。然而, 现有优化算法在迭代优化过程中容易陷入局部最优。

结合上述分析, 现有工作存在预测精度不足、人工确定超参数困难、易陷入局部最优的问题。因此, 本文旨在设计一种能够捕捉负荷数据长期依赖关系、自动确定模型超参数的负荷预测算法, 以提高预测精度, 同时缓解现有模型在迭代过程中存在的局部最优问题。

2 相关理论

2.1 变分模态分解 VMD

VMD 算法是一种非递归的信号分解方法, 能够将复杂信号分解为多个有限带宽的本征模态函数 IMF, 缓解了 EMD 算法带来的模态混叠问题^[23]。其分解步骤如下:

首先, 根据原始信号构造变分问题, 如式(1)所示:

$$\begin{cases} \min_{\{u_m\}, \{\omega_m\}} \left\{ \sum_k \left\| \partial(t) \left[\left(\delta(t) + \frac{j}{\pi t} \right) * u_k(t) \right] * e^{-j\omega_m t} \right\|^2 \right\} \\ \text{s.t.} \sum_{m=1}^M u_m = f(t) \end{cases} \quad (1)$$

式(1)中: M 是分解模态的个数; $\{u_1, u_2, \dots, u_M\}$ 表示分解的 IMF 信号; $\{\omega_1, \omega_2, \dots, \omega_M\}$ 是相应 IMF 的中心频率; $f(t)$ 是原始负荷信号; $\delta(t)$ 是 Dirac 分布函数; $\partial(t)$ 是函数对时间 t 的偏导; $*$ 是卷积运算符。

然后, 利用 Lagrange 方法将式(1)中的有约束极值问题转换为无约束问题, 如式(2)所示:

$$\begin{aligned} L(\{u_m\}, \{\omega_m\}, \lambda) \\ = \alpha \sum_m \left\| \partial_t \left[\left(\delta(t) + \frac{j}{\pi t} \right) * u_m(t) \right] e^{-j\omega_m t} \right\|_2^2 \\ + \left\| f(t) - \sum_m u_m(t) \right\|_2^2 + \left\langle \lambda(t), f(t) - \sum_m u_m(t) \right\rangle \end{aligned} \quad (2)$$

式(2)中: $L(\cdot)$ 为拉格朗日函数; α 为二次惩罚项; λ 为拉格朗日乘子。 α 和 λ 代表约束对最优解的“权重”。

最后, 各 IMF 分量及相应的中心频率可以由交替方向乘子法和傅里叶等距变换法来进行求解, 求解方法如式(3)~(5)所示:

$$\hat{u}_m^{n+1}(\omega) = \frac{\hat{f}(\omega) - \sum_{i \neq m} \hat{u}_i^n(\omega) + \frac{\hat{\lambda}^n(\omega)}{2}}{1 + 2\alpha(\omega - \omega_m^n)^2} \quad (3)$$

$$\omega_m^{n+1} = \frac{\int_0^\infty \omega \left| \hat{u}_m^{n+1}(\omega) \right|^2 d\omega}{\int_0^\infty \left| \hat{u}_m^{n+1}(\omega) \right|^2 d\omega} \quad (4)$$

$$\hat{\lambda}^{n+1}(\omega) = \hat{\lambda}^n(\omega) + \tau \left(f(\omega) - \sum_m \hat{u}_m^{n+1}(\omega) \right) \quad (5)$$

式(3)~(5)中: $\hat{f}(\omega)$ 、 $\hat{u}(\omega)$ 和 $\hat{\lambda}(\omega)$ 分别是 $f(t)$ 、 $u(t)$ 和 $\lambda(t)$ 的傅里叶变换; n 表示迭代次数。

通过上述过程, VMD 将复杂非线性的原始负荷信号分解为具有各自频率的部分, 降低原始负荷信号的复杂度, 便于下游任务对数据的分析与利用。

2.2 蜣螂优化算法 DBO

2.2.1 滚球行为

蜣螂优化算法的滚球行为有两种模式, 即无障碍模式和避障模式。当前进方向无阻碍时, 滚球过程中的位置更新如式(6)所示:

$$\begin{cases} x_i(t+1) = x_i(t) + \alpha \times \kappa \times x_i(t-1) + b \times \Delta x \\ |\Delta x| = |x_i(t) - X^w| \end{cases} \quad (6)$$

式(6)中: t 表示迭代次数; $x_i(t)$ 表示第 i 只蜣螂在循环 t 时的位置; κ 表示偏转系数, 值范围为 $(0, 0.2]$; b 是常数, 值范围为 $(0, 1)$; α 是一个自然系数, 用于表示是否偏离行进方向, 根据概率方法取值为 1 或 -1; X^w 代表全局最差位置; Δx 用于表示环境光强的变化。

如果蜣螂遇到障碍物且无法正常移动, 位置更新如式(7)所示:

$$x_i(t+1) = x_i(t) + \tan(\theta) \cdot |x_i(t) - x_i(t-1)| \quad (7)$$

式(7)中: θ 的取值范围为 $[0, \pi]$, 如果是 0、 π 或 $\pi/2$, 蜣螂的位置不会更新。

2.2.2 繁殖行为

采用动态边界选择策略以模拟雌性蜣螂在繁殖过程中的产卵区, 如式(8)所示:

$$\begin{cases} Lb^* = \max(X^* \times (1-R), Lb) \\ Ub^* = \min(X^* \times (1+R), Ub) \end{cases} \quad (8)$$

式(8)中: X^* 为当前的局部最优位置; Lb^* 和 Ub^* 分别为繁殖区的下界和上界; R 的值为 $1-t/T_{\max}$, 其中 $T_{\max}$ 表示最大迭代次数; Lb 和 Ub 分别代表下界和上界。

此外, 根据公式(8), 蜣螂的繁殖区动态变化, 因此繁殖球在迭代过程中的位置如式(9)所示:

$$\begin{aligned} B_i(t+1) = & X^* + b_1 \times (B_i(t) - Lb^*) \\ & + b_2 \times (B_i(t) - Ub^*) \end{aligned} \quad (9)$$

式(9)中: $B_i(t)$ 表示第 i 只蜣螂在第 t 个迭代中产卵的位置; b_1 和 b_2 是两个独立的随机向量, 维度为 $1 \times D$; D 表示维度。

2.2.3 觅食行为

出生后, 小蜣螂需要在有限的觅食区域内觅食。最佳觅食区的定义见公式(10)所示:

$$\begin{cases} Lb^b = \max(X^b \times (1-R), Lb) \\ Ub^b = \min(X^b \times (1+R), Ub) \end{cases} \quad (10)$$

式(10)中: Lb^b 和 Ub^b 表示最佳觅食区的下界和上界; X^b 为当前最佳位置。

小蜣螂在最佳觅食区进行觅食行为, 其位置更新如式(11)所示:

$$\begin{aligned} x_i(t+1) = & x_i(t) + C_1 \times (x_i(t) - Lb^b) \\ & + C_2 \times (x_i(t) - Ub^b) \end{aligned} \quad (11)$$

式(11)中: C_1 为随机数; C_2 表示值域为(0, 1)的随机向量。

2.2.4 盗窃行为

在蜣螂盗窃过程中, 个体蜣螂的位置更新如式(12)所示:

$$\begin{aligned} x_i(t+1) = & X^b + S \times g \\ & \times (|x_i(t) - X^*| + |x_i(t) - X^b|) \end{aligned} \quad (12)$$

式(12)中: S 是常数; g 是维度为 $1 \times D$ 的随机向量。

2.3 时间卷积网络 TCN

时间卷积网络 TCN 网络包含膨胀因果卷积以及残差连接, 其结构如图 1 所示。由于因果卷积

是通过填充策略以当前时刻之前的时间步信息来获得未来时间步的输出, 从而确保数据输入和输出的维度具有一致性, 这种完全排除未来时间信息的方法契合负荷数据的因果特性, 能够有效防止信息泄露。因果卷积表示为式(13)所示:

$$y_t = \sum_{i=0}^{k-1} w_i \cdot x_{t-i} \quad (13)$$

式(13)中: y_t 为 t 时刻的输出; x_{t-i} 为 $t-i$ 时刻的值; w_i 为第 i 个卷积核的权重; k 表示卷积核的长度。




图 1 TCN 网络结构

为了捕获长期依赖关系, 扩大感受野, 膨胀卷积在因果卷积的基础上引入膨胀因子 d , 使感受野在每层呈现指数级扩张, 从而建模负荷数据中的长期依赖关系。其计算如式(14)所示:

$$y_t = \sum_{i=0}^{k-1} w_i \cdot x_{t-d \cdot i} \quad (14)$$

由于上述过程在深层网络会出现梯度消失及性能退化, 利用简单的残差结构可以有效缓解梯度消失问题, 提高训练的稳定性, 增强网络的表达能力^[24]。因此, TCN 可以最终表示为式(15)所示:

$$y_t = \sum_{i=0}^{k-1} w_i \cdot x_{t-d-i} + W_r \cdot x_t \quad (15)$$

式 (15) 中: w_r 表示残差连接的权重。

2.4 回声状态网络 ESN

回声状态网络 ESN 是一种基于储备池计算框架的递归神经网络 RNN, 它不需要训练 RNNs 的循环权重, 只随机生成一个“储备池”, 使其能够自然产生复杂的动态回声。ESN 的设计有效解决了传统 RNNs 难训练、收敛速度慢的难题, 在各种领域有着较好的前景。其结构如图 2 所示。




图 2 ESN 网络结构

ESN 在输入层、储备池和输出层分别有 K 、 N 、 L 个节点, 其储备池和输出层的状态可以表示为:

$$x(t+1) = (1-\delta)x(t) + \delta\tau[W_{in}u(t+1) + Wx(t) + W_{back}y(t)] \quad (16)$$

$$y(t+1) = \sigma[W_{out}(u(t+1), x(t+1), y(t))] \quad (17)$$

式 (16)、(17) 中: δ 为泄露率, 可以控制储备池的更新速度; τ 、 σ 为激活函数, 如 sigmoid 等; W_{in} 、 W 、 W_{back} 、 W_{out} 分别是 ESN 的输入矩阵、储备池矩阵、输出反馈矩阵和输出矩阵, 其中只有输出矩阵 W_{out} 由训练生成, 其余均为随机生成并保持不变。因此, 只需求解输出矩阵 W_{out} 即可, 利用融合正则化的岭回归方法求解, 如式(18)、(19)所示:

$$Y^{target} = W_{out}X \quad (18)$$

$$W_{out} = Y^{target}W^T(XX^T + \beta I)^{-1} \quad (19)$$

式 (18)、(19) 中: X 为储备池内部状态矩阵; β 为正则化系数; I 为单位矩阵; Y^{target} 为目标值。

综上, TCN 能够利用膨胀因果卷积提取多尺度时序特征, 能够有效捕获负荷序列中的局部变

化模式和中长期依赖关系。然而, 当负荷序列存在复杂动态演化特性时, 仅依靠卷积结构难以充分描述系统状态随时间的连续演化过程。因此, 本文将 TCN 作为时序特征提取器, 对原始负荷序列进行高层特征编码, 再结合 ESN 进一步在更加平稳和紧凑的特征空间中完成动态建模。这种组合充分发挥了 TCN 特征提取能力和 ESN 动态记忆能力的互补优势。

3 多策略改进的 DBO 算法

在原始的 DBO 算法中, 种群初始化是通过随机化进行的, 这无法保证种群分布的均匀性, 且很容易导致种群多样性下降。其次, 尽管 DBO 算法有一定优势, 但也存在其缺乏平衡全局探索与局部利用的能力^[25], 这容易导致算法陷入局部最优, 无法寻找全局最优解。因此, 为了进一步提升 DBO 算法的搜索性能, 更好地平衡其全局探索与局部开发能力, 本文提出了基于混沌映射、协同搜索策略和自适应 T 分布突变扰动策略的改进 DBO 算法 IDBO。首先, 采用混沌映射策略初始化种群, 使个体在种群中的分布更均匀。其次, 考虑到 DBO 算法中的滚球行为对种群具有全局引导作用, 采用协同搜索策略来改善蜣螂的滚球行为, 实现算法中全局探索与局部开发之间的良好平衡。最后, 采用自适应 T 分布突变策略扰动蜣螂的最优位置, 以增强算法跳出局部最优的能力。具体的改进策略如下所述。

3.1 Cubic 混沌映射

在优化复杂问题时, DBO 算法通过随机生成种群初始化种群, 这可能导致种群多样性下降, 并在后续迭代中倾向于陷入局部最优状态。混沌映射具有非线性、非周期性和随机性等特性。使用混沌初始化生成种群可以增加种群多样性, 改善算法收敛性, 并扩大探索范围。Cubic 映射属于混沌映射的一种, 可用于生成具有更好随机性和解空间的初始群体。因此, 本文引入了 Cubic 混沌映射作为增加 DBO 算法中初始种群多样性的策略。Cubic 混沌映射的表示如式(20)所示, 其中 γ 表示映射参数。

$$x_{n+1} = \gamma x_n (1 - x_n^2) \quad (20)$$

通过多次实验检验, 本文设置初始值 $x_0 = 0.3$ 和映射参数 $\gamma = 2.595$, 从而得到图 3 所示的混沌

值分布图。由图 3 可知,生成的混沌变量具有良好的普遍性,使最初的蜣螂种群能够在不同环境条件下展现良好的适应性和稳定性。




图 3 混沌值分布

3.2 协同搜索策略

DBO 算法中的滚球行为在蜣螂种群中起着主导作用,并对算法的搜索能力和收敛速度有显著影响。然而,如公式(6)所示,蜣螂只在滚球行为中与上一代最严重的蜣螂互动,个体间缺乏信息交流。

为弥补这一不足,本文结合协同搜索策略中的团队沟通策略启发,用团队沟通策略替代原 DBO 算法中的位置更新策略,引导个体蜣螂与其他个体交流,促进种群信息传播,扩展搜索空间,提升性能。DBO 算法的全局搜索能力得到了增强。改进后的蜣螂在滚球时的位置更新如式(21)所示:

$$\begin{cases} x_{i,j}(t+1) = x_{i,j}(t) + A_{i,j}(t) + B_{i,j}(t) \\ \quad + C_{i,j}(t), i \in [1, I], j \in [1, J] \\ A_{i,j}(t) = \log(1/\phi(0,1)) \cdot (gBest_{ind,j}(t) - x_{i,j}(t)) \\ B_{i,j}(t) = \alpha \cdot \phi(0,1) \cdot \left[\frac{1}{M} \sum_{m=1}^M gBest_{m,j}(t) - x_{i,j}(t) \right] \\ C_{i,j}(t) = \beta \cdot \phi(0,1) \cdot \left[\frac{1}{I} \sum_{l=1}^I pBest_{i,l}(t) - x_{i,j}(t) \right] \end{cases} \quad (21)$$

式(21)中: $x_{i,j}(t+1)$ 是第 j 只蜣螂在第 i 个解决方案中 $t+1$ 迭代时的位置; $gBest_{i,j}(t)$ 是第 j 只蜣螂在第 t 个体群中的位置; $gBest_{ind,j}(t)$ 是从开始到第 t 次迭代中第 n 只蜣螂在第 m 个全局最优虫群中的位置; α 和 β 分别表示调整 $B_{i,j}(t)$ 和 $C_{i,j}(t)$ 的系数; A 、 B 、 C 分别为全局最优解、平均全局最优解和平均个体最优解。

3.3 自适应 T 分布突变策略

在迭代的后期阶段, DBO 算法会迅速收敛到最优位置附近。然而,如果当前的最优解不是全局最优解,而蜣螂群体专注于在当前位置附近搜索,就会陷入局部最优解^[26]。为解决上述问题,在算法中引入突变扰动策略可以增强算法跳出局部最优状态的能力,扩展搜索范围,最终找到全局最优解。

因此,引入突变算子可以保持种群多样性,同时避免种群在局部最优位置被聚合。本文引入自适应 T 分布突变扰动,以改进算法的搜索策略。同时,为了减少算法复杂度,本文只对最优的蜣螂个体应用突变扰动,并选择位置更优的蜣螂进入下一次迭代,此方法有效增加了蜣螂的多样性并提升了算法的搜索性能。改进的位置更新如式(22)所示:

$$x_{new_i}^t = x_{best_i} + t(iter) \times x_{best_i} \quad (22)$$

式(22)中: x_{best_i} 是蜣螂个体 i 在第 t 次迭代中的最佳位置; $x_{new_i}^t$ 指示经历适应性 T 分布变化的个体蜣螂的位置; $t(iter)$ 表示自由度参数为 $iter$ 的 T 分布算子。

4 基于 IDBO 的参数优化

VMD 算法需要预设模态成分的数量 M 和惩罚因子 α , 这两个参数在最终分解效果中起决定性作用^[27,28]。如果参数 M 未被正确选择,容易导致信号分解出现问题;如果参数 α 未正确选择,将影响模态组件,使其不处于适当的带宽位置。因此,如果参数 M 和 α 设置不当,会影响负荷特征的提取和处理。

此外, ESN 的性能受储备池规模 N 、正则化系数 β 和泄露率 δ 的影响较大。储备池规模越大,预测精度越高,相应的计算量也会更大,容易造成过拟合;正则化系数的作用是抑制模型的过拟合;泄露率代表了储备池内部状态的更新速率,其值在 0 到 1 之间。经过 ESN 模型后可以获得负荷数据的时间序列特征,然后通过一个全连接层输出最终的预测结果。

目前,大多数参数选择方法依赖于以往经验或文献中的数值参考,但人为设置参数常常存在随机性和偶然性等问题。而且,参数值的大小对模型性能有显著影响,不合适的值可能导致网络性能不佳。因此,本文选择 IDBO 算法,以全局自适应优化 VMD 算法的参数 M 和 α 以及 ESN 算法的参数 N 、 β 和 δ , 以确定最优参数组合,并

实现负荷信号的最佳预测。基于 IDBO 的优化流程如图 4 所示。




图 4 基于 IDBO 的优化流程图

5 负荷预测流程

本文提出的 IDBO 算法通过各种策略改进,具有良好的优化性能和收敛速度,并且解决了容易陷入局部最优的问题,避免了手动选择参数而耗费大量人力和时间的问题。此外,本文提出的 TCN-ESN 能够有效捕获时序数据的长期依赖特征并缓解了传统 RNNs 难训练、收敛速度慢的难题。本文提出的负荷预测方法整体实施步骤如下:

(1) 收集数据并预处理:采集负荷数据和气象数据,对数据进行清洗和归一化操作。

(2) 信号分解:利用 IDBO 算法搜索 VMD 的参数组合,然后用优化后的 VMD 算法分解负荷信号为多个 IMF 分量。

(3) 特征提取:利用 TCN 算法提取负荷信号中存在的长期特征和潜在规律。

(4) 模型训练:将提取的特征分为训练集和测试集,并使用 IDBO 算法优化 VMD、ESN 中的核心参数。同时,使用最佳参数训练模型。

(5) 模型测试:将测试集样本输入训练好的 VMD-TCN-ESN 模型,输出负荷预测结果,从而验证模型的有效性。

IDBO-VMD-TCN-ESN 整体流程图如图 5 所示。




图 5 IDBO-VMD-TCN-ESN 模型流程图

6 实验数据与评估

6.1 实验数据与实验环境

本文使用的数据集为徐州市某城区 2022-2024 年的用电负荷,每间隔 15 分钟取一次数据,共约 105000 条记录。此外,数据集还包括温度、湿度、降雨量、风速、工作日、节假日等影响因素。将归一化后的数据按照 6:2:2 的比例划分训练集、验证集、测试集,数据集中包含的负荷数据和相关特征能够为模型训练和验证提供数据支持。


本文中所有实验同一台 Windows 计算机上进行,处理器类型为 Intel i5-12600KF 3.70 GHz, GPU 类型为 16 GB 存储的 NVIDIA GeForce RTX 4060Ti,开发框架为 Pytorch 2.4.0,开发环境为 Python 3.12。

6.2 特征筛选


电力负荷受多重因素耦合作用,但各因素影响程度存在显著差异。因此,在构建预测模型之前,需对各种因素进行筛选。本文综合 SHAP 分析中的特征相关性热图及特征重要性排序,制定如下筛选准则:(1)以 SHAP 平均绝对值低于 1 作为低影响因素;(2)与负荷数据的 Pearson 相关系数绝对值低于 0.2 因素作为弱关联特征。相关结果如图 6 所示。

从图 6(b)中的特征重要性分析可知,SHAP 值低于 1 的为湿度和降雨量,说明二者对模型的

输出结果影响较小。同时,在图 6(a)中的特征相关性分析中,湿度、降雨量与电负荷之间的相关性系数分别为-0.08 和 0.17,其绝对值低于 0.2,这也说明二者与负荷数据的关联程度较低。因此,综合上述指标,湿度与降雨量被剔除,其它因素对负荷预测的影响更显著,故保留并作为模型的输入特征。



(a) 特征相关性分析



(b) 特征重要性分析

图 6 SHAP 分析结果

6.3 模型参数设置

为优化 IDBO-VMD-TCN-ESN 模型的性能,所设置的关键参数如表 1 所示。

表 1 参数设置

参数名称	参数值
Epoch	200
Dropout	0.2
Optimizer	Adam
Learning rate	0.001
Activation function	ReLU
Kernel size	3
Dilations	2

6.4 数据归一化

数据归一化可以有效加快模型收敛速度,提高模型精度,减少梯度下降过程中的剧烈波动。由于模型中不仅包含负荷数据,还包含其它类型的数据。因此,为减少数据间差异造成的预测模型性能下降,在进行预测前,本文使用 min-max 标准化的方法进行归一化。如式(23)所示:

$$x_i^* = \frac{x_i - x_{\min}}{x_{\max} - x_{\min}} \quad (23)$$

式(23)中: x_i 为第 i 个原始数据; $x_{\max}$ 和 $x_{\min}$ 分别是相应数据类型的最大值和最小值; x_i^* 为 x_i 归一化的数值。在模型预测后,为得到正确的预测结果,需对预测结果进行反归一化操作。如式(24)所示:

$$y_i = y_i^* (x_{\max} - x_{\min}) + x_{\min} \quad (24)$$

式(24)中: y_i^* 和 y_i 分别为模型预测的归一化值与反归一化值。

6.5 评估指标

为验证 IDBO-VMD-TCN-ESN 模型在负荷预测任务上的有效性,本文采用均方根误差 R_{MSE} (root mean square error, RMSE)、平均绝对百分误差 M_{APE} (mean absolute percentage error, MAPE)、平均绝对误差 M_{AE} (mean absolute error, MAE)、均方误差 M_{SE} (mean Squared Error, MSE)和决定系数 R^2 (R-Squared)作为评价提出模型的指标。以 n 个数据点,预测值和真实值分别是 y_i' 和 y_i 为例,公式如下:

$$R_{\text{MSE}} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - y_i')^2} \quad (25)$$

$$M_{\text{APE}} = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - y_i'}{y_i} \right| \times 100\% \quad (26)$$

$$M_{\text{AE}} = \frac{1}{n} \sum_{i=1}^n |y_i - y_i'| \quad (27)$$

$$M_{\text{SE}} = \frac{1}{n} \sum_{i=1}^n y_i - y_i' \quad (28)$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - y_i')^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (29)$$

7 实验结果与分析

7.1 IDBO 算法收敛性实验

为测试本文提出的改进 DBO 算法的性能,将 IDBO 与 DBO 算法、灰狼优化算法 GWO^[29]、金豺优化算法 GJO^[30]进行比较。为保证实验的公平性和一般性,本文选择四种具有单一最优值的单峰测试函数 F_1 、 F_2 、 F_4 和 F_6 以及一种双峰测试函数 F_7 , 如表 2 所示。单峰测试函数的局部最优值等价于全局最优值,后者可用于测试算法在迭代过程中的收敛速度。双峰测试函数可用于测试算法是否能避免陷入局部最优。


表 2 测试函数

测试函数	定义域	理论最优值
$F_1 = \sum_{i=1}^n x_i^2$	$[-100, 100]^n$	0
$F_2 = \sum_{i=1}^n x_i + \prod_{i=1}^n x_i $	$[-10, 10]^n$	0
$F_4 = \max_{1 \leq i \leq n} \{ x_i \}$	$[-100, 100]^n$	0
$F_6 = \sum_{i=1}^n x_i + 0.5 ^2$	$[-100, 100]^n$	0
$F_7 = \sum_{i=1}^n ix_i^4 + \text{rand}[0,1]$	$[-1.28, 1.28]^n$	0


实验中,算法的迭代次数上限为 1000。为了减少算法随机性的影响并提高测试结果的说服力,每个需要测试的算法分别在五种标准测试函数上运行 30 次。为了直观比较四种算法的收敛精度和速度,计算了 30 个模拟结果的平均值,并绘制了不同算法的适应度迭代收敛曲线,如图 7 所示。

图 7(a)~(d)为单峰测试函数的结果,从图中可以看出,与其他算法相比,本文提出的 IDBO 算法在初始阶段收敛速度更快,表明引入的 Cubic 混沌映射策略提高了总体中初始解的多样性,提高了算法的全局探索性能,并且使算法不仅能在迭代早期阶段快速收敛。同时,随着迭代次数增加,性能也持续优化,直到找到全局最优解且无搜索停滞现象。


图 7(e)为双峰测试函数结果,可以看出收敛曲线具有多个拐点,表明本文对原始 DBO 算法嵌入的协同搜索策略和自适应 T 分布策略能够有效使算法跳出局部最优解。因此,提出的改进策略是有效的,与其他算法相比, IDBO 在快速收敛速度和最佳搜索准确度方面能够表现出更好的性能。




(a) F1 收敛曲线




(b) F2 收敛曲线



(c) F4 收敛曲线



(d) F6 收敛曲线



(e) F7 收敛曲线
图 7 IDBO 收敛性实验

7.2 历史负荷时间序列分解

VMD 分解受模态分解个数 M 和二次惩罚项 α 影响较大。其中, 模态分解个数 M 决定了信号频带的划分精度, M 过小易导致不同频率成分混叠, 过大则可能产生虚假分量或造成有效信息丢失。二次惩罚项 α 则主要控制各模态的带宽, α 过大易使模态带宽过窄, 导致信息缺失, 过小则模态带宽过宽, 易引起相邻模态的频率重叠。因此, 使用提出的改进 DBO 算法优化 VMD 的参数 M 和 α 。设置的搜索范围 M 为 $[2, 10]$, 惩罚项 α 的搜索范围设为 $[50, 2000]$, 蜣螂初始种群规模设为 10, 最大重复次数设为 20。

由于优化算法存在随机性, 每次迭代的结果可能存在一些差异。这是因为每次迭代都会重新初始化总体, 优化结果可能不完全一致。因此, 为了保持普遍性, 本文以五次实验的平均值作为结果。二次惩罚项 α 迭代曲线如图 8 所示, 在第 8 次迭代中收敛至最优, 为 1586。模态分解个数 M 迭代曲线如图 9 所示, 在第三次迭代中收敛至最优。




图 8 二次惩罚项迭代曲线




图 9 模态分解个数迭代曲线

在得到优化后的 VMD 参数 M 和 α , VMD 分解结果如图 10 所示。从图中可以看出, 经过优化后的 VMD 算法将原始负荷序列分解为了不同频率的 IMF 分量。其中, IMF1-IMF3 频率较低, 表明负荷的周期性变化趋势, 而 IMF4 和 IMF5 频率较高, 体现了负荷数据的随机性波动。




图 10 历史负荷序列和模态分解序列

7.3 对比实验

为了全面评估本文提出的 IDBO-VMD-TCN-ESN 模型在时序负荷数据预测

任务中的性能表现, 本文与经典的负荷预测模型进行了对比实验, 从多个角度验证其在处理复杂、多尺度时序特征方面的有效性。本文选取了五种常用的评价指标, 包括均方误差 M_{SE} 、平均绝对误差 M_{AE} 、均方根误差 R_{MSE} 、平均绝对百分比误差 M_{APE} 以及决定系数 R^2 , 对所提出模型与其他基准模型的预测精度进行了实验对比。

表 3 给出了本文提出的 IDBO-VMD-TCN-ESN 模型与其它对比模型的误差结果。从表中可以看出, 本文提出的 IDBO-VMD-TCN-ESN 模型在 M_{SE} 、 M_{AE} 、 R_{MSE} 、 M_{APE} 和 R^2 指标上的误差均低于其它基线模型, 这表明 IDBO-VMD-TCN-ESN 模型能够有效捕捉负荷序列数据的特征与数据间的长期依赖关系。

表 3 不同模型性能对比

模型	M_{SE}	M_{AE}	R_{MSE}	M_{APE}	R^2
CNN-LSTM ^[31]	975.4	117.6	117.9	0.86	0.92
EMD-LSTM ^[32]	719.8	69.4	86.2	0.76	0.94
GWO-TCN-GRU ^[33]	625.5	60.2	80.3	0.51	0.95
EEMD-AFS-E	672.6	64.8	82.7	0.57	0.97
SN ^[34]					
OURS	562.7	54.5	66.4	0.42	0.99

图 11 展示了 IDBO-VMD-TCN-ESN 模型与其它对比模型在均方误差 M_{SE} 指标上的实验结果。从图中可以看出, IDBO-VMD-TCN-ESN 模型相较于无模态分解的 CNN-LSTM 模型在均方误差上提升了 42.31%, 相较于具有基础模态分解的 EMD-LSTM 和 EEMD-AFS-ESN 模型分别提升了 21.83% 和 16.34%。

这证明了本文所提模型通过自动确定超参数获得较好的性能表现。同时, 相较于 GWO-TCN-GRU 模型, IDBO-VMD-TCN-ESN 模型性能提升了 10.04%, 这是因为改进的 IDBO 模型通过混沌映射能够更好的确定超参数, 解决容易陷入局部最优的问题。因此, IDBO-VMD-TCN-ESN 模型能够较好地衡量预测值与真实值之间的平均平方偏差, 在负荷预测任务上具有较好的稳定性。

综上所述, IDBO-VMD-TCN-ESN 模型在所有指标上的性能均处于最优, 因为它不仅采用 IDBO 算法优化了 VMD 和 ESN 的超参数以提高预测精度, 而且利用多种策略实现了模型的全局优化性能, 使其能够更好地捕捉数据中的长期依赖关系, 使模型在负荷预测中处于最低预测误差和最高预测精度。




图 11 各模型的 M_{SE} 实验结果

7.4 消融实验

为验证本文提出的 IDBO-VMD-TCN-ESN 模型中 IDBO 和 TCN 的合理性, 设计了消融实验。图 12 为 IDBO-VMD-TCN-ESN 模型与 ESN、IDBO-VMD-ESN、VMD-TCN-ESN 模型的预测曲线对比图。表 4 为不同模型在不同指标下的结果对比。从图 12 和表 4 中可以得出结论, 本文提出的 IDBO-VMD-TCN-ESN 模型具有最好的预测精度, 而简单的 ESN 模型的预测性能最差。




图 12 预测曲线

表 4 消融实验结果对比

模型	M_{SE}	M_{AE}	R_{MSE}
ESN	1045.6	157.2	146.9
IDBO-VMD-ESN	622.3	63.1	76.8
VMD-TCN-ESN	867.5	89.4	113.8
OURS	562.7	54.5	66.4

尽管没有经过 IDBO 算法优化的 VMD-TCN-ESN 模型较 ESN 模型相比取得了大幅提升, 但是由于人工设定超参数造成模型性能没有处于最佳。而经过 IDBO 算法优化的 VMD-ESN 模型相较于 VMD-TCN-ESN 模型在 M_{SE} 指标上

提升了 30%左右,但因模型无法捕获负荷数据的长期依赖关系造成预测结果次优。而 IDBO-VMD-TCN-ESN 模型与次优性能的 IDBO-VMD-ESN 模型相比提升了 10%左右。因此,本文提出的 IDBO-VMD-TCN-ESN 模型在解决了人工设定超参数问题的基础上进一步通过 TCN 捕捉长期依赖关系,减少了人工设置模型超参数的时间和模型的预测偏差。

8 结论

随着智能电网建设的不断推进以及电力系统规模的持续扩大,准确的电力负荷预测已成为保障电网安全稳定运行、提高能源利用效率和优化电力资源配置的重要支撑。然而,传统负荷预测方法存在人工设定超参数成本高、容易陷入局部最优以及长期依赖关系捕捉不足的问题。因此,为了解决上述问题,从而提高短期负荷预测的性能,本文提出了 IDBO-VMD-TCN-ESN 模型。该模型的有效性通过与其它模型的对比试验得以验证。总结如下:

(1) 本文将混沌映射、协同搜索策略和自适应 T 分布突变扰动策略相融合,提出了改进的 DBO 算法 IDBO。实验表明, IDBO 算法相较于传统寻参模型具有更好的收敛性,且在跳出局部最优状态时表现良好。

(2) 提出了基于 IDBO 算法用于 VMD 和 TCN-ESN 的参数优化方法。 IDBO 算法用于自适应搜索最优参数,避免了手动参数设置带来的随机性和不确定性。

(3) 本文所述模型在真实数据集上经过实验验证,并通过实验测试证明该模型能够有效提取负荷序列特征,且具有较高的预测准确性。

参考文献

- [1] Chandrasekaran R, Paramasivan S K. Advances in deep learning techniques for short-term energy load forecasting applications: A review[J]. Archives of Computational Methods in Engineering, 2025, 32(2): 663-692.
- [2] Li N, Sun S P, Zhang L, et al. The evaluation method of the power supply capability of an active distribution network considering demand response[J]. Processes, 2024, 12(12): 2719.
- [3] Ahmad N, Ghadi Y, Adnan M, et al. Load forecasting techniques for power system: Research challenges and survey[J]. IEEE Access, 2022, 10: 71054-71090.
- [4] Zhang Y, Liu L, Yuan F, et al. Multifactor and multiscale method for power load forecasting[J]. Knowledge-Based Systems, 2023, 268: 110476.
- [5] Ouyang Z, Chen X, Li H, et al. Day-ahead electricity load forecasting based on multi-scale decomposition gated residual network[J]. Electrical Engineering, 2026, 108(5): 278.
- [6] Abumohsen M, Owda A Y, Owda M. Electrical load forecasting using LSTM, GRU, and RNN algorithms[J]. Energies, 2023, 16(5): 2283.
- [7] Alhashemi K, Altunöz Ö T. Electricity load forecasting models based on LSTM and GRU with their bidirectional recurrent neural networks[J]. Niğde Ömer Halisdemir Üniversitesi Mühendislik Bilimleri Dergisi, 2025, 14(4): 1372-1384.
- [8] Mounir N, Ouadi H, Jhrilifa I. Short-term electric load forecasting using an EMD-Bi-LSTM approach for smart grid energy management system[J]. Energy and Buildings, 2023, 288: 113022.
- [9] 陈仪,刘春元.基于聚类集合的 EMD-CNN-BiLSTM 自注意力机制短期电力负荷预测[J].软件工程,2025,28(3):1-5, 46.
- [10] Xiao Y, Zou C, Chi H, et al. Boosted GRU model for short-term forecasting of wind power with feature-weighted principal component analysis[J]. Energy, 2023, 267: 126503.
- [11] Kong W, Dong Z Y, Jia Y, et al. Short-term residential load forecasting based on LSTM recurrent neural network[J]. IEEE Transactions on Smart Grid, 2017, 10(1): 841-851.
- [12] Hua H, Liu M, Li Y, et al. An ensemble framework for short-term load forecasting based on parallel CNN and GRU with improved ResNet[J]. Electric Power Systems Research, 2023, 216: 109057.
- [13] Feng Y, Zhu J, Qiu P, et al. Short-term power load forecasting based on TCN-BiLSTM-attention and multi-feature fusion[J]. Arabian Journal for Science and Engineering, 2025, 50(8): 5475-5486.
- [14] Song K, Yu Y, Zhang T, et al. Short-term load forecasting based on CEEMDAN and dendritic deep learning[J]. Knowledge-Based Systems, 2024, 294: 111729.
- [15] Tsai W C, Tu C S, Hong C M, et al. A review of state-of-the-art and short-term forecasting models for solar PV power generation[J]. Energies, 2023, 16(14): 5436.
- [16] Liu H L, Li Z Y, Li C, et al. Research and application of short-term load forecasting based on CEEMDAN-LSTM modeling[J]. Energy Reports, 2024, 12: 2144-2155.
- [17] Wang Y Y, Sun S F, Chen X Q, et al. Short-term load forecasting of industrial customers based on SVMD and XGBoost[J]. International Journal of Electrical Power & Energy Systems, 2021, 129: 106830.
- [18] Ma K, Nie X, Yang J, et al. A power load forecasting method in port based on VMD-ICSS-hybrid neural network[J]. Applied Energy, 2025, 377: 124246.
- [19] Hu L, Shi W, Hu W, et al. Short-term prediction of mooring tension for floating offshore wind turbines under typhoon conditions based on the VMD-MI-LSTM method[J]. Renewable and Sustainable Energy Reviews, 2025, 216: 115606.
- [20] 农高海. 基于 VMD-BiLSTM 的短期电力负荷预测[J]. 电脑知识与

- 技术,2025,21(15):107-110.
- [21] Duan J, Wang P, Ma W, et al. A novel hybrid model based on nonlinear weighted combination for short-term wind power forecasting[J]. International Journal of Electrical Power & Energy Systems, 2022, 134: 107452.
- [22] Tan S, Wang A, Shi H, et al. Rolling bearing incipient fault detection via optimized VMD using mode mutual information[J]. International Journal of Control, Automation and Systems, 2022, 20(4): 1305-1315.
- [23] Ning Z, Chen G, Wang J, et al. Multi-scale decomposition and hybrid deep learning CEEMDAN-VMD-CNN-BiLSTM approach for wind power forecasting[J]. Processes, 2025, 13(7): 2046.
- [24] Wei Z, Zhipan D, Rong D, et al. Operational functional-zone proxies as learnable context for TCN-based indoor temperature forecasting[J]. Buildings, 2026, 16(15): 2966.
- [25] Tang B, Zhu R, Wang M, et al. Research on electric vehicle charging load forecasting based on IDBO-SVM[J]. Journal of Electrical Engineering & Technology, 2026, 21(1): 263-279.
- [26] 沙云东,赵宇,栾孝驰,等.基于多参数信息融合筛选的滚动轴承振动信号特征提取与表征方法[J].推进技术,2023,44(7):243-253.
- [27] Wang J, Han L, Zhang X, et al. Electrical load forecasting based on variable T-distribution and dual attention mechanism[J]. Energy, 2023, 283: 128569.
- [28] Liu W, Bai Y, Yue X, et al. A wind speed forecasting model based on rime optimization based VMD and multi-headed self-attention-LSTM [J]. Energy, 2024, 294: 130726.
- [29] Deng X, Wang Y, Meng Q. A CNN-BiLSTM bearing fault diagnosis model based on an improved grey wolf optimization algorithm[J]. Engineering Letters, 2026, 34(5): 1874.
- [30] 陈静,李政委,杨凯,等.基于 IGJO-TCN-BiGRU-SA 的水质预测模型 [J].电子测量与仪器学报,2026, 40(4): 23-39.
- [31] Wan A, Chang Q, Khalil A L B, et al. Short-term power load forecasting for combined heat and power using CNN-LSTM enhanced by attention mechanism[J]. Energy, 2023, 282: 128274.
- [32] 王荣茂,谢宁,于海洋,等.基于 EMD-LSTM 模型的台区负荷短期预测方法[J].实验室研究与探索, 2022,41(1):62-66,79.
- [33] Hu Y, Pan L, Yang X, et al. Short-term power load dynamic scheduling based on GWO-TCN-GRU optimization algorithm[J]. IEEE Access, 2024, 12: 144919-144931.
- [34] Shi J, Teh J. Load forecasting for regional integrated energy system based on complementary ensemble empirical mode decomposition and multi-model fusion[J]. Applied Energy, 2024, 353: 122146.