

# 基于低秩重构表示的动态回归迁移模型

霍海丹, 阎高伟<sup>†</sup>, 程 兰, 任密峰, 肖舒怡

(太原理工大学 电气与动力工程学院, 太原 030024)

**摘 要:** 针对实际流程工业过程存在动态时变和概念漂移特性, 导致软测量模型预测精度下降的问题, 提出基于低秩重构表示的动态迁移回归模型. 为了更好地描述动态过程, 在动态内模型偏最小二乘框架下, 将高维过程数据映射到低维潜变量空间中, 以捕获质量变量与潜变量之间的动态相关性. 为了减小概念漂移, 在获得动态相关性的同时, 通过增强不同工况质量变量估计值之间的相关性实现数据的条件分布对齐. 在 3 个公开工业数据集上的实验结果表明: 所提出模型的预测精度与静态基模型和动态基模型相比均有所提升, 可以有效地提高模型的预测精度和泛化能力.

**关键词:** 软测量; 动态时变; 概念漂移; 动态内模型偏最小二乘; 条件分布对齐; 低秩重构

中图分类号: TP273

文献标志码: A

DOI: 10.13195/j.kzyjc.2023.0133

引用格式: 霍海丹, 阎高伟, 程兰, 等. 基于低秩重构表示的动态迁移回归模型[J]. 控制与决策, 2024, 39(8): 2511-2520.

## Dynamic transfer regression model based on low-rank reconstruction representation

HUO Hai-dan, YAN Gao-wei<sup>†</sup>, CHENG Lan, REN Mi-feng, XIAO Shu-yi

(College of Electrical and Power Engineering, Taiyuan University of Technology, Taiyuan 030024, China)

**Abstract:** Aiming at the problem of the actual process industry process with dynamic time-varying and concept drift characteristics, which leads to a decrease in the prediction accuracy of the soft sensor model, a dynamic regression migration model based on low-rank reconstruction representation is proposed. In order to better describe the dynamic process, under the dynamic internal model partial least squares framework, the high-dimensional process data is mapped to the low-dimensional latent variable space to capture the dynamic correlation between quality data and latent variables. In order to reduce concept drift, while obtaining dynamic correlation, the conditional distribution alignment of data is achieved by enhancing the correlation between the estimated values of quality variables in different working conditions. Compared with the static base model and the dynamic base model, the experimental results on the three public industrial datasets improved, indicating that the proposed method can effectively improve the prediction accuracy and generalization ability of the model.

**Keywords:** soft sensor; dynamic time variation; concept drift; dynamic-inner partial least squares; conditional distribution alignment; low-rank reconstruction

## 0 引 言

许多重要质量变量的准确实时测量是流程工业过程的巨大挑战. 基于数据驱动的软测量技术利用过程变量建立对关键质量变量的预测模型, 已被广泛应用于具有大规模复杂化的工业系统中. 流程工业采集的数据具有强非线性、高维共线性、动态时序性等复杂特性, 如何从数据中挖掘真实和有价值信

息是数据驱动软测量建模的难点<sup>[1-2]</sup>.

目前, 基于回归分析、人工智能和统计学理论的模型是比较常见的数据驱动软测量方法. 然而, 像主成分分析(principal component analysis, PCA)、偏最小二乘回归(partial least squares regression, PLSR)、潜变量回归(latent variables regression, LVR)<sup>[3-5]</sup>等方法均属于静态模型, 其假设数据样本的采集独立于传

收稿日期: 2023-02-07; 录用日期: 2023-07-04.

基金项目: 国家自然科学基金面上项目(61973226, 62073232, 62003233); 山西省自然科学基金项目(201901D211083, 20210302123189); 格盟集团科技创新基金项目(2022-05).

责任编辑: 牛玉刚.

<sup>†</sup>通讯作者. E-mail: yangaowei@tyut.edu.cn.

\*本文附带电子附录文件, 可登录本刊官网该文“资源附件”区自行下载阅览.

感器,不存在序列相关性.但是,大多数实际工业过程在时间上是连续的,数据样本中包含动态信息,具有动态时变性.同时,由于生产设备老化或生产环境变化等原因,使得不同工况的数据分布会随时间发生变化,导致基于旧工况样本建立的模型不能适用于新的工况,即存在概念漂移现象<sup>[6]</sup>.

为适应工业过程数据的动态特性,典型的策略是通过时滞输入(输出)扩充输入(输出)矩阵,对扩充后的数据执行PCA或PLS,即动态PCA(dynamic PCA, DPCA)模型<sup>[7]</sup>和动态PLS(dynamic PLS, DPLS)模型<sup>[8]</sup>,但是它们无法解释提取的潜在变量,并且增广后的模型易造成维度灾难,增加了计算的复杂度.动态内部主成分分析(dynamic inner PCA, DiPCA)模型<sup>[9]</sup>,通过最大化自协方差刻画潜变量之间的动态关系,减小了维度灾难,降低了计算成本.同时,为建立过程变量与质量变量之间的动态回归关系,文献<sup>[10]</sup>在潜变量空间中,通过最大化当前时刻质量变量和当前及过去时刻过程变量的线性组合的协方差,建立内外模型一致的显式表达,提出了动态内部偏最小二乘(dynamic inner PLS, DiPLS)模型.但是,上述模型只考虑了数据的动态特性,忽略了不同工况数据之间存在分布差异的问题.

近年来,基于域不变表示的域适应方法常用来解决因数据分布存在差异而导致模型预测性能下降的问题.根据目标域样本有无标签,域适应方法可以划分为无监督方法和半监督方法,本文重点考虑目标域中没有标签的情况.例如文献<sup>[11]</sup>提出了迁移成分分析(transfer component analysis, TCA)方法,将源域数据和目标域数据投影到高维空间后通过最小化最大均值差异(maximum mean discrepancy, MMD)<sup>[12]</sup>距离减少数据分布差异.关联对齐(correlation alignment, CORAL)<sup>[13]</sup>通过线性变换方法对齐源域和目标域数据的二阶统计量,提高无监督域适应预测效果.在此基础上,部分学者尝试利用域不变表示的域适应方法来解决软测量中出现的概念漂移问题,通过寻找历史工况和当前工况的域不变空间实现不同工况过程数据的分布对齐,然后利用对齐后的数据建立回归模型实现最终的预测<sup>[14-15]</sup>.但是,上述方法在求解域不变空间过程中未考虑标签的信息,易导致域不变空间缺乏对质量变量的解释性,破坏原始数据过程变量和质量变量之间的映射关系.

文献<sup>[16]</sup>提出了域不变迭代偏最小二乘(domain-invariant iterative partial least squares, DIPALS)模型,将CORAL中的二阶统计量作为PLSR

模型的正则化项,为利用域适应思想解决回归问题提供了框架.文献<sup>[17]</sup>提出了基于时间近邻拉普拉斯正则的域适应回归模型(domain adaptive regression based on time nearest neighbor Laplace regularity, TNN-LR-MR),在DIPALS基础上引入时间近邻拉普拉斯正则化项,保持数据局部结构关系的同时降低了训练时间.文献<sup>[18]</sup>利用源域数据的潜变量重构目标域的潜变量,将重构误差项最小嵌入在PLSR框架中,提出了基于迁移子空间学习的偏最小二乘回归(partial least squares regression based on transfer subspace learning, TSL-PLSR)软测量模型,提高了模型的预测精度.但是上述模型只考虑了潜变量之间的静态关系,不适用于具有动态特性的工业过程数据.文献<sup>[19]</sup>提出了一种新的动态迁移偏最小二乘法(dynamic transfer partial least squares, DTPLS),利用结构风险最小化思想实现系统的动态建模,同时引入分布对齐和结构保持正则化项实现数据分布对齐,在动态数据集上有较好的预测性能.因此,与回归分析的其他应用领域相比,在设计面向流程工业的数据驱动软测量模型时,需要重点考虑以下两个方面对模型预测性能的影响:1)数据样本之间的动态特性;2)工业过程中概念漂移问题导致的数据分布差异.

基于上述思想,本文提出基于低秩重构表示的动态迁移回归模型(dynamic transfer regression model based on low-rank reconstruction representation, LRR-DTR).该模型将历史工况和当前工况的原始高维数据投影在潜变量空间,在潜变量空间中建立历史工况中的当前及过去时刻过程变量和当前时刻质量变量的线性回归模型,以挖掘数据的动态信息,同时利用历史工况的质量变量估计值重构当前工况的质量变量估计值,使得两者的相关性最大,实现条件分布对齐,从而减少不同工况之间的数据分布差异,进而对重构系数实施低秩约束保留原始数据空间的多子空间结构.

## 1 相关理论

### 1.1 符号定义

在无监督域适应回归问题中,将历史工况视为源域 $\mathcal{D}_S = \{\mathbf{x}_i^s, \mathbf{y}_i^s\}_{i=1}^{n_s} = \langle P, l \rangle$ ,数据分布为 $P \in \mathbb{R}^m$ ,标签生成函数为 $l: \mathbb{R}^m \rightarrow \mathbb{R}$ ,过程变量为 $\mathbf{X}^s = [\mathbf{x}_1^s, \dots, \mathbf{x}_{n_s}^s]^T \in \mathbb{R}^{n_s \times m}$ ,质量变量为 $\mathbf{Y}^s = [\mathbf{y}_1^s, \dots, \mathbf{y}_{n_s}^s]^T \in \mathbb{R}^{n_s \times 1}$ .当前工况视为目标域 $\mathcal{D}_T = \{\mathbf{x}_j^t\}_{j=1}^{n_t} = \langle Q \rangle$ ,数据分布为 $Q \in \mathbb{R}^m$ ,过程变量为 $\mathbf{X}^t = [\mathbf{x}_1^t, \dots, \mathbf{x}_{n_t}^t]^T \in \mathbb{R}^{n_t \times m}$ .本文通过 $s$ 和 $t$ 来区分历史工况和当前工况数据集, $n_s$ 和 $n_t$ 为样本个数, $m$ 为特征维

度.  $\text{tr}(\cdot)$  表示矩阵的迹,  $\text{rank}(\cdot)$  表示矩阵的秩.  $\|M\|_F$  表示F范数,  $\|M\|_* = \sum_i \delta_i(M)$  表示矩阵  $M$  的核范数, 其中  $\delta_i(M)$  表示矩阵  $M$  的第  $i$  个奇异值.

1.2 静态偏最小二乘模型

PLSR模型由静态外模型和内模型组成,用于处理数据中的共线性问题,并被广泛应用于软测量领域. 定义质量变量和过程变量分别为  $Y \in \mathbb{R}^{n \times p}$  和  $X \in \mathbb{R}^{n \times m}$ . 其中:  $n$  为样本个数,  $p$  为质量变量个数,  $m$  为过程变量个数. 将  $Y$  和  $X$  投影到潜变量空间中,通过最大化潜变量之间的协方差来建立外模型,目标函数为

$$\begin{aligned} \max_{q,w} & q^T Y^T X w; \\ \text{s.t.} & \|w\| = 1, \|q\| = 1. \end{aligned} \tag{1}$$

其中:  $q$  和  $w$  分别为  $Y$  和  $X$  的投影向量,  $u = Yq$  和  $t = Xw$  分别为  $Y$  和  $X$  的潜变量.

通过建立潜变量  $u$  和  $t$  的线性回归关系来确定内模型,目标函数为

$$u = bt + r. \tag{2}$$

通过下式去除提取潜变量的影响,同时利用残差获得剩余的潜变量,直至提取足够的潜在变量:

$$\begin{aligned} X &:= X - tp^T = X - \frac{X^T t}{t^T t}, \\ Y &:= Y - btq^T. \end{aligned} \tag{3}$$

最终,PLSR模型将  $Y$  和  $X$  分解为

$$X = TP^T + E, Y = TBQ^T + F. \tag{4}$$

其中:  $E$  和  $F$  分别为  $X$  和  $Y$  的残差,  $P = [p_1, p_2, \dots, p_L] \in \mathbb{R}^{m \times L}$ ,  $T = [t_1, t_2, \dots, t_L] \in \mathbb{R}^{n \times L}$ ,  $Q = [q_1, q_2, \dots, q_L] \in \mathbb{R}^{p \times L}$ ,  $B = \text{diag}[b_1, b_2, \dots, b_L]$ .

1.3 动态内模型偏最小二乘模型

显然,上述PLSR模型只有在静态过程中具有良好的性能,但是大多数工业过程是动态的. 针对动态

数据,文献[10]提出了内外一致的动态内模型偏最小二乘. 定义  $x_k$  和  $y_k$  分别为  $k$  时刻的过程变量和质量变量,通过建立潜在变量  $t_k$  和  $u_k$  之间的动态关系获得内模型,动态关系由下所示:

$$u_k = \beta_0 t_k + \beta_1 t_{k-1} + \dots + \beta_c t_{k-c}. \tag{5}$$

其中:  $u_k = y_k^T q$ ,  $t_k = x_k^T w$ ,  $c$  是时滞系数.

由下式获得  $k$  时刻质量变量的潜变量的估计值  $\hat{u}_k$ ,即所有时滞时刻下质量变量的潜变量的估计值:

$$\hat{u}_k = \beta_0 t_k + \beta_1 t_{k-1} + \dots + \beta_c t_{k-c}, \tag{6}$$

表示成矩阵的形式为  $\hat{U}_d = Z_d(\beta \otimes w)$ .

通过最大化内模型估计值  $\hat{u}_k$  和外模型  $u_k$  的协方差,获得DiPLS的外模型

$$\begin{aligned} \max & \sum_{k=c}^{c+N} u_k^T \hat{u}_k = \\ & \sum_{k=c}^{c+N} u_k^T [x_{k+c}, x_{k+c-1}, \dots, x_k](\beta \otimes w) = \\ & U_d^T Z_d(\beta \otimes w) = q^T Y_d^T Z_d(\beta \otimes w); \\ \text{s.t.} & \|w\| = 1, \|q\| = 1, \|\beta\| = 1. \end{aligned} \tag{7}$$

数据被重新定义为  $Z_d \in \mathbb{R}^{N \times (c+1)m}$ ,  $Y_d \in \mathbb{R}^{N \times p}$ . 其中:  $\otimes$  是克罗内克积;  $n = c + N$ ;  $Y_d = [y_c, y_{c+1}, \dots, y_{c+N}]^T$ ;  $Z_d = [X_c, X_{c-1}, \dots, X_0]^T$ ,  $X_i = [x_i, x_{i+1}, \dots, x_{i+N}]^T$ ,  $i = 0, 1, \dots, c$ ;  $\beta = [\beta_0, \beta_1, \dots, \beta_c]^T$ .  $\beta$ 、 $w$  和  $q$  三个模型参数的求解可采用拉格朗日乘法,具体步骤参见文献[10].

2 低秩重构动态迁移回归模型

受DiPLS模型的启发,本文提出了基于低秩重构的动态回归迁移模型. 通过在潜变量空间中建立历史工况的当前及过去时刻过程变量和当前时刻质量变量的线性回归模型获得质量变量和过程变量之间的动态关系,用来适应工业过程的动态时变性,与静态模型相比具有较高的预测性能. 同时利用动态内模型对质量变量的估计,建立基于低秩重构的条件分




图1 基于低秩重构的动态迁移回归模型算法示意图

布对齐正则化项,以解决由于生产元件老化或生产环境变化等原因导致过程数据和质量数据呈现概念漂移现象,造成不同工况过程变量和质量变量之间的映射关系被破坏的问题.模型示意如图1所示.

## 2.1 外模型

### 2.1.1 低秩重构条件分布对齐

针对工况差异对软测量回归模型预测精度的影响,引入域适应正则化项.将历史工况的数据和当前工况的数据投影在公共的潜变量空间中,利用DiPLS的动态内模型式(6),实现历史工况质量变量的动态估计,即 $\hat{U}_d^s = Z_d^s(\beta \otimes w)$ ,以及当前工况质量变量的动态估计,即 $\hat{U}_d^t = Z_d^t(\beta \otimes w)$ .进而将当前工况的质量变量的估计值利用历史工况的质量变量的估计值重构,使得当前工况的估计值和重构值相关性最大,从而减小两个工况的条件分布差异.由于在工业过程中,严格意义上服从同一分布的样本并不存在,同一工况的数据也会因设备损耗、催化剂失活等发生缓慢的概念漂移,导致同一工况的数据也具有分布差异,使得历史工况和当前工况数据之间往往跨越多个子空间.因此对重构矩阵施加低秩约束,可以使重构矩阵具有块状结构,使当前工况下的质量变量可以由不同子空间下的历史工况中的质量变量进行线性重构,有助于挖掘数据的多子空间结构.最终建立如下目标函数:

$$\max \text{cov}(Z\hat{U}_d^s, \hat{U}_d^t) - \text{rank}(Z). \quad (8)$$

其中: $\hat{U}_d^s$ 为历史工况质量变量的估计值, $\hat{U}_d^t$ 为当前工况质量变量的估计值; $Z_d^s$ 和 $Z_d^t$ 分别为历史工况和当前工况的过程变量增广后的数据, $Z$ 为重构系数矩阵.由于秩函数的非凸性,式(8)不易直接优化获得有效解.因此,通过松弛问题,用核范数代替求解低秩约束<sup>[20]</sup>.最终式(8)重新定义为

$$\begin{aligned} \max & (\hat{U}_d^s)^T Z^T (\hat{U}_d^t) - \|Z\|_* = \\ & (\beta \otimes w)^T (Z_d^s)^T Z^T Z_d^t (\beta \otimes w) - \|Z\|_*. \end{aligned} \quad (9)$$

### 2.1.2 模型的建立与求解

为了降低工业过程的动态时变性和概念漂移问题对模型预测性能的影响.本文将低秩重构条件分布对齐作为DiPLS模型的正则化项,构造LRR-DTR外模型.将式(7)和(9)结合建立目标函数,由于本文研究对象是多输入单输出系统,质量变量的潜变量是其本身,即 $U_d^s = Y_d^s$ , $\hat{U}_d^s = \hat{Y}_d^s$ , $\hat{U}_d^t = \hat{Y}_d^t$ .因此,目标函数简化为

$$\begin{aligned} \max_{\beta, w, Z} & (Y_d^s)^T Z_d^s (\beta \otimes w) + \\ & \gamma (\beta \otimes w)^T (Z_d^s)^T Z^T Z_d^t (\beta \otimes w) - \eta \|Z\|_*; \\ \text{s.t.} & \|w\| = 1, \|\beta\| = 1. \end{aligned} \quad (10)$$

但是,利用拉格朗日乘子法求解式(10)时,会引入两个拉格朗日乘子,拉格朗日乘子不能通过闭式解获得.因此,将式(10)转化为

$$\begin{aligned} \max_{\beta, Z} & (\beta \otimes w)^T (Z_d^s)^T Y_d^s (Y_d^s)^T Z_d^s (\beta \otimes w) + \\ & \gamma (\beta \otimes w)^T (Z_d^s)^T Z^T Z_d^t (\beta \otimes w) - \eta \|Z\|_*; \\ \text{s.t.} & \|w\| = 1, \|\beta\| = 1. \end{aligned} \quad (11)$$

该模型涉及3个变量 $Z$ 、 $\beta$ 和 $w$ 的求解.由于目标函数是非凸优化问题,采用非精确增广拉格朗日乘子方法(IALM)<sup>[20]</sup>求解该模型.为了使得目标函数可分离求解,引入辅助变量 $J$ 将问题等价

$$\begin{aligned} \max_{\beta, Z, J} & (\beta \otimes w)^T (Z_d^s)^T Y_d^s (Y_d^s)^T Z_d^s (\beta \otimes w) + \\ & \gamma (\beta \otimes w)^T (Z_d^s)^T Z^T Z_d^t (\beta \otimes w) - \eta \|J\|_*; \\ \text{s.t.} & \|w\| = 1, \|\beta\| = 1, Z = J. \end{aligned} \quad (12)$$

拉格朗日乘子方法常用来解决核正则化问题,因此有

$$\begin{aligned} L = & (\beta \otimes w)^T \Lambda (\beta \otimes w) - \eta \|J\|_* - \lambda_1 (w^T w - 1) - \\ & \lambda_2 (\beta^T \beta - 1) - \frac{\mu}{2} \|Z - J + \frac{\psi}{\mu}\|_F^2. \end{aligned} \quad (13)$$

其中

$$\Lambda = (Z_d^s)^T Y_d^s (Y_d^s)^T Z_d^s + \gamma (Z_d^s)^T Z^T Z_d^t,$$

$\gamma$ 、 $\eta$ 、 $\lambda_1$ 、 $\lambda_2$ 、 $\mu$ 为惩罚系数, $\psi$ 为拉格朗日乘子.利用交替乘子法对外模型进行求解.

1) 更新 $w$ :

$$\frac{\partial L}{\partial w} = 0 \Rightarrow (\beta \otimes I_m)^T \Lambda (\beta \otimes I_m) w = \lambda_1 w, \quad (14)$$

即 $w$ 的解为 $(\beta \otimes I_m)^T \Lambda (\beta \otimes I_m)$ 最大特征值对应的特征向量.

2) 更新 $\beta$ :

$$\frac{\partial L}{\partial \beta} = 0 \Rightarrow (I_{c+1} \otimes w)^T \Lambda (I_{c+1} \otimes w) \beta = \lambda_2 \beta, \quad (15)$$

即 $\beta$ 的解为 $(I_{c+1} \otimes w)^T \Lambda (I_{c+1} \otimes w)$ 最大特征值对应的特征向量.

3) 更新 $Z$ :

$$\begin{aligned} \frac{\partial L}{\partial Z} = 0 \Rightarrow \\ Z = \frac{\gamma}{\mu} Z_d^s (\beta \otimes w) (\beta \otimes w)^T (Z_d^s)^T + J - \frac{\psi}{\mu}. \end{aligned} \quad (16)$$

4) 更新  $J$ :

$$\frac{\partial L}{\partial J} = 0 \Rightarrow J = \vartheta_{1/\mu} \left( Z + \frac{\psi}{\mu} \right). \quad (17)$$

其中:  $\vartheta_{\lambda}(X) = US_{\lambda}(\Sigma)V^T$  是关于奇异值  $\lambda$  的阈值算子,  $S_{\lambda}(\Sigma_{ij}) = \text{sign}(\Sigma_{ij}) \max(0, |\Sigma_{ij} - \lambda|)$  是软阈值算子,  $X = U\Sigma V^T$  是  $X$  的奇异值分解.

5) 更新  $\psi, \mu$ :

$$\begin{cases} \psi = \psi + \mu(Z - J), \\ \mu = \min(\rho\mu, \mu_{\max}). \end{cases} \quad (18)$$

重复 1)~5) 直至收敛, 获得最终的外模型投影向量  $w$ .

## 2.2 内模型

构建 LRR-DTR 算法的内模型依然使用 DiPLS 内模型的思想: 假设当前  $k$  时刻下质量数据的潜变量由当前及过去  $c$  时刻下过程数据的潜变量线性回归而成, 借此挖掘数据的动态信息. 利用式(6)建立历史工况和当前工况数据的内模型, 分别为

$$y_k^s = \beta_0 t_k^s + \beta_1 t_{k-1}^s + \dots + \beta_c t_{k-c}^s, \quad (19)$$

$$y_k^t = \beta_0 t_k^t + \beta_1 t_{k-1}^t + \dots + \beta_c t_{k-c}^t. \quad (20)$$

其中  $t_k^s$  和  $t_k^t$  分别为历史工况和当前工况第  $k$  时刻过程数据的潜变量, 由外模型优化的投影向量  $w$  获得, 表示为  $t_k^s = (x_k^s)^T w$  和  $t_k^t = (x_k^t)^T w$ . 由于当前工况的质量变量  $y_k^t$  是未知的, 本文只能获得历史工况的内模型. 利用普通最小二乘法可以获得回归参数  $\beta$  的解, 如下所示:

$$\beta = ((T^s)^T T^s)^{-1} (T^s)^T Y_d^s. \quad (21)$$

其中:  $T^s = [t_c^s, t_{c-1}^s, \dots, t_0^s]$ ,  $t_i^s = [t_i^s, t_{i+1}^s, \dots, t_{i+N}^s]$ .

由于在外模型中获得的潜变量满足条件分布对齐, 使得不同工况间潜变量空间的动态关系保持不变, 即享用相同的参数  $\beta$ . 通过  $\beta$  获得历史工况和当前工况的质量变量的估计值

$$\begin{aligned} \hat{Y}^s &= T^s \beta, \\ \hat{Y}^t &= T^t \beta, \end{aligned} \quad (22)$$

其中  $T^t = [t_c^t, t_{c-1}^t, \dots, t_0^t]$ .

## 2.3 模型缩并与预测

在获得  $t^s, t^t$  和  $\hat{Y}^s$  后, 通过下式去除原始数据中已经提取的潜变量信息, 同时利用残差获得剩余的潜变量, 直至提取足够的潜在变量:

$$\begin{aligned} X^s &:= X^s - t^s (p^s)^T, \\ X^t &:= X^t - t^t (p^t)^T, \end{aligned}$$

$$Y_d^s := Y_d^s - T^s \beta. \quad (23)$$

其中:  $p^s = (X^s)^T t^s / (t^s)^T t^s$ ,  $p^t = (X^t)^T t^t / (t^t)^T t^t$ .

提取完所有的潜在变量后, 获得最终的回归模型

$$\hat{y}_k = x_k^T R b_0 + x_{k-1}^T R b_1 + \dots + x_{k-c}^T R b_c. \quad (24)$$

其中:  $R = W((P^s)^T W)^{-1}$ ,  $W = [w_1, w_2, \dots, w_L]$ ,  $P^s = [p_1, p_2, \dots, p_L]$ ,  $b_i = [\beta_{i1}, \beta_{i2}, \dots, \beta_{iL}]^T$ . 整体算法流程如下所示.

**算法1** 基于低秩重构表示的动态迁移回归算法.

输入: 历史工况过程变量  $X^s$ , 历史工况质量变量  $Y^s$ , 当前工况过程变量  $X^t$ , 时滞常数  $c$ , 潜变量个数  $L$ , 惩罚系数  $\alpha, \eta, \mu$ ;

输出: 回归系数  $RB \in \mathbb{R}^m$ .

初始化: 去均值化  $X^s = X^s - E[X^s]$ ,  $X^t = X^t - E[X^t]$ ,  $Y^s = Y^s - E[Y^s]$ .

step 1: 对  $X^s$  和  $X^t$  进行扩展分别得到  $Z_d^s$  和  $Z_d^t$ , 对  $Y^s$  转化为  $Y_d^s$ .

step 2: 建立外部模型.

step 2.1: 初始化  $w, \beta$  为随机单位向量;

step 2.2: 根据式(14)~(18)计算  $w, \beta, Z, J, \psi$  和  $\mu$  直至收敛.

step 3: 建立内模型.

$$t^s = X^s w, \quad t^t = X^t w;$$

$$t_i = X_i w, \quad i = 0, 1, \dots, c;$$

$$T^s = [t_c^s, t_{c-1}^s, \dots, t_0^s], \quad T^t = [t_c^t, t_{c-1}^t, \dots, t_0^t];$$

$$\beta = ((T^s)^T T^s)^{-1} (T^s)^T Y_d^s.$$

step 4: 缩并.

$$p^s = (X^s)^T t^s / (t^s)^T t^s, \quad X^s := X^s - t^s (p^s)^T,$$

$$p^t = (X^t)^T t^t / (t^t)^T t^t, \quad X^t := X^t - t^t (p^t)^T,$$

$$Y_d^s := Y_d^s - T^s \beta.$$

step 5: 将计算结果添加到矩阵中.

$$P^s = [P^s, p^s], \quad W = [W, w], \quad B = [B, \beta].$$

step 6: 重复  $L$  次上述 step 1 ~ step 5.

## 2.4 算法复杂度

为了进一步说明本文算法的具体计算过程, 对该算法的时间复杂度进行分析. 本文算法复杂度主要包括对外模型参数和潜变量的迭代求解. 对外部模型参数的求解主要是对  $w, \beta$  和  $J$  矩阵的求解, 包括矩阵求逆和特征值分解、SVD 分解, 求解  $w$  的复杂度为  $\mathcal{O}(km^2(c+1)^2 N + m^3(c+2))$ , 求解  $\beta$  的



复杂度为 $\mathcal{O}(km^2(c+1)^2N+(c+1)^3(m+1))$ ,求解 $J$ 的复杂度为 $\mathcal{O}(N^3)$ . 最终本文算法总的复杂度为 $\mathcal{O}(T_1L(N^3+km^2(c+1)^2N+m^3+(c+1)^3))$ . 其中: $T_1$ 为外模型参数求解的最大迭代次数, $L$ 为潜变量的个数.

3 实验结果及分析

为验证本文方法的有效性,选择在3个公开工业过程数据集上进行验证,分别为田纳西-伊斯曼过程(Tennessee Eastman process, TEP)数据集、脱丁烷塔(debutanizer column, DC)数据集和硫磺回收装置(sulfur recovery unit, SRU)数据集. 将实验分为静态模型和动态模型两部分进行讨论. 以PLSR为静态基模型,选取TNN-LR-MR、TSL-PLSR和LRR-STR为静态模型的对比方法进行实验. 其中LRR-STR为本文方法所对应的静态模型,其目标函数如下所示:

$$\begin{aligned} \max_{\mathbf{w}, \mathbf{Z}} \quad & \mathbf{w}^T(\mathbf{X}^s)^T\mathbf{Y}^s(\mathbf{Y}^s)^T\mathbf{X}^s\mathbf{w}+ \\ & \gamma\mathbf{w}^T(\mathbf{X}^s)^T\mathbf{Z}^T\mathbf{X}^t\mathbf{w}-\eta\|\mathbf{Z}\|_*; \\ \text{s.t.} \quad & \|\mathbf{w}\|=1. \end{aligned} \tag{25}$$

以DiPLS为动态基模型,首先将利用TCA和CORAL进行数据分布对齐,再进行回归预测建模的方法记为TCA+DiPLS和CORAL+DiPLS,选取上述两种方法以及DTPLS模型和LRR-DTR模型作为动态模型的对比方法进行实验. 本文通过设置潜变量个数 $L$ 的搜索区间 $1 \leq L \leq m$ ,利用交叉验证的方法来使得模型精度最高的潜变量个数.

为了评价算法的预测性能,选择均方根误差(root mean square error, RMSE)、决定系数(coefficient of determination,  $R^2$ )和平均绝对误差(mean absolute error, MAE)作为评价指标,其计算公式如下:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}, \tag{26}$$

$$R^2 = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2}, \tag{27}$$

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |\hat{y}_i - y_i|. \tag{28}$$

其中: $n$ 为测试样本的数量, $y_i$ 为第 $i$ 个样本的真实值, $\hat{y}_i$ 为第 $i$ 个样本的估计值.

3.1 TEP数据集

TEP<sup>[21]</sup>是伊士曼化工公司设计的一种工艺过程仿真系统,为软测量领域的监测和控制提供了一个工业过程的现实模拟. 该过程包括12个操纵变量和41个测量变量. 测量变量包含22个每3 min采样一次的过程变量,以及19个带有停滞时间和时间延迟的质量变量. 本文实验中,选择22个过程变量XMEAS(1~22)和11个操纵变量XMV(1~11)作为输入,质量变量XMEAS(38)作为输出. 将训练集作为历史工况,测试集作为当前工况进行模型的验证.

实验结果如表1所示. 从表1可以看出,与静态基模型PLSR相比,TNN-LR-MR模型、TSL-PLSR模型和LRR-STR模型将不同的域适应项作为正则化项,减少了历史工况与当前工况的分布差异,预测精度均有所改善. 另外,可以看出,动态模型的预测效果普遍优于静态模型. 与动态基模型DiPLS相比,TCA+DiPLS模型和CORAL+DiPLS模型预测性能下降,出现负迁移现象. DTPLS模型引入域适应项和结构保持项,预测精度有所提升,但是LRR-DTR模型的拟合程度最好.

表1 不同对比方法对TEP数据集的预测比较

| 评价指标  | 静态模型    |           |          |         | 动态模型    |           |             |         |                |
|-------|---------|-----------|----------|---------|---------|-----------|-------------|---------|----------------|
|       | PLSR    | TNN-LR-MR | TSL-PLSR | LRR-STR | DiPLS   | TCA+DiPLS | CORAL+DiPLS | DTPLS   | LRR-DTR        |
| RMSE  | 0.911 6 | 0.855 7   | 0.856 4  | 0.856 6 | 0.794 3 | 0.871 4   | 0.802 8     | 0.816 7 | <b>0.760 6</b> |
| $R^2$ | 0.440 7 | 0.507 7   | 0.506 9  | 0.498 9 | 0.575 4 | 0.488 4   | 0.565 7     | 0.545 2 | <b>0.611 2</b> |
| MAE   | 0.735 2 | 0.698 2   | 0.696 8  | 0.699 4 | 0.652 7 | 0.693 6   | 0.65 71     | 0.655 1 | <b>0.622 4</b> |

3.2 脱丁烷塔数据集

脱丁烷塔过程是石油脱硫及石脑油分离对象的一部分<sup>[22]</sup>,用于减少脱丁烷塔底部的丁烷浓度. 塔底丁烷浓度的测量存在较大的滞后,需要建立软测量模型实现预测. 本文选择该过程的7个辅助变量作为输入,塔底丁烷浓度作为输出,将该数据集2 349个样本

中的前1 200个样本作为历史工况,剩余样本作为当前工况进行模型验证.

实验结果如表2所示. 从表2可以看出,与静态基模型PLSR相比,所有对比模型的预测精度都有提高. 同时,动态模型的预测效果普遍比静态模型的预测效果好. 与动态基模型DiPLS相比,TCA+DiPLS、

表 2 不同对比方法对DC数据集的预测比较

| 评价指标  | 静态模型   |           |          |         | 动态模型   |             |               |        |               |
|-------|--------|-----------|----------|---------|--------|-------------|---------------|--------|---------------|
|       | PLSR   | TNN-LR-MR | TSL-PLSR | LRR-STR | DiPLS  | TCA + DiPLS | CORAL + DiPLS | DTPLS  | LRR-DTR       |
| RMSE  | 1.2762 | 1.2014    | 1.2567   | 1.1724  | 0.9042 | 0.8775      | 0.9021        | 0.8651 | <b>0.8537</b> |
| $R^2$ | 0.0910 | 0.0332    | -0.0579  | 0.0918  | 0.4524 | 0.4845      | 0.4538        | 0.5060 | <b>0.5108</b> |
| MAE   | 0.9649 | 0.9109    | 0.9314   | 0.9139  | 0.7236 | 0.6396      | 0.6334        | 0.6282 | <b>0.6208</b> |

CORAL + DiPLS、DTPLS与本文模型的预测精度均有所提升,其中本文所提出的LRR-DTR模型预测精度最高.

3.3 硫磺回收装置数据集

硫磺回收装置数据集<sup>[23]</sup>用于去除酸性气体中的有害物质,以两种酸性气体为输入,通过化学反应将硫化氢(hydrogen sulfide, H<sub>2</sub>S)转化为单质硫和二氧化硫(sulfur dioxide, SO<sub>2</sub>). 该数据集是检验软测量模型性能的标准数据集. 本文实验选择5个过程变量为输入, H<sub>2</sub>S和SO<sub>2</sub>的浓度为输出,将训练集的5 000个

样本作为历史工况,测试集的5 000个样本作为当前工况进行模型的验证.

对质量变量H<sub>2</sub>S的预测结果如表3所示,可以看出动态模型的预测精度普遍高于静态模型的预测精度. 与静态基模型PLSR相比, TNN-LR-MR出现了负迁移的现象,其他静态对比模型的预测精度有所改善,但是改善程度不大;与动态基模型DiPLS相比, TCA + DiPLS模型和CORAL + DiPLS模型预测性能下降,DTPLS模型和本文建立的LRR-DTR模型预测精度都有较大的提升,但是DTPLS模型的精度最高.

表 3 不同对比方法对SRU数据集H<sub>2</sub>S的预测比较

| 评价指标  | 静态模型   |           |          |         | 动态模型   |             |               |               |         |
|-------|--------|-----------|----------|---------|--------|-------------|---------------|---------------|---------|
|       | PLSR   | TNN-LR-MR | TSL-PLSR | LRR-STR | DiPLS  | TCA + DiPLS | CORAL + DiPLS | DTPLS         | LRR-DTR |
| RMSE  | 0.9228 | 0.9333    | 0.9082   | 0.9129  | 0.8472 | 0.9006      | 0.8806        | <b>0.5873</b> | 0.6463  |
| $R^2$ | 0.0084 | -0.0136   | 0.0384   | 0.0270  | 0.1649 | 0.0570      | 0.0983        | <b>0.5971</b> | 0.5171  |
| MAE   | 0.5241 | 0.5398    | 0.4763   | 0.4951  | 0.5453 | 0.5016      | 0.5170        | <b>0.3668</b> | 0.3825  |

对质量变量SO<sub>2</sub>的预测结果如表4所示. 与静态基模型PLSR相比,静态模型对比方法TNN-LR-MR模型、TSL-PLSR模型和LRR-STR模型引入域适应正则化项后模型的预测精度均有所改善. 与动态基模

型DiPLS相比: TCA + DiPLS模型和CORAL-DiPLS模型的预测结果出现恶化的情况;DTPLS模型和本文建立的LRR-DTR模型预测精度均有所提高,但是DTPLS模型的拟合程度最好.

表 4 不同对比方法对SRU数据集SO<sub>2</sub>的预测比较

| 评价指标  | 静态模型   |           |          |         | 动态模型   |             |               |               |         |
|-------|--------|-----------|----------|---------|--------|-------------|---------------|---------------|---------|
|       | PLSR   | TNN-LR-MR | TSL-PLSR | LRR-STR | DiPLS  | TCA + DiPLS | CORAL + DiPLS | DTPLS         | LRR-DTR |
| RMSE  | 0.8366 | 0.8322    | 0.8296   | 0.8308  | 0.7493 | 0.8119      | 0.7964        | <b>0.4174</b> | 0.4708  |
| $R^2$ | 0.0065 | 0.0178    | 0.0239   | 0.0127  | 0.2039 | 0.0661      | 0.1014        | <b>0.7514</b> | 0.6850  |
| MAE   | 0.6156 | 0.6122    | 0.6089   | 0.6166  | 0.5322 | 0.5818      | 0.5822        | <b>0.3135</b> | 0.3543  |

3.4 实验分析

3.4.1 实验结果分析

不同对比方法在3个数据集上的均方根误差如图2所示. 从图2可以看出,动态模型的预测误差普遍小于静态模型,进一步说明了在软测量建模中考虑过程动态时序性的必要性. 另外,与静态基模型PLSR相比, TNN-LR-MR、TSL-PLSR和LRR-STR等

静态对比方法在PLSR的基础上引入了域适应正则化项,模型性能有所提升. 与动态基模型DiPLS相比, TCA + DiPLS和CORAL + DiPLS在部分数据集中出现负迁移的情况,这是因为该类方法的数据分布对齐过程与回归建模过程是分阶段进行的,在数据对齐过程缺乏标签信息的指导,破坏了原始数据中质量变量与过程变量之间的映射关系以及动态结构. 而

DTPLS与本文所提LRR-DTR方法在DiPLS方法的基础上引入域适应正则化项,即在提取动态关系的同时考虑了不同工况之间的数据分布差异,较DiPLS方法的预测性能有了较大的提升.




图2 不同数据集下不同方法均方根误差对比

3.4.2 动态性表征

DTPLS模型和LRR-DTR模型通过建立当前时刻的质量变量与当前时刻过程变量及前 $c$ 时刻过程变量的线性回归模型来刻画数据的动态特性.以本文LRR-DTR模型为例,通过回归系数 $\beta$ 将数据的动态性显式地表征出来.图3为LRR-DTR模型在不同数据集上的第1个潜变量对应的回归系数 $\beta$ ,可以看出当前过程变量的回归系数最大,表明当前质量变量受当前过程变量的影响最大,同时前几个时刻的过程变量对应的回归系数随时间逐渐减小,说明数据具有动态特性,并且不同数据集的动态性强弱不同.




图3 不同数据集第1个潜变量回归系数 $\beta$

3.4.3 域适应正则项

本文模型引入低秩重构的条件分布对齐域适应正则化项是为了解决工业过程中的概念漂移问题,即减少工业过程数据中的分布差异.为说明该域适应正则化的有效性,以SRU数据集为例绘制DiPLS模型和LRR-DTR模型的历史工况和当前工况第1个 $H_2S$ 和 $SO_2$ 潜变量估计值的核密度分布图,如图4所示.从图4可以看出,LRR-DTR模型引入域适应正则化项,与DiPLS模型相比质量变量的分布差异小.




图4 SRU数据集质量变量估计值的核密度分布

为进一步说明LRR-DTR模型中构建基于低秩重构的条件分布域适应正则化项的出发点,选取同类型算法DTPLS进行对比说明. DTPLS模型和LRR-DTR模型相比,两者都是在挖掘数据动态特性的同时引入域适应正则化项来减小数据的分布差异.不同的是DTPLS模型对齐的是数据的边缘分布并引入了数据结构保持项.而本文建立的LRR-DTR模型对齐的是数据的条件分布差异,即域适应正则化项的构造不同.对比两个模型的实验结果,可以看出LRR-DTR模型在TE数据集和DC数据集上的预测精度高于DTPLS模型的结果,但是在SRU数据集上,DTPLS模型的结果更佳.这是由于本文重点解决的是质量变量差异带来的影响,即对齐的是条件分布差异.从图5质量变量的核密度估计图可以看出,TEP数据集和DC数据集的分布差异比较大,SRU数据集的分布



差异比较小,表明本文提出的模型在质量变量分布差异比较大的情况下适用性更强.




图5 不同数据集质量变量的核密度分布

4 结 论

为解决流程工业中过程数据的动态时变性和概念漂移问题,本文提出了基于低秩表示的动态迁移回归模型. 通过将高维数据投影在低维潜变量空间中,建立过去时刻过程变量和当前时刻质量变量的线性回归模型,挖掘数据之间的动态关系. 同时,设计基于低秩重构的条件分布对齐正则项嵌入动态内模型偏最小二乘中,实现不同工况之间的数据分布对齐,减少概念漂移对模型预测精度的影响. 在3个工业数据集上做对比实验,验证了本文算法的有效性. 但是,本文方法所建立的是离线模型,下一步拟计划研究遵循迁移学习“预训练-微调”范式的实时更新校正策略,

研究如何通过新样本来对现有模型的参数进行微调以提高模型对新样本的预测能力,进一步提高域适应方法在软测量领域内的实用性.

参考文献 (References)

[1] 汤健, 夏恒, 乔俊飞, 等. 深度集成森林回归建模方法及应用[J]. 北京工业大学学报, 2021, 47(11): 1219-1229.  
(Tang J, Xia H, Qiao J F, et al. Modeling method of deep ensemble forest regression with its application[J]. Journal of Beijing University of Technology, 2021, 47(11): 1219-1229.)

[2] 袁小锋, 王雅琳, 阳春华, 等. 深度学习在流程工业过程数据建模中的应用[J]. 智能科学与技术学报, 2020, 2(2): 107-115.  
(Yuan X F, Wang Y L, Yang C H, et al. The application of deep learning in data-driven modeling of process industries[J]. Chinese Journal of Intelligent Science and Technology, 2020, 2(2): 107-115.)

[3] Zhao Y H. A soft sensor based on orthogonal nonlinear principal component analysis[J]. Developments in Chemical Engineering and Mineral Processing, 2005, 13(3/4): 233-242.

[4] Geladi P, Kowalski B R. Partial least-squares regression: A tutorial[J]. Analytica Chimica Acta, 1986, 185: 1-17.

[5] Zhu Q Q. Latent variable regression for supervised modeling and monitoring[J]. IEEE/CAA Journal of Automatica Sinica, 2020, 7(3): 800-811.

[6] 乔俊飞, 孙子健, 汤健. 面向工业过程软测量建模的概念漂移检测综述[J]. 控制理论与应用, 2021, 38(8): 1159-1174.  
(Qiao J F, Sun Z J, Tang J. Overview of concept drift detection for industrial process soft sensor modeling[J]. Control Theory & Applications, 2021, 38(8): 1159-1174.)

[7] Ku W F, Storer R H, Georgakis C. Disturbance detection and isolation by dynamic principal component analysis[J]. Chemometrics and Intelligent Laboratory Systems, 1995, 30(1): 179-196.

[8] Qin S J, McAvoy T J. Nonlinear FIR modeling via a neural net PLS approach[J]. Computers & Chemical Engineering, 1996, 20(2): 147-159.

[9] Dong Y N, Qin S J. A novel dynamic PCA algorithm for dynamic data modeling and process monitoring[J]. Journal of Process Control, 2018, 67: 1-11.

[10] Dong Y N, Qin S J. Regression on dynamic PLS structures for supervised learning of dynamic data[J]. Journal of Process Control, 2018, 68: 64-72.

[11] Pan S J, Tsang I W, Kwok J T, et al. Domain adaptation via transfer component analysis[J]. IEEE Transactions on

- Neural Networks, 2011, 22(2): 199-210.
- [12] Borgwardt K M, Gretton A, Rasch M J, et al. Integrating structured biological data by kernel maximum mean discrepancy[J]. Bioinformatics, 2006, 22(14): 49-57.
- [13] Sun B C, Feng J S, Saenko K. Correlation alignment for unsupervised domain adaptation[C]. Domain Adaptation in Computer Vision Applications. Cham: Springer, 2017: 153-171.
- [14] 杜宇浩, 阎高伟, 李荣, 等. 基于局部线性嵌入的测地线流式核多工况软测量建模方法[J]. 化工学报, 2020, 71(3): 1278-1287.  
(Du Y H, Yan G W, Li R, et al. Multiple working conditions soft sensor modeling method of geodesic flow kernel based on locally linear embedding[J]. CIESC Journal, 2020, 71(3): 1278-1287.)
- [15] 阎高伟, 贺敏, 汤健, 等. 基于最大均值差异多源域迁移学习的湿式球磨机负荷参数软测量[J]. 控制与决策, 2018, 33(10): 1795-1800.  
(Yan G W, He M, Tang J, et al. Soft sensor of wet ball mill load based on maximum mean discrepancy multi-source domain transfer learning[J]. Control and Decision, 2018, 33(10): 1795-1800.)
- [16] Nikzad-Langerodi R, Zellinger W, Lughofer E, et al. Domain-invariant partial-least-squares regression[J]. Analytical Chemistry, 2018, 90(11): 6693-6701.
- [17] 徐志强, 任密峰, 程兰, 等. 基于时间近邻拉氏正则的多工况软测量回归[J]. 仪器仪表学报, 2021, 42(11): 279-287.  
(Xu Z Q, Ren M F, Cheng L, et al. Multi-conditions soft sensor regression based on the time-nearest neighbor Laplacian regularization[J]. Chinese Journal of Scientific Instrument, 2021, 42(11): 279-287.)
- [18] 韩鹏东, 阎高伟, 任密峰, 等. 基于迁移子空间学习的偏最小二乘回归软测量方法[J]. 控制与决策, 2023, 38(11): 3147-3155.  
(Han P D, Yan G W, Ren M F, et al. Partial least squares regression soft sensor method based on transfersubspace learning[J]. Control and Decision, 2023, 38(11): 3147-3155.)
- [19] Zhao Z J, Yan G W, Ren M F, et al. Dynamic transfer partial least squares for domain adaptive regression[J]. Journal of Process Control, 2022, 118: 55-68.
- [20] Wright J, Ganesh A, Rao S, et al. Robust principal component analysis: Exact recovery of corrupted low-rank matrices[J/OL]. 2009, arXiv: 0905.0233.
- [21] Downs J J, Vogel E F. A plant-wide industrial process control problem[J]. Computers & Chemical Engineering, 1993, 17(3): 245-255.
- [22] Fortuna L, Graziani S, Xibilia M G. Soft sensors for product quality monitoring in debutanizer distillation columns[J]. Control Engineering Practice, 2005, 13(4): 499-508.
- [23] Fortuna L, Graziani S, Xibilia M G, et al. Comparing regressors selection methods for the soft sensor design of a sulfur recovery unit[C]. 2006 14th Mediterranean Conference on Control and Automation. Ancona, 2006: 9189147.

#### 作者简介

霍海丹(1994—), 女, 硕士生, 从事软测量、迁移学习等研究, E-mail: hhd\_tylg@163.com;

阎高伟(1970—), 男, 教授, 博士生导师, 从事机器学习和人工智能、软测量等研究, E-mail: yangaowei@tyut.edu.cn;

程兰(1984—), 女, 副教授, 博士, 从事机器人协同视觉定位与建图等研究, E-mail: chenglan@tyut.edu;

任密峰(1985—), 女, 副教授, 博士, 从事随机控制、深度学习等研究, E-mail: renmifeng@126.com;

肖舒怡(1994—), 女, 讲师, 博士, 从事多智能体协同控制、容错控制、自适应控制等研究, E-mail: xiaobeyond1994@163.com.