

公路工程
Highway Engineering
ISSN 1674-0610, CN 43-1481/U

《公路工程》网络首发论文

题目：基于变分模态分解与 LightGBM 的改扩建道路沉降预测模型研究
作者：张行，田权，张静波，唐楚轩
收稿日期：2024-12-06
网络首发日期：2026-08-21
引用格式：张行，田权，张静波，唐楚轩. 基于变分模态分解与 LightGBM 的改扩建道路沉降预测模型研究[J/OL]. 公路工程.
<https://link.cnki.net/urlid/43.1481.U.20260820.1526.004>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于变分模态分解与 LightGBM 的改扩建道路沉降预测模型研究

张行¹, 田权¹, 张静波¹, 唐楚轩²

(1. 中交第二公路勘察设计研究院有限公司, 湖北 武汉 430056; 2. 中国科学院武汉岩土力学研究所, 湖北 武汉 430071)

[摘要] 目前, 针对改扩建道路施工过程中沉降精准预测的研究仍然较少。为此, 基于变分模态分解 (VMD) 和 LightGBM 算法提出了一种针对改扩建道路的沉降预测模型。首先, 对原始沉降序列进行 VMD 分解, 根据模态特征将序列分解成趋势项和波动项。对趋势项采用多项式拟合进行预测, 而波动项通过累积填土高度、日降雨量与前期沉降数据作为外界变量, 通过 LightGBM 算法进行建模与预测。以广西某高速公路改扩建路基沉降数据为例, 结果表明该方法的预测精度较高, 决定系数 (R^2) 超过 0.97, MSE 仅为 0.034, 显著优于传统的支持向量回归 (SVR) 和人工神经网络 (ANN) 模型。该方法能够实现路基施工过程中沉降的高精度预测, 为施工方案优化提供了有效支持。

[关键词] 道路沉降预测; 变分模态分解; 波动项; LightGBM; 施工方案优化

[中图分类号] U416.1

[文献标志码] A

[文章编号] 1674-0610(2026)04-0000-00

Research on Settlement Prediction Model for Road Reconstruction and Expansion Based on Variational Mode Decomposition and LightGBM

ZHANG Hang¹, TIAN Quan¹, ZHANG Jingbo¹, TANG Chuxuan²

(1. CCCC Second Highway Consultants Co., Ltd., Wuhan, Hubei 430056, China; 2. Institute of Rock and Soil Mechanics, Chinese Academy of Sciences, Wuhan, Hubei 430071, China)

[Abstract] Currently, there are still relatively few studies on accurate settlement prediction during the construction of reconstructed and expanded roads. Therefore, this paper proposes a settlement prediction model for road reconstruction and expansion based on Variational Mode Decomposition (VMD) and the LightGBM algorithm. First, the original settlement sequence is decomposed using VMD, dividing the sequence into trend and fluctuation components based on the characteristics of the mode functions. The trend component is predicted using polynomial fitting, while the fluctuation component is predicted by training the LightGBM model with the cumulative height of the fill, daily rainfall, and prior settlement data as input variables. Using settlement data from a reconstruction and extension project of highway in Guangxi as a case study, the results demonstrate that this method has high prediction accuracy, with a coefficient of determination (R^2) exceeding 0.97 and a mean squared error (MSE) of only 0.034, significantly outperforming traditional models such as Support Vector Regression (SVR) and Artificial

[收稿日期] 2024-12-06

[基金项目] 国家自然科学基金资助项目 (42077262)

[作者简介] 张行 (1987—), 男, 湖北仙桃人, 高级工程师, 硕士, 主要从事公路勘察与地质灾害防治研究。

[引文格式] 张行, 田权, 张静波, 等. 基于变分模态分解与 LightGBM 的改扩建道路沉降预测模型研究 [J]. 公路工程, 2026, 51(4):

Neural Networks (ANN). This model provides highly accurate settlement predictions during roadbed construction, offering effective support for the optimization of construction plans.

[**Key words**] road settlement prediction; variational mode decomposition; fluctuation components; LightGBM; construction plan optimization

0 引言

随着交通需求的不断增长, 现有公路的通行能力逐渐难以满足需求, 尤其是 20 世纪 80 年代和 90 年代建设的公路, 迫切需要进行改扩建。相比新建高速公路, 改扩建现有公路不仅成本更低、工期更短, 还已成为提升交通效率的主要手段^[1]。然而, 在改扩建过程中, 旧路基与新路基的结合容易引发差异沉降^[2], 进而影响公路的使用寿命和安全性。路基沉降受多种因素影响, 并随着时间推移而变化, 其复杂的力学性质使得土体参数的确定尤为困难^[3-4]。因此, 准确预测路基沉降已成为近年来研究的热点和挑战性领域。

当前, 路基沉降的预测方法主要分为传统理论方法和人工智能方法^[5]。传统方法如曲线拟合法、反演参数法、灰色系统理论及系统理论在一定程度上得到了应用^[6-7], 但通常存在预测精度有限和对复杂因素敏感等缺点, 导致在处理复杂沉降现象时效果不佳。例如曲线拟合法虽然在处理长期沉降数据时表现良好, 但在面对快速变化的沉降情况时, 其适应性不足; 反演参数法能够通过实际沉降监测数据反演出更准确的模型参数, 提升计算精度, 但其对初始参数的依赖性较强, 且需要较多的先验知识^[8]; 而灰色系统法在数据稀缺的情况下仍具应用价值, 但其模型复杂性和适用范围有限。

相较之下, 人工智能方法在路基沉降预测中展现出显著的优势, 近年来在解决沉降预测问题中取得了较好效果^[9]。人工智能方法能够有效处理非线性和高维数据, 适用于建模传统方法难以捕捉的复杂关系。通过自动从数据中提取关键特征, 这些方法无需大量先验知识即可提高沉降预测的精度, 而且针对不同的工程也有较强的适应性^[10]。然而, 目前对路基沉降的研究主要集中在施工后的沉降预

测, 对路基填筑过程中沉降的监测和预测研究相对较少。高填方路基的沉降时间长、影响因素复杂且规律不明确, 传统预测方法难以有效应对。鉴于此, 利用机器学习方法进行沉降预测时, 充分考虑影响路基沉降的多种因素^[11], 并通过元启发式算法优化模型超参数, 能够进一步提高预测模型的准确性和可靠性。

本文基于 VMD 与 LightGBM 算法, 提出了针对改扩建道路的沉降预测模型^[12], 并结合某实际改扩建工程, 构建了施工期间路基沉降的预测模型, 并对其预测效果进行了全面评估。本研究还建立了传统的支持向量回归和人工神经网络沉降预测模型, 通过不同的评价指标对其性能进行了比较与分析。

1 理论基础

1.1 变分模态分解(VMD)

变分模态分解(VMD)是一种非递归信号分解方法^[13], 用于将复杂信号分解为若干具有物理意义的本征模态函数 (IMFs)。其核心思想是在分解过程中确保每个模态的频谱 $\{\mu_k(t)\}$ 集中于指定的中心频率 $\{\omega_k\}$ 附近。VMD 通过最小化以下变分问题来完成信号的分解:

$$\min_{\{\mu_k\}, \{\omega_k\}} \left\{ \sum_k \left\| \partial_t \left[(\delta(t) + \frac{j}{\pi t}) \cdot \mu_k(t) \right] e^{-j\omega_k t} \right\|_2^2 \right\} \quad (1)$$

其中, ∂_t 表示时间导数; $\delta(t)$ 表示狄拉克函数; $*$ 表示卷积运算; j 表示虚数单位。VMD 通过交替方向乘子法 (ADMM) 逐步优化, 求解模态函数 $\mu_k(t)$ 与中心频率 ω_k 。优化过程引入拉格朗日乘子和惩罚参数, 构建拉格朗日函数(式 2), 实现信号的有效分解。

$$L(\{\hat{\mu}_k(\omega)\}, \{\omega_k\}, \lambda) = \sum_k \left\| \omega(\hat{\mu}_k(\omega) - \hat{f}(\omega) e^{-j\omega_k t}) \right\|_2^2 + \sum_k \hat{\mu}_k(\omega) - \hat{f}(\omega) \quad (2)$$

通过交替更新 $\hat{\mu}_k$ 、 ω_k 和 λ , 实现对信号精确分解。

1.2 轻量级梯度提升机(LightGBM)

LightGBM 是一种梯度提升决策树 (GBDT) 变体^[14], 通过引入梯度单侧采样 (GOSS) 和互斥特

征捆绑 (EFB) 技术, 提升了预测准确率。GOSS 通过丢弃梯度较小的数据实例, 仅使用剩余数据实例来评估信息增益, 按梯度绝对值对数据排序, 并将排名前 $\alpha\%$ 的数据实例分配到子集 A 。

从补集 A^c 中随机采样构建子集 B 。特征 j 在点 d 处方差增益用于分割数据实例, 其数学表达为:

$$V_j(d) = \frac{1}{n} \left(\sum_{x_i \in A_l} g_i + \frac{1-a}{b} \sum_{x_i \in B_l} g_i \right)^2 \cdot n_j^l(d) + \left(\sum_{x_i \in A_r} g_i + \frac{1-a}{b} \sum_{x_i \in B_r} g_i \right)^2 \cdot n_j^r(d) \tag{3}$$

其中, $n_j^l(d)$ 和 $n_j^r(d)$ 分别表示左节点和右节点的数据数量; A_l 和 A_r 是子集 A 中的子集; B_l 和 B_r 是子集 B 中的子集; $\frac{1-a}{b}$ 为归一化梯度系数。

EFB 将互斥特征捆绑成一个单一特征, 假设特征 j 和 k 是互斥的, 定义捆绑特征后的方差增益 $V_{j+k}(d)$ 与冲突率 ρ_{jk} :

$$V_{j+k}(d) = V_j(d) + V_k(d) \tag{4}$$

$$\rho_{jk} = \frac{|\{x \mid x^j \neq 0 \text{ and } x^k \neq 0\}|}{|\{i \mid x_i^j \neq 0\}| + |\{i \mid x_i^k \neq 0\}|} < \varepsilon \tag{5}$$

则可以将特征 j 和捆绑在一起, ε 为预设的冲突率阈值。在训练完成后, 预测过程是通过将输入样本依次传递到每棵决策树, 逐层遍历到叶子节点, 从而得到每棵树的预测值。所有树的预测值最终相加形成总和, 直接作为该样本的回归预测结果。

1.3 时间卷积网络 (TCN)

时间卷积网络(TCN)是用于序列建模的神经网络, 通过因果卷积和扩张卷积来捕捉时间序列中的长距离依赖。使用卷积层代替循环层, 因果卷积确保输出只依赖于当前及之前的输入, 而扩张卷积则通过间隔扩展卷积核以获取上下文信息。通过输入

序列生成特征图, 经激活函数与全连接层生成预测结果。

1.4 算法流程

道路沉降数据受内外因素影响, 通常包含噪声和非线性, 直接建模难以取得满意效果。本文提出一种融合变分模态分解(VMD)与轻量级梯度提升机(LightGBM)的沉降预测算法, 算法流程如下:

- a. 运用 VMD 将原始信号分解为数个 IMF, 据 IMF 频率, 将序列分解为趋势项、季节项和随机项;
- b. 通过灰色关联度筛选外部因子, 选取主控因子并结合季节项数据, 构建季节项沉降预测模型;
- c. 评估不同步长输入的预测误差, 确定最优输入步长;
- d. 通过多项式拟合方法预测趋势项沉降;
- e. 结合 TCN 算法与单变量时序模型进行动态预测;
- f. 叠加季节项、趋势项与随机预测结果, 得到最终沉降预测结果。

算法流程图见图 1。为衡量所建立模型的性能, 选用均方误差(MSE)和决定系数(R^2)评估模型准确性与拟合能力。




图 1 算法流程图
Figure 1 Algorithm flow chart

2 案例研究

2.1 案例概况

以广西某高速公路改扩建工程 ZK1216+650~ZK1217+000 左侧加宽高填方为例, 设计基准期

100 a, 整体式路基宽 42 m, 采用沥青砼路面结构, 设计荷载等级为公路-I 级。原运营高速中, 该段填方路基左侧边坡最大高差 23.4 m, 整体坡比 1:1.75; 改扩建方案为左右同时加宽, 其中左侧为高填方段加宽, 右侧为普通填方加宽。左侧加宽

段分三级(1 : 1.5、1 : 1.75、1 : 2.0)放坡填方,设计路面标高比现有运营路面高出 4.2 ~ 4.3 m。左侧加宽填方位于原低丘山间冲沟斜坡处,斜坡地层为填筑角砾土,下部基岩为泥质砂岩及灰岩。填方拼宽对原边坡削坡并在老路路基边坡开挖台阶、铺设土工合成材料、分层进行路堤压实,施工过程安装沉降板以便后期进行沉降监测(见图 2),沉降板设置于断面左幅新老填方界面处,以监测垂直沉降,相关地质条件及监测布设如图 3 所示。



图 2 现场监测点布设
Figure 2 Site monitoring point layout




图 3 ZK1216 + 750 左幅加宽段高填方监测断面图 (单位:)
Figure 3 ZK1216 + 750 left widening section of high-fill monitoring profile (unit:)

根据相关文献,影响路基沉降的关键因素包括地基岩土的性质、路基填筑材料的特性、路基的几何尺寸、填筑速度、压实程度,以及降雨等环境因素^[15-16]。在路基填筑过程中,基岩和土体的性质通常保持相对稳定,因此,路基填筑的自重效应成为施工期间沉降的主要决定因素^[17-18],路基沉降随着填筑高度的增加而变化。因此,在建立路基施工期间的沉降预测模型时,重点考虑填筑时间和累积填筑高度等因素,图 4 展示了累积填筑高度的时间曲线。本研究还收集了项目区域日降雨量数据,其时间序列如图 5 所示。




图 4 路基施工期间累积沉降监测结果
Figure 4 Monitoring results of cumulative settlement during subgrade construction




图 5 累计填筑高度与逐日降雨量图
Figure 5 Cumulative filling height and daily rainfall

2.2 变分模态分解结果

从 2021 年 10 月 1 日起,对 J1 监测点进行沉降监测,每隔 1 d 进行一次测量,总共记录 190 个周期。为了深入挖掘 J1 沉降序列特征,并去除信号中的天然噪声以便于模型学习,采用了变分模态分解方法对 J1 原始沉降序列进行了分解,VMD 分解效果在很大程度上取决于模态数量和惩罚因子的选择,参数选择不当时,可能会导致信号模态重叠或混淆,进而影响模型预测精度。为解决此问题,本文采用了粒子群优化 (PSO) 方法来寻找最佳的 VMD 分解参数。具体参数设置为:种群规模为 100,最大迭代次数为 200,学习因子 c_1 和 c_2 均设为 1.7,惯性权重 w 为 0.8。通过优化后,确定

VMD 参数为模态数量 $k=3$, 惩罚因子 $\alpha=2\ 200$ 。图 6 为优化后的 VMD 分解结果, 由结果可见, IMF1 呈现一定季节性波动, 其定义为季节项。IMF2 周期

最长, 整体曲线平滑且变化平缓符合趋势项特点, 将其定义为趋势项。IMF3 的特点为频率高、周期短, 符合随机项的特点, 将其定义为随机项。




图 6 J1 道路沉降序列 VMD 分解结果
Figure 6 VMD decomposition results of J1 road settlement sequence

2.3 试验环境与结果分析

试验的编程语言为 Python 3.9, 计算机系统内存为 32 GB, 采用 NVIDIA GeForce GTX 4060Ti 12GB 显卡, 虚拟环境配置 CUDA 和 cuDNN, 将数据集划分为训练集和测试集, 比例为 7 : 3, 前 133 个周期用于模型训练, 剩余数据用于检测模型精度。LightGBM 参数如下, 学习率为 0.05。

从图 6(c) 可以看出, 沉降趋势项变形的变化相对缓慢, 且随时间呈现出稳步下降的趋势, 受

$$y(t)=57.03+1.17\times10^{-2}t-2.81\times10^{-2}t^2+4.96\times10^{-4}t^3-4.54\times10^{-6}t^4-2.10\times10^{-8}t^5-3.72\times10^{-6}t^6\quad(6)$$
式中: $y(t)$ 为趋势项变形随时间的变化函数; t 为时间期数。

表 1 不同阶数的多项式拟合精度			
Table 1 Fitting accuracy of polynomials of different orders			
阶数	MSE	阶数	MSE
1	41.43	5	0.38
2	7.66	6	0.07
3	0.63	7	0.10
4	0.39	8	0.32

前文已提到降雨是诱发道路沉降的外部诱发因素之一。因此, 在季节项预测中, 本研究将当日降雨量作为模型的外部变量之一, 为了更全面地考虑降雨对道路沉降的滞后影响, 引入前期累计降雨量的概念。将监测当天的降雨量记作 R_0 , 前两天的累计降雨量记作 R_1 , 以此类推, 综合考虑一周内的累计降雨量对道路沉降的影响。基于此, 将一周

外界因素的影响较小。为了对趋势项变形进行预测, 本文采用多项式拟合方法, 并通过最小二乘法优化多项式方程的系数。表 1 列出了不同阶数的多项式对趋势项拟合的均方误差 (MSE)。由表 1 可见, 当多项式阶数由 1 阶增至 6 阶时, MSE 数值下降, 在 6 阶时达到极小值 0.07, 而阶数到 8 时 MSE 数值上升。基于模型精度与计算效率的考虑, 本文最终选用了 6 阶多项式进行拟合, 具体公式如下:

内的累计降雨量视为道路沉降的潜在主控因素, 并利用灰色关联度理论对各因素进行关联度分析, 结果如表 2 所示。由表 2 计算结果可知, 累计降雨量关联度峰值位于 R_4 , 即前五天的累计降雨量与道路沉降 1 的相关性最强。因此, 本文在 LightGBM 模型的外部特征选择上采用了前四天的累计降雨量作为输入特征。

表 2 一周内累计降雨灰色关联度计算结果							
Table 2 The calculation results of grey correlation degree of cumulative rainfall in a week							
因子	R_0	R_1	R_2	R_3	R_4	R_5	R_6
累计降雨	0.64	0.66	0.71	0.72	0.74	0.68	0.66

在季节项沉降预测中, 除了考虑降雨因素, 还需要填筑时间和累积填筑高度因素, 将上述外部因素都纳入外部特征矩阵中。此外引入外部特征, 还需要结合序列自身的特性, 将季节项的历史变形数

据作为模型输入的一部分。为了确定最佳的历史输入步长，本文通过均匀分布试验对不同步长进行了验证。试验中，将模型的输入步长从 6 逐步递减至 1，步长为 6 时，表示输入包含前 6 期的变形数据，输出对应目标期的变形数据。表 3 展示了不同输入步长下的 MSE 精度。结果表明，随着步长由 1 增至 3，MSE 逐渐下降，步长为 3 时 MSE 最低，步长继续增至 4 后 MSE 回升。最终，本文选择输入步长为 3。J1 季节项的预测结果见图 7。

表 3 波动序列不同输入步长的预测精度

Table 3 Prediction accuracy of different input steps of fluctuation sequence

输入步长	MSE	输入步长	MSE
1	0.37	4	0.10
2	0.28	5	0.32
3	0.06	6	0.42




图 7 J1 季节项预测结果

Figure 7 Prediction results of the seasonal component at J1

随机项受随机因素与人为因素影响，缺乏可量化的信息特征，本文从序列本身特征出发利用数据驱动建模，随机项部分结合 TCN 算法与单变量时序模型进行动态预测。TCN 算法参数如下：卷积

表 4 不同预测方法的优缺点与精度对比

Table 4 The advantages and disadvantages and accuracy comparison of different prediction methods

方法	优点	缺点	MSE
支持向量回归 (SVR)	适用性强，泛化能力良好，针对小样本效果好	对参数选择较为敏感	0.25
BP 神经网络 (BPNN)	非线性拟合能力强，适应复杂关系	容易过拟合，需要大量训练数据，且模型解释性差，小样本下表现不佳	0.49
本文方法	预测精度高，适应性强，泛化能力较好	计算复杂度较高	0.03




图 9 J1 监测点 VMD-LightGBM 与 SVR、BPNN 预测结果对比图

Figure 9 Comparison of prediction results of VMD-LightGBM, SVR and BPNN at J1 monitoring point

核为 2，膨胀系数为 2，隐藏层通道数为 32，层数为 3，激活函数部分采用 ReLU，MSE 为 0.004。在完成趋势项、季节项与随机项沉降预测后，将各部分沉降叠加，得到最终预测值如图 8 所示，最终预测结果的 R^2 和 MSE 分别为 0.97 和 0.034，预测结果良好。




图 8 J1 沉降预测结果图

Figure 8 Prediction results of the settlement at J1

2.4 试验结果对比

为了验证本文方法的优越性，选取了两种常用的回归预测模型作为对照组，分别是支持向量回归 (SVR) 和 BP 神经网络 (BPNN) 模型。3 种模型的输入数据和试验条件与本文方法保持一致。具体而言，SVR 模型采用径向基函数 (RBF) 核，BPNN 模型的隐藏层大小设为 128，随机种子为 42，迭代次数为 2 000，学习率为 0.05。各方法的优缺点及预测精度对比信息见表 4，结果对比图如图 9 所示。试验结果表明，SVR 模型和 BPNN 模型的均方误差 (MSE) 分别为 0.25 和 0.49，而本文方法的 MSE 为 0.18，表明本文方法在预测精度上明显优于传统的 SVR 和 BPNN 模型。

3 结论

a. 本研究创新性地融合变分模态分解 (VMD) 与轻量级梯度提升机 (LightGBM) 算法，构建了适用于改扩建道路工程的沉降预测模型。针对复杂工程环境下的沉降数据特性，首先通过 VMD 方法对原始时序数据进行模态分解，有效分离出趋势项、季节项和随机项等关键特征分量。将经分解后的多维特征序列作为模型输入，不仅增强了特征的表征

能力, 更显著提升了 LightGBM 模型对时间序列长期依赖关系的建模效果。试验结果表明, 该混合模型在复杂工况下的沉降预测精度较传统方法提升显著。

b. 本文提出的 VMD-LightGBM 预测模型在广西某高速公路改扩建工程 ZK1216 + 650 ~ ZK1217 + 000 左侧加宽高填方路基沉降监测中的预测效果显著。根据相关文献收集了累积填筑高度、逐日降雨量等外部数据, 通过灰色关联度确定了前四天的累计降雨量为最显著外部特征, 运用筛选因子作为季节项的输入项, 累加多项式拟合的趋势和 TCN 算法预测的随机项结果, 模型在测试集上的均方误差 (MSE) 仅为 0.065, 而决定系数 R^2 为 0.973, 证明模型在实际应用中具有较高的预测精度和稳定性。

c. 与传统的支持向量回归 (SVR) 和人工神经网络 (ANN) 模型相比, 本文所提出的方法具有更高的预测精度与鲁棒性。该方法可为类似路基施工期沉降预测提供参考。

[参考文献]

[1] 龚莉, 孔令玉. 道路改扩建工程技术经济分析[J]. 中国林业经济, 2006(5): 51 - 53.

[2] 王明帅, 孙红, 牛富俊, 等. 软土地区高速公路改扩建工程地基沉降分析[J]. 公路工程, 2025, 50(2): 95 - 102.

[3] 候志峰, 靳灿章. 软土地区道路加宽工程路基差异沉降特性研究[J]. 城市道桥与防洪, 2020(5): 230 - 232, 235.

[4] 南秋彩. 道路改扩建工程中新老路面拼接受力状态的数值模拟[J]. 公路工程, 2018, 43(6): 278 - 282.

[5] 李西斌. 高速公路软土地基沉降预测方法现状探讨[J]. 公路, 2011(5): 16 - 20.

[6] 孟雪, 赵燕容, 黄小红, 等. 基于灰色 GM(1,1) 和神经网络组合模型的基坑周边地面沉降预测分析[J]. 勘察科学技术, 2018(6): 39 - 44.

[7] 李小刚, 张廷会. GM(1,1) 灰色预测模型在道路软基沉降预测中的应用[J]. 铁道科学与工程学报, 2016, 13(1): 63 - 68.

[8] 李群. 泡沫轻质土在既有软基道路扩建中的应用及沉降预测研究[D]. 北京: 北京科技大学, 2019.

[9] 罗林, 左昌群, 赵连, 等. 基于 BP 神经网络和 R/S 分析的隧道仰坡沉降变形预报预测[J]. 施工技术, 2014, 43(11): 80 - 84.

[10] 吴钧, 王晓, 李亚峰, 等. 基于预测信息集对关系的公路软基沉降组合预测模型研究[J]. 公路工程, 2024, 49(1): 67 - 73.

[11] 潘宇平, 倪静, 李林, 等. 基于 LIB - SVM 的盾构隧道地表沉降预测方法研究[J]. 水资源与水工程学报, 2018, 29(3): 231 - 235.

[12] 柴少波, 岳山丘, 王铭一, 等. 基于变分模态分解和粒子群优化长短期记忆网络的黄土地区高填方路基沉降预测[J]. 太原理工大学学报, 2025, 56(5): 907 - 915.

[13] Wang Yanxue, Markert R, Xiang Jiawei, et al. Research on variational mode decomposition and its application in detecting rub-impact fault of the rotor system[J]. Mechanical Systems and Signal Processing, 2015, 60/61: 243 - 251.

[14] Wang Dehua, Zhang Yang, Zhao Yi. LightGBM: an effective miRNA classification method in breast cancer patients[C]//Proceedings of the 2017 International Conference on Computational Biology and Bioinformatics, 2017: 7 - 11.

[15] Liu Lulu, Li Zhe, Cai Guojun, et al. Performance and prediction of long-term settlement in road embankments constructed with recycled construction and demolition waste[J]. Acta Geotechnica, 2022, 17(9): 4069 - 4093.

[16] Li Haichao, Tao Junliang, Wei Lianyu, et al. Explosive compaction technology for loess embankment settlement control: numerical simulation and field implementation[J]. Acta Geotechnica, 2020, 15(4): 975 - 997.

[17] Hou Xiaokun, Qi Shengwen, Yu Yongtang, et al. Long-term settlement characterization of high-filling foundation in the mountain excavation and city construction area of the Yan'an New District, China[J]. Journal of Earth Science, 2023, 34(6): 1908 - 1915.

[18] Mao Wuwei, Li Wei, Rasouli R, et al. Numerical simulation of liquefaction-induced settlement of existing structures[J]. Journal of Earth Science, 2023, 34(2): 339 - 346.