



电力系统自动化

Automation of Electric Power Systems

ISSN 1000-1026, CN 32-1180/TP

《电力系统自动化》网络首发论文

题目：基于闲时算力调度的算电协同方法与实践
作者：付智，郑博文，刘效辰，程伟，张涛，刘晓华
收稿日期：2026-02-05
网络首发日期：2026-07-09
引用格式：付智，郑博文，刘效辰，程伟，张涛，刘晓华. 基于闲时算力调度的算电协同方法与实践[J/OL]. 电力系统自动化.
<https://link.cnki.net/urlid/32.1180.TP.20260708.1710.002>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于闲时算力调度的算电协同方法与实践

付智^{1,2}, 郑博文¹, 刘效辰¹, 程伟³, 张涛¹, 刘晓华¹

(1. 清华大学建筑技术科学系, 北京市 100084; 2. 北京共绩科技有限公司, 北京市 100080;

3. 中国联通广东省分公司, 广东省广州市 510627)

摘要: 数据中心能耗持续增长对电力系统构成严峻挑战, 尤其是大语言模型(LLM)推理计算任务的实时响应需求导致了显著的用电尖峰负荷。闲时算力资源规模庞大且具备时空调节灵活性, 是实现算电协同的重要潜力资源。为充分发挥闲时算力的柔性调节能力, 提出了一种基于闲时算力调度的算电协同方法, 以实现计算任务的高稳定性和低成本。首先, 分析了GPU单机“性能-功耗”非线性特性; 其次, 构建了面向闲时算力的“时域-地域”调度策略; 最后, 在真实闲时算力调度平台上开展了工程实践验证。结果表明: 时域调节使算力系统总功耗降低17%以上, 地域调度使计算成本降低近18%, 地区绿电利用率提高近20%。本研究证明了所提方法在降低计算能耗、促进可再生能源利用等方面的显著效果和推广潜力, 为新型电力系统和算力网络的协同低碳发展提供了可行方案。

关键词: 算电协同; 闲时算力; 算力调度; 绿色算力; 需求侧柔性

0 引言

随着人工智能(artificial intelligence, AI)迅猛发展, 算力需求激增, 将成为未来电力负荷中的重要组成部分。2024年全球数据中心的电力消耗估计为415 TW·h, 过去五年内年均增速约12%, 预计2030年将增至945 TW·h^[1]。截至2024年底, 我国数据中心耗电量达到166 TW·h, 算力总规模近5年平均增速近30%^[2]。同时, 已有研究表明算力负荷具备灵活调节的潜力^[3-6], “算电协同”对于绿色算力发展和新型电力系统建设具有重要意义。目前, 国家持续推动数据中心绿色低碳发展^[7], “算电协同”已纳入全国一体化算力网和新型电力系统建设的总体框架^[8], 青海、河北等省份已开展绿色算力调度平台的试点建设^[9]。

AI算力的能源需求主要源于大语言模型(large language model, LLM)计算任务, 包括训练任务、微调任务和推理任务。目前, 训练任务和微调任务占据了大部分的算力资源和能源消耗。但随着AI全面落地应用, 推理任务的算力需求将大幅增加, 据多

家AI科技公司预测, 未来推理任务在所有LLM计算任务中的占比将高达90%^[10-11]。

从计算特征来看, 训练任务、微调任务和少量推理任务为批量型任务(batch workload), 而大量推理任务为交互型任务(interactive workload)。对用户提交的交互型推理任务请求数据进行监测分析, 可以发现: 受人行为影响, 算力需求在时间维度上呈现明显的波峰波谷特征; 受用户地理分布影响, 在空间维度上具有分散性。这两个特性构成了推理算力需求区别于训练算力需求的核心差异。此外, 批量型任务允许在规定期限内延迟完成并统一返回结果, 而交互型任务对延迟有严格约束, 须实时返回计算结果^[12]。

在算力任务方面, 现有算电协同相关研究主要针对批量型任务, 通过“时间-空间”两维度的算力调度, 降低算力系统用电成本并为电力系统提供灵活性。空间维度上, 算力系统跨区域调度具有低成本、高稳定性、低延迟的特点^[13], 可响应不同地区的绿电出力或电价变化; 时间维度上, 利用批量型任务可延迟完成的特性^[14], 将计算任务调度至绿电出力高峰或电价低谷时段完成。文献[15]基于排队等待模型和多目标优化模型, 实现了算力任务在地域上迁移、在时域上微调。文献[16]基于模糊电价预测, 采用了时空联合负载均衡算法优化了运行策略。然而, 上述策略均难以适应交互型任务需求, 随着交互

收稿日期: 2026-02-05; 修回日期: 2026-04-29。

国家工信部算力强基揭榜挂帅(异构算力跨域任务编排系统); 北京市自然科学基金资助项目(QY25032); 中国科协青年人才托举工程资助项目(2023QNRC001)。

型任务占比持续增加,其适用范围将受到显著制约。

针对交互型任务,部分研究也提出了优化调节方法。现有方案主要基于动态电压与频率缩放(dynamic volt frequency scaling, DVFS)调整 GPU 频率,以优化 LLM 推理服务的能效,同时满足服务水平目标和服务水平协议的要求。文献[17]提出的频率缩放技术实现了截止期限感知的能效调度;文献[18]提出的服务水平目标感知框架能够在满足延迟要求的同时,最小化能源消耗。上述研究虽然在降低瞬时计算功耗方面取得了一定进展,但尚缺少对算力集群的“性能-功耗”特性的实测探索。

已有实验表明,GPU 频率与功耗存在非线性关系。文献[19]对不同参数大小的模型、不同任务类型的“频率-能耗”、“频率-推理时间”规律进行了实验,论证了推理能效并非由参数规模主导,并发现 LLM 推理任务存在频率最优点,可实现单位推理任务的能耗最小化。文献[20]基于计算延迟与计算功耗的非线性关系,对批量性 LLM 微调任务提出了慢算扩容策略,在保障计算任务在一定时间内完成的前提下,降低了总体功耗。其慢算扩容思路可进一步推广至 LLM 交互型推理场景,并与地域优化调度耦合实现综合优化。

在算力供给方面,现有研究主要针对专用、独占的算力集群。此类集群计算设备投入成本高昂,闲置折旧成本可能超过调度带来的电费节约,制约了规模化应用。对于未来大量波动性 LLM 推理需求,专用算力资源将面临长期低利用率问题,产生高昂的算力成本,难以支撑 AI 大规模商业化部署。

区别于专用、独占的算力资源,“闲时算力”指未在计算进程中或未被满载使用的空闲计算设备所提供的计算资源。当前大量计算设备的平均利用率偏低,因此闲时算力资源广泛存在。闲时算力存在于不同类型场景的计算设备中,如数据中心算力集群、网吧电脑、个人电脑等^[17,21]。据统计,目前我国智能算力规模达 788 EFLOPS,但平均利用率不足 30%,部分地区的集群甚至利用率不足 18%^[22-24]。约 400 万台网吧电脑持续一年的实际监测数据表明,平均每台电脑每日开机时长不足 3h。Steam 游戏平台上有 40 万中国玩家持有配备 RTX 4090 GPU 的设备,但日均游戏时长不超过 2 h,每日空闲时长占比高达 94%^[25]。闲时算力分布广、规模大^[26],且无需额外承担设备购置与折旧成本,具备跨地区、跨时段的用能灵活调节潜力。在闲时算力的资源支持下,算电协同的设备成本可以降低至极低水平,相比投入成本较高的专用算力集群,更具工程实践价值,在实现算电协同、支撑绿电消纳、促进算力绿色发展方面具

有重要意义。

以国外亚马逊弹性计算云(Amazon EC2)为例,其提供的竞价实例(spot instance, SI)即作为闲时算力的典型应用形态,被高性能计算、批量作业、科学应用程序等场景调度利用^[27]。文献[28-29]基于深度学习构建了 SI 的估价模型和价格预测以提高使用率。然而,受限于计算设备拥有者使用行为的随机性,算力调度的安全性、稳定性难以保障^[29-30],大规模应用于 LLM 计算任务并实现算电协同仍面临挑战。

为了解决闲时算力的安全稳定问题,以推进算电协同实践,部分研究针对闲时算力调度进行了尝试和实践。文献[31-32]设计了自适应负载波动调度策略以最大化利用算力资源;文献[33]建立的 Leftover 系统利用闲时算力资源服务 LLM 批量型计算任务;文献[34]聚焦于 LLM 交互型推理任务的迁移安全性问题,融合交替方向乘子法与同态加密技术,实现隐私保护下的协作优化。以上研究能够提高任务迁移的安全性和稳定性,但在持续保障交互型推理任务服务质量方面仍存在局限,规模化生产级应用尚面临困难。

综上,虽然当前已有大量关于算力负荷调度与优化的研究,但是现有工作多数针对批量型计算任务的能耗优化与任务迁移,对于交互型推理任务的研究较少;对于算力集群的“性能-功耗”特性缺乏定量实验更新。再者,现有研究多数使用专用、独占的算力集群,规模化应用的经济性存在瓶颈;在利用闲时算力进行跨区域、跨时段动态调度方面缺乏系统的理论框架与工程验证。亟需面向算力负荷调节特性,建立兼具工程可行性与推广价值的闲时算力调度方法,并进行面向闲时算力的算电协同优化策略的设计与实践检验。

针对上述问题,本文提出并研发了闲时算力灵活调度平台与调度方法,并开展算电协同实践应用,主要创新点包括:

- 1)提出了具有高稳定性、低成本的闲时算力调度方法;
- 2)刻画了较新 GPU 和 LLM 模型对于推理任务的“性能-功耗”特性;
- 3)构建了面向闲时算力 LLM 推理任务的“时域-空域”调度策略,有效提高绿电利用率。

1 闲时算力调度框架与平台

闲时算力调度框架的调度对象聚焦于生成式模型的交互型推理计算任务,旨在纳入分布式的集群算力和个人算力,在保障服务稳定的前提下挖掘闲

时算力调度潜力,并通过综合调度降低计算总成本、提高绿电利用率。

1.1 闲时算力资源接入与管理

算力调度平台所接入的对象包括数据中心、个人计算设备等社会上广泛存在的各类闲时算力资源。算力调度体系可划分为三个层次:服务端、客户端和闲时算力设备。

图1描述了闲时算力资源接入与管理的流程。首先,闲时算力设备会部署专门开发的客户端^[35],在客户端内封装了资源监测模块、环境配置模块和任务管理模块。资源监测模块实时检测设备的硬件参数(CPU、内存、GPU等),监控实时负载,推送至部署在云平台的服务端。服务端通过任务调度模块接收并持久化存储最新设备参数与负载信息。环境配置模块检查算力资源是否具备运行任务所需的环境配置(如驱动版本、CUDA版本、库函数、WSL权限等),并进行自动升级与更新以接收并计算任务。实测表明,94%的个人计算设备可全自动完成环境配置。任务管理模块通过进程监控保证设备自身任务的优先级始终最高,不影响设备持有者的正常使用需求,真正实现闲时资源利用。




图1 闲时算力资源接入与管理
Fig.1 Computing Resources Access and Management

在正式开始承接计算任务之前,服务端系统需判断目标设备能否持续空闲一定时间,以规避频繁迁移带来的时间开销。根据设备 i 的历史负载记录,对时刻 t 之后的持续空闲时间 $T_{i,t}$ 进行概率预测,其累积分布函数 $F_{T_{i,t}}(x)$ 定义为:

$$F_{T_{i,t}}(x) = P(T_{i,t} \leq x) \quad x \geq 0 \quad (1)$$

式中: x 为持续空闲时间的取值; $P(\cdot)$ 为概率函数。

在设备 i 的历史负载记录中,提取第 h 天时刻 t 开始的连续空闲时段信息,累计共 K_i 天。采用经验分布函数 $\hat{F}_{T_{i,t}}(x)$ 估计式(1):

$$\hat{F}_{T_{i,t}}(x) = \frac{1}{K_i} \sum_{h=1}^{K_i} 1\{T_{i,t,h} \leq x\} \quad (2)$$

式中: $1\{\cdot\}$ 为指示函数,当括号内条件成立时取1,否

则取0; $T_{i,t,h}$ 为设备 i 第 h 天从时刻 t 之后的连续空闲时间。

设定容忍接入失效率0.05,最小持续时间阈值0.5 h,将式(2)代入式(3),以确定接入判据,若 $\hat{T}_{i,t}$ 小于0.5 h,则在时刻 t 时不接入设备 i :

$$\hat{T}_{i,t} = \inf \{x \in \mathbf{R}: \hat{F}_{T_{i,t}}(x) \geq 0.05\} \quad (3)$$

式中: $\hat{T}_{i,t}$ 为设备 i 在容忍接入失效率下的最小持续空闲时间阈值估计。

根据设备性能将不同设备分类,提前分发不同复杂度的模型镜像至本地以待调用。服务端周期性执行调度算法,筛选可用设备、生成调度决策,并将任务指令下达至客户端的任务管理模块。客户端调用本地镜像执行计算,完成后将结果回传至服务端。在整个过程中,平台通过对计算设备历史使用模式的学习实现忙闲状态预测,进而实现任务的精准分发;通过硬件筛选、软件环境自动配置及镜像预置,确保平台具备随时承接任务的能力。此外,基于进程隔离和磁盘加密保障本地数据和计算任务数据的安全。实际生产中为保障高质量服务,还需在网络层完成内网穿透和链路打通等工作,由于非本文研究重点,在此不做详述。目前该客户端可自行下载进行测试。

据此,实现了对闲时算力资源的接入和管理,保障了接入的安全性与稳定性,为后续利用闲时算力开展算电协同奠定了基础。

1.2 算力任务迁移

闲时算力调度平台中算力资源的稳定使用要求算力任务迁移具备足够的速度和连续性。一方面,闲时算力资源可能因资源提供者自身使用需求随时下线,为保障在线服务不中断,需快速将计算任务迁移至其他可用资源。另一方面,新型电力系统背景下不同地区的电价存在差异,要求调度平台具备快速响应电价变化并灵活调控的能力。

如图2所示,算力迁移体系划分为用户侧、服务端和安装客户端的算力设备。用户侧提供计算任务请求,传递至服务端的任务调度模块。任务调度模块根据目标任务调度方案中各数据中心的任务副本数量,通过负载均衡实现任务的迁移。

在推理计算场景下,由于模型镜像已在设备筛选过程中提前下载部署,任务迁移仅涉及指令与少量过程数据的传输,能够保证迁移速度,基本不产生迁移开销,并保障在线服务在迁移过程中不中断。这一特性适应了推理任务的分散性,可利用闲时算力为不同地区的推理请求提供稳定服务。




图2 算力任务迁移
Fig. 2 Computing Task Migration

1.3 闲时算力调度平台

基于以上接入、管理与迁移的基础,本文开发了闲时算力调度平台^[36],已实现空间尺度上的调度迁移和时间尺度上的弹性扩缩容。平台涵盖青海、河南、福建、重庆等多个地区的算力集群资源,支持便捷部署生产级推理服务。计算设备掉线时可快速切换到其余空闲设备,保障服务稳定性,服务水平协议(service level agreement, SLA)达到99.9%。该平台为闲时算力算电协同调度提供了技术支撑和实践基础,本文3.2节的实验亦依托该平台开展。

2 基于闲时算力的算电协同调度策略

算力调度策略从时域和地域两个维度展开。时域上,采用慢算扩容策略,通过降低单机计算速度以降低功耗,同时扩增节点以保障服务质量;地域上,采用地区间迁移策略,将算力调度至电价更低的地区,从而降低成本并提升绿电利用率。

2.1 时域策略

2.1.1 单机“性能-功耗”特性

已有研究表明, GPU单机的功耗与性能之间存在凸性关系^[17-19]。GPU单机功耗满足:

$$\begin{cases} P^{\text{dyn}} \propto CV^2 f \\ P^{\text{sta}} \propto V \\ P = P^{\text{dyn}} + P^{\text{sta}} \end{cases} \quad (4)$$

式中: P^{dyn} 为动态功耗; C 为动态电容; V 为电压; f 为时钟频率; P^{sta} 为静态功耗; P 为总功耗。

对于GPU配置为 s 的设备, 功耗 P_s 与时钟频率 f 的关系可以整理为^[19]:

$$P_s(f) = \alpha_s^P f^3 + \beta_s^P f + \gamma_s^P \quad (5)$$

式中: α_s^P 、 β_s^P 、 γ_s^P 为GPU配置为 s 的设备“功耗-频率”多项式拟合参数。

由于GPU单机性能与时钟频率 f 接近正比关系, 单机性能与功耗呈非线性, “性能-功耗”曲线表现为上凸特性。

针对LLM推理性计算任务, 性能通过瞬时吞吐量表征。本文分别使用两种GPU卡、三类LLM和简单/复杂两种交互型命令(图3模型名带*表示复杂交互型命令)开展“性能-功耗”特性实验, 具体实验信息见附录A表1。实验结果如图3(a)所示, 其中散点表示实测数据, 实线为三次多项式拟合的结果。结果表明: 当性能降低10%时, A卡四组实验中功耗均下降超过23%, B卡两组实验中功耗均下降超过16%。

由实验可拟合出单机性能与功耗的关系如下:

$$g_s(P) = \alpha_s^W P^3 + \beta_s^W P^2 + \gamma_s^W P + \eta_s^W \quad (6)$$

式中: $g_s(P)$ 为单机性能关于功耗的拟合函数; α_s^W 、 β_s^W 、 γ_s^W 、 η_s^W 为GPU配置为 s 的设备“性能-功耗”多项式拟合参数。

图3(b)展示了单机的性能与功耗在运行过程中存在一定范围的波动, 该不稳定性对实际调度实践的影响将在第3节具体分析。





图3 单机实验结果
Fig. 3 Single-machine Experiment Result

2.1.2 慢算扩容调节策略

基于2.1.1节所述单机“性能-功耗”特性, 在时间尺度上通过慢算扩容策略挖掘GPU的用能灵活性潜力。文献[20]针对LLM微调任务建模, 考虑了

多GPU之间的传输时延和梯度聚合时延,及频率调节后对计算时间和功耗的影响,对单个微调任务的总能耗寻找最优频率和GPU数。式(7)拟合了微调计算任务的时延与频率和GPU数的关系,结合式(5)得到总能耗式(8)

$$T_s(n, f) = \alpha_s^T + \beta_s^T f^{-1} + \gamma_s^T n \quad (7)$$

$$E_s(n, f) = nP_s(f)T_s(n, f) \quad (8)$$

式中: $T_s(n, f)$ 为单个微调任务时延; n 为GPU数; $\alpha_s^T, \beta_s^T, \gamma_s^T$ 为GPU配置为 s 的设备“时延-频率”多项式拟合参数; $E_s(n, f)$ 为单个微调任务总能耗。

对于LLM推理交互型任务,慢算扩容策略保障瞬时吞吐量而非任务完成时间。此外,推理场景下各GPU独立承载用户请求,不涉及模型并行中的梯度同步与跨卡通信,总吞吐量可近似视为各GPU吞吐量的线性叠加。因此,将慢算扩容策略简化如下:

$$\begin{cases} \min_{w, n} P_s^{\text{tot}} = nP_s \\ \text{s.t.} \quad P_s = g_s^{-1}(w) \\ nw = n_0 w_0, w \in (0, w_0], n \in \mathbb{N}_+, n \geq n_0 \end{cases} \quad (9)$$

式中: P_s^{tot} 为总瞬时功耗; P_s 为单机瞬时功耗; $g_s^{-1}(\cdot)$ 为性能-功耗拟合函数的逆函数; w 为单机瞬时吞吐量; n_0 为原始GPU数; w_0 为原始单机瞬时吞吐量。

通过降低单机运行功率并扩容计算节点补偿能耗性能损失,在维持总服务性能不变的前提下降低系统总功耗。在算力集群同时运行多种类型的计算任务时,还需决策将富余的闲时GPU资源分配给节能潜力更大的任务进行扩容。针对每一算力集群,在式(9)基础上求解以下优化问题:

$$\begin{cases} \min_{\Delta n_t} J_t = \underbrace{\theta_t \sum_{j \in \mathcal{B}} P_{j(s)}(n_{j,t} + \Delta n_{j,t})}_{\text{电费}} + \underbrace{y \sum_{j \in \mathcal{B}} (n_{j,t} + \Delta n_{j,t})}_{\text{租赁费}} \\ \text{s.t.} \quad P_{j(s)} = g_{j(s)}^{-1}(w_j) \quad \forall j \in \mathcal{B} \\ n_{j,t} w_{j,0} = (n_{j,t} + \Delta n_{j,t}) w_j \quad \forall j \in \mathcal{B} \\ \sum_{j \in \mathcal{B}} (n_{j,t} + \Delta n_{j,t}) \leq N_t^{\text{GPU}} \\ w_j \in (0, w_{j,0}], \Delta n_{j,t} \in \mathbb{N}, \forall j \in \mathcal{B} \end{cases} \quad (10)$$

式中: $\Delta n_t = [\Delta n_{1,t}, \dots, \Delta n_{|\mathcal{B}|,t}]^T$ 为 t 时刻各任务扩容GPU数决策向量; $\Delta n_{j,t}$ 为 t 时刻任务 j 扩容增加的GPU数; J_t 为 t 时刻的瞬时运行成本; j 为任务编号; $\mathcal{B}$ 为任务集合; θ_t 为 t 时刻的算价(综合机柜租赁、供应商利润与电价后的算力使用价格,参考市场行情取电价的4倍)^[37]; $j(s)$ 为任务 j 对应的设备GPU配置; $P_{j(s)}$ 为任务 j 的单机瞬时功耗; $n_{j,t}$ 为 t 时刻任务 j

使用的GPU数; y 为每台闲时设备租赁成本; w_j 为任务 j 的瞬时吞吐量; $w_{j,0}$ 为任务 j 在优化前的初始瞬时吞吐量; N_t^{GPU} 为 t 时刻可用GPU总资源。

式(10)为混合整数非线性规划问题,本文对 $g_{j(s)}^{-1}(\cdot)$ 进行分段线性化,对双线性项约束 $n_{j,t} w_{j,0} = (n_{j,t} + \Delta n_{j,t}) w_j$ 采用 McCormick 包络松弛,把式(10)转化为混合整数线性规划问题,借助 Gurobi 求解。

2.2 地域策略

2.2.1 闲时算力资源网络

在闲时算力系统中,算力资源广泛分布于不同地区、不同类型的终端设备之中,可能来自企业数据中心、校园机房、个人电脑、边缘设备等,构成多层次、异构化的算力网络。

由于地域差异,不同地区的电力负荷、电价水平以及绿电占比存在明显差异。闲时算力调度平台可基于上述差异动态调度算力,在电价较低或绿电占比更高的地区优先分发计算任务,从而实现能源成本的最小化与绿色能源利用最大化。

闲时算力资源网络中可用总量通常远超系统实际需求,在资源利用上仍具有较大的优化空间。然而,由于闲时算力具有上下线不确定性,集群资源可能出现较大波动;且任务调度本身存在时延与一定概率的传递丢包,优化调度时需避免频繁迁移的发生。

2.2.2 地区间调度策略

闲时算力调度平台可通过地区间调度将算力迁移至电价最低的地区,以降低计算成本、提高绿电利用率。考虑 $|\mathcal{R}|$ 个参与调度的地区, t 时刻的静态单步调度问题为:

$$\begin{cases} \min_{M_t} J_t = \sum_{r \in \mathcal{R}} (\theta_{r,t} \bar{P}_{r,t} + y_r) (D_{r,t} + M_{r,t}) \\ \text{s.t.} \quad -D_{r,t} \leq M_{r,t} \leq S_{r,t} - D_{r,t}, \forall r \in \mathcal{R} \\ \sum_{r \in \mathcal{R}} (D_{r,t} + M_{r,t}) = N_t^{\text{Tot}} \\ \theta_{r,t} = 4c_{r,t} \\ D_{r,t}, M_{r,t} \in \mathbb{Z}, \forall r \in \mathcal{R} \end{cases} \quad (11)$$

式中: $M_t = [M_{1,t}, \dots, M_{|\mathcal{R}|,t}]^T$ 为各地区任务副本数迁移决策向量; $M_{r,t}$ 为 t 时刻地区 r 的任务副本净迁移量决策变量 ($M_{r,t} > 0$ 为净迁入, $M_{r,t} < 0$ 为净迁出); r 为地区编号; $\mathcal{R}$ 为地区集合; $\theta_{r,t}$ 为 t 时刻地区 r 的算价; $\bar{P}_{r,t}$ 为 t 时刻地区 r 单台GPU的平均运行功耗; y_r 为地区 r 单台设备的租赁成本; $D_{r,t}$ 为 t 时刻调度前地区 r 上已经有的任务副本数; $S_{r,t}$ 为 t 时刻地区 r 可接入任务副本上限; N_t^{Tot} 为 t 时刻用户任务的总副本需求量; $c_{r,t}$ 为 t 时刻地区 r 的电价。

实际运行中,闲时算力资源存在上下线不确定性、集群规模可能出现较大波动,为抑制频繁迁移、兼顾未来电价与资源变化,在式(11)基础上引入基于历史数据的滚动预测优化:

$$\begin{aligned} \min_{\{M_{r,\tau}\}} J'_t = & \sum_{r \in \mathcal{R}} (\theta_{r,t} \bar{P}_{r,t} + y_r)(D_{r,t} + M_{r,t}) + \\ & \sum_{\tau=t+1}^{t+H} \sum_{r \in \mathcal{R}} (\hat{\theta}_{r,\tau} \hat{P}_{r,\tau} + y_r)(D_{r,\tau} + M_{r,\tau}) + \\ & \sum_{\tau=t}^{t+H} \sum_{r \in \mathcal{R}} (\mu_{in} M_{r,\tau,in} + \mu_{out} M_{r,\tau,out}) \end{aligned} \quad (12)$$

式中: τ 为滚动窗口内的时刻索引; J'_t 为滚动窗口内各时刻期望成本和迁移惩罚项之和; H 为滚动窗口长度; $\hat{\theta}_{r,\tau}$ 为 τ 时刻地区 r 的算价预测值; $\hat{P}_{r,\tau}$ 为 τ 时刻地区 r 单台 GPU 平均运行功耗预测值; $M_{r,\tau,in}$ 为 τ 时刻地区 r 的非负迁入分量决策变量; $M_{r,\tau,out}$ 为 τ 时刻地区 r 的非负迁出分量决策变量; μ_{in} 为迁入惩罚系数; μ_{out} 为迁出惩罚系数。

式(12)的完整约束条件见附录 B 式(B2)一式(B8)及说明。采用 Gurobi 求解该动态规划问题后,取 t 时刻的迁入/迁出决策作为最优方案,如图 4 所示,为低电价地区标记高优先级,优先通过信息序列进行任务分配。




图 4 算力地域调度策略

Fig. 4 Computing power regional dispatch strategy

2.3 时域-地域耦合策略

将 2.1 节和 2.2 节所述策略耦合,即得到时域-地域耦合优化策略。完整问题表述和约束条件见附录 C 式(1)-式(12)及说明。优化问题耦合了式(10)与式(11)的约束结构,同样采用分段线性化与 McCormick 包络松弛,借助 Gurobi 求解器求解。求得的全局最优解可同时兼顾时域降速扩容与地域迁移,兼顾成本最低与服务质量保证。

3 实践与分析

2.1.1 节实验过程中,图 3(b)表明单机性能与功

耗均存在一定波动。对于慢算扩容策略,实际动态变化的性能能否绝大部分时间满足原始性能要求,有待实验验证;对于地域调度策略,单机功耗的不稳定性在规模化场景下是否会产生较大的聚合波动,从而影响调度决策,亦需通过规模化实验观察。


3.1 时域调节实践

3.1.1 实验设置

针对 2.1.2 节所述慢算扩容策略,组建由 8 张 RTX 4090 GPU 组成的算力节点,两个节点构成一个算力集群进行实验。电价取 0.6 元/(kW·h)^[38],则 θ 为 2.4 元/(kW·h)。由于采用闲时算力,设备租赁成本 y 理论上为 0;但实际运行中为保障基本服务,部分采用“半闲时算力”(即在特定时段将闲时算力视作专用算力),故综合取 y 为 0.5 元/(卡·h)。使用 DeepSeek-r1:14b 和 QwQ:32b 模型作为两个任务,初始状态下两个任务各满载部署 5 张 GPU。

3.1.2 结果分析

对于两个任务,优化算法均扩容 1 张 GPU,相应降低每张 GPU 的运行功耗。优化前后瞬时吞吐量对比如图 5(a)所示,优化后性能与原始性能基本一致,能够保障平均服务质量不降低,动态服务质量基本不降低。如图 5(b)所示, QwQ 模型总功耗降低了 17.27%, DeepSeek 模型总功耗降低了 25.70%,且优化后性能均略高于初始性能。



(a) 调节前后瞬时吞吐量对比




图 5 慢算扩容实验结果

Fig. 5 Slow-Computation & Scaling-Up Experiment Results

3.2 地域调度实践

3.2.1 实验设置

针对2.2.2节所述地区间调度策略,依托本文开发的闲时算力调度平台^[36],开展多GPU跨地区算力调度实验。实验采用重庆算力集群15张RTX 4090 GPU、福建算力集群10张RTX 4090 GPU和河南算力集群15张RTX 4090 GPU,同时部署20个LLM交互型任务。

根据三地区典型日风光发电量模拟生成对应电价,以1 h为调整周期更新地区优先级并调度任务。对于GPU突然离线的情形,将溢出任务调度至有闲时算力资源的地区。

3.2.2 结果分析

3.2.2.1 规模化运行分析

如图6(a)所示,当某地区部分GPU离线时,平台能够有效保障计算任务的连续性与稳定性,在较短响应时间内将任务重新部署至其他地区。同时,若出现集群短时间设备频繁上下线的情形,而引发了频繁的调度过程,由此引发的频繁调度过程将产生不可接受的累积时延,进一步验证2.2.2节中引入频繁调度抑制因子的必要性。

图6(a)所示的瞬时功耗曲线表明,单机功耗的波动性在多GPU聚合场景下不会产生显著的一致性波动,调度决策在规模化实践中未引发稳定性或安全性问题。2.1.1节中观测到的单机功耗波动源于LLM交互型推理过程中解码阶段的时变性与随机性——解码过程对每个输出Token进行概率分布的随机采样^[39],使推理过程具有固有的不确定性。同时,不同模型、不同输入输出长度等均影响推理过程^[40],使得各GPU功耗波动的同步性极低,规模化场景下的聚合波动因而得到自然平抑。

3.2.2.2 优化结果分析

图6(a)记录了实验过程中分别出现的数次GPU离线事件和电价变化,地区设备离线与电价优先级变更均触发了算力地域调度。详细分析见附录D。

实验结果表明,地域调度可有效降低计算成本并提升绿电利用率。如图6(b)所示,地域调度使算力系统计算成本降低了17.97%,绿电利用率提升了19.87%。

3.3 时域-地域耦合实践

3.3.1 案例介绍

在3.2节实践基础上,应用2.3节的时域-地域耦合优化模型,考虑重庆、福建、河南3个地区规模化RTX 4090 GPU算力集群,开展仿真分析。各地区可调度算力资源上限为600张RTX 4090 GPU,可




图6 算力地域调度实验结果
Fig. 6 Computing Power Regional Dispatch Experiment Results

用算力卡数可能产生波动。电价采用与第3.2节相同的模拟数据,推理任务需求取自某企业真实请求数据,详细数据分析见附录E图E1。以5 min为最小时间区间,进行典型日的实时地区调度与慢算扩容调节。各地区资源短时间波动参考算了么平台^[35]数据进行模拟,并对大规模上下线(波动超过20%设备数)事件进行了仿真。

3.3.2 结果分析

对于可用资源固定为500张GPU卡的情形(图7(a))和可用资源波动变化的情形(图7(b)),时域-地域耦合优化将任务优先迁至电价更低地区的算力集群进行计算,实现了对电价的实时响应,如图7(a1)和(b1)所示。同时,图7(a2)和(b2)展示了慢算扩容调节效果,在不同时刻各地区算力集群均实现了不同程度的降速扩容。图中绿色颗粒线表示各地区的可用算力资源上限。

图7(b2)体现了调度算法对较大资源波动的及时响应,其中红色虚线标记了短时段的高频资源波动情形,调度算法在该场景下保持了良好的稳定性,有效避免了计算任务的频繁跨地区迁移。

由图7(a3)和(b3)可见,时域-地域耦合优化在可用资源固定与波动情形下分别降低成本16.7%

和15.8%,均展现出显著的灵活性潜力。进一步拆解地区调度与慢算扩容各自的贡献后,对比了联合优化与先地区调度再慢算扩容的串行策略效果。结果表明,联合优化的成本降低幅度均优于上述串行策略,证实了联合优化能够搜索到成本最低的全局最优解。

3.4 讨论与展望

实验结果充分验证了闲时算力算电协同在节能降耗与促进绿电利用方面的有效性。通过时域调节与地域调度的协同实施,在保持服务性能稳定的前提下实现了算力资源与电力资源的协同优化。

在时域调节方面,慢算扩容策略降低功耗超过17%,为算力集群的动态能耗管理提供了可行的调节路径。在地域调度方面,调度平台在多区域、多电价、多任务环境下展现了实时响应与自适应调度能力。当部分地区出现节点下线或电价波动时,系统能够迅速重新分配任务并实现不中断迁移,保障算力服务的连续性和可靠性。基于电价信号的优先级调整机制实现了算力与电价的动态匹配,使整体计算成本降低近18%,区域间绿电利用率提高近20%。

同时,本实验所利用的均为闲时算力资源而非专用资源,除调度系统的部署运营费用之外无额外设备投入,所节约的成本远高于资源投入成本,算电协同的经济可行性得到了验证。

本文所提基于闲时算力的时域-地域联合调度策略在地区级多算力集群中的实践结果,初步展现了其在大规模算力-电力网络中的应用潜力。但本文目前仅基于大型智算集群开展实验,尚缺少基于其他类型闲时算力资源的验证。此外,根据密度定律^[41],未来更加分散的个人算力节点将占据越来越大的比例。分散算力将成为日常用电的重要组成部分,海量细粒度算力资源对优化调度策略提出更高要求,未来分布式算力与分布式能源的关联关系与协同发展路径,有待深入研究。

后续研究工作须针对不同类型算力资源开展更全面的实验,并在以下方向深化:

1) 柔性潜力评估:在“全域-局域-个体”多层级估计算力资源的柔性调节潜力,完善各层级与电网的互动模式,指导多层级异构灵活算力体系的构建。

2) 多种类算力资源预测:针对不同类型、不同区域的闲时算力资源进行总量估计与动态预测,支撑更精细化的调度决策。

3) 个人分布式算力资源特征研究:探究个人分布式算力资源的利用模式,探索分布式算力与分布式能源的关联关系与协同发展路径。




图7 时域-地域耦合优化实验结果

Fig. 7 Experimental Results of the Temporal-Regional Joint Optimization

综上,本文的实践验证了基于闲时算力发展算电协同的可行性与前景。随着算力需求的持续增

长,基于闲时算力资源的算电协同有望成为新型电力系统需求侧柔性潜力挖掘的重要发展方向。

4 结语

本文构建了可靠的闲时算力调度平台,设计了基于闲时算力调度的算电协同方法与策略,并通过实践验证了所提方法在交互型推理任务下降低计算能耗、提升绿电利用率的效果。通过慢算扩容调节和跨区域调度,本文方法能够降低运行成本近18%、提升绿电利用率近20%,且完全基于闲时算力资源,无额外设备占用成本,为构建高效、低碳、可持续发展的算力资源网络提供了可行方案。

随着AI技术的持续发展,算力系统与电力系统之间的耦合将日益紧密。基于闲时算力调度的算电协同有望成为二者交互的理想形式,充分挖掘算力系统作为全新需求侧柔性资源的潜力,发挥“以算代储”的作用,为能源高效利用和算力绿色转型做出重要贡献。

致 谢

本文中部分相关数据由青海省数据局提供,单机“性能-功耗”特性部分实验在青海省数据局的支持下完成,在此对青海省数据局表示衷心感谢。

附录见本刊网络版,点击<http://www.aeps-info.com/aeps/article/abstract/20260205005>,或扫描英文摘要后二维码,可阅读全文。

参 考 文 献

- [1] International Energy Agency (IEA). Energy and AI [R]. International Energy Agency, 2025.
- [2] 中国信息通信研究院产业与规划所,内蒙古和林格尔新区管委会.绿色算力发展研究报告(2025年)[R].北京:中国信息通信研究院,2025.
China Academy of Information and Communications Technology, Institute of Industry and Planning, and Administrative Committee of Horinger New Area, Inner Mongolia. Green Computing Power Development Research Report (2025) [R]. Beijing: China Academy of Information and Communications Technology, 2025.
- [3] CHEN S R, LI P, JI H R, et al. Operational flexibility of active distribution networks with the potential from data centers [J]. Applied Energy, 2021, 293: 116935.
- [4] ALAPERÄ I, HONKAPURO S, PAANANEN J. Data centers as a source of dynamic flexibility in smart grids [J]. Applied Energy, 2018, 229: 69-79.
- [5] 王永真,唐豪,魏一鸣,等.中国数据中心综合能耗及其灵活性预测[J].北京理工大学学报(社会科学版),2025,27(2):12-18.
WANG Yongzhen, TANG Hao, WEI Yiming, et al. Comprehensive energy consumption and flexibility forecast of data centers in China [J]. Journal of Beijing Institute of Technology (Social Sciences Edition), 2025, 27(2): 12-18.
- [6] 丁巧宜,王梓耀,潘振宁,等.面向电量-调频-容量市场的数据中心园区算力及电力资源规划[J].电力系统自动化,2024,48(1): 59-66.
DING Qiaoyi, WANG Ziyao, PAN Zhenning, et al. Planning of computing power and electric power resources in data center parks for electricity, frequency regulation and capacity markets [J]. Automation of Electric Power Systems, 2024, 48(1): 59-66.
- [7] 国家发展改革委,工业和信息化部,国家能源局等.数据中心绿色低碳发展专项行动计划[R/OL]. 中华人民共和国中央政府. 2024-07-03. https://www.gov.cn/zhengce/zhengceku/202407/content_6964165.htm. National Development and Reform Commission, Ministry of Industry and Information Technology, National Energy Administration, et al. Special Action Plan for Green and Low-Carbon Development of Data Centers[R/OL]. The Central People's Government of the People's Republic of China. 2024-07-03. https://www.gov.cn/zhengce/zhengceku/202407/content_6964165.htm.
网址有效. 点击这里,可链出核对其他内容
- [8] 陈敏,郭庆来,井汤博,等.算电协同探索: HVDC 侧储备一体电池灵活性挖掘[J].电力建设,2025,46(2):1-12.
CHEN Min, GUO Qinglai, JING Tangbo, et al. Exploring synergy of computing power and electricity: unearthing flexibility of high-voltage direct current-side integrated backup and energy storage batteries [J]. Electric Power Construction, 2025, 46(2): 1-12.
- [9] 陈明菊,张莉萍.青海:绿色算力产业发展工作成效显著[N/OL]. 人民网, 2025-01-19. <https://app.people.cn/h5/detail/normal/6152684713772032>. CHEN Mingju, ZHANG Liping. Qinghai: Remarkable Achievements in the Development of the Green Computing Power Industry [N/OL]. People's Daily Online, 2025-01-19. <https://app.people.cn/h5/detail/normal/6152684713772032>.【网址有效. 点击这里,可链出核对其他内容】
- [10] MORGAN P. The Battle Begins for AI Inference Compute in the Datacenter[R/OL]. The Next Platform, 2024, September 10. <https://www.nextplatform.com/2024/09/10/the-battle-begins-for-ai-inference-compute-in-the-datacenter/#:~:text=applications%20or%20to%20create%20entirely,processes%20with%20modest%20packaging%20needs.>【自助补缺】【自助补缺】【自助补缺】
- [11] DESISLAVOV R, MARTÍNEZ-PLUMED F, HERNÁNDEZ-ORALLO J. Trends in AI inference energy consumption: Beyond the performance-vs-parameter laws of deep learning [J]. Sustainable Computing: Informatics and Systems, 2023, 38: 100857.
- [12] 秦雪雪,李泽宁,薛屹洵,等.计及建筑热动态特性的数据中心时空协调两阶段鲁棒优化方法[J].电力系统自动化,2025,49(11):59-69.
QIN Xuexue, LI Zening, XUE Yixun, et al. Two-stage robust optimization method for spatio-temporal coordination of data center considering thermal dynamic characteristics of buildings [J]. Automation of Electric Power Systems, 2025, 49(11): 59-69.

- 59-69.
- [13] CAO Y J, CAO F, WANG Y J, et al. Managing data center cluster as non-wire alternative: a case in balancing market[J]. *Applied Energy*, 2024, 360: 122769.
 - [14] YU L, JIANG T, ZOU Y L. Distributed real-time energy management in data center microgrids[J]. *IEEE Transactions on Smart Grid*, 2018, 9(4): 3748-3762.
 - [15] ZHANG L T, DENG J K, LI Q F, et al. Research on data center computing resources and energy load co-optimization considering spatial-temporal allocation [J]. *Computers and Electrical Engineering*, 2024, 116: 109206.
 - [16] LUO J Y, RAO L, LIU X. Spatio-temporal load balancing for energy cost optimization in distributed Internet data centers[J]. *IEEE Transactions on Cloud Computing*, 2015, 3 (3) : 387-397.
 - [17] ILAGER S, MURALIDHAR R, RAMMOHANRAO K, et al. A data-driven frequency scaling approach for deadline-aware energy efficient scheduling on graphics processing units (GPUs) [C]// 2020 20th IEEE/ACM International Symposium on Cluster, Cloud and Internet Computing (CCGRID), May 11-14, 2020. Melbourne. 579-588.
 - [18] KAKOLYRIS A K, MASOUIROS D, XYDIS S, et al. SLO-aware GPU DVFS for energy-efficient LLM inference serving [J]. *IEEE Computer Architecture Letters*, 2024, 23 (2) : 150-153.
 - [19] MALIAKEL P J, ILAGER S, BRANDIC I. Characterizing LLM inference energy-performance tradeoffs across workloads and GPU scaling [EB/OL]. 2025; arXiv: 2501.08219. <https://arxiv.org/abs/2501.08219>
 - [20] WANG Y, GUO Q L, CHEN M. Providing load flexibility by reshaping power profiles of large language model workloads[J]. *Advances in Applied Energy*, 2025, 19: 100232.
 - [21] SUN J J, FU Z, MA J H, et al. Sharing computing power: enhancing energy efficiency and reducing carbon emissions[J]. *IEEE Energy Sustainability Magazine*, 2026, 2(1): 103-119.
 - [22] 中国信息通信研究院. 云计算蓝皮书(2025年)[R]. 北京: 中国信息通信研究院, 2025.
China Academy of Information and Communications Technology. *Cloud Computing Blue Book*[R]. Beijing: China Academy of Information and Communications Technology, 2025.【自助补缺】【自助补缺】【自助补缺】
 - [23] 都芄. 利用率仅三成,“沉睡”的算力如何激活[N/OL]. 广东省科学技术厅, 2025-07-17. https://gdsc.gd.gov.cn/kjzx_n/mtjj/content/post_4745744.html. DU Peng. With a utilization rate of only 30%, how can we awaken "dormant" computing power [N/OL] Department of Science and Technology of Guangdong Province, 2025-07-17. https://gdsc.gd.gov.cn/kjzx_n/mtjj/content/post_4745744.html.【网址有效 . 点击这里, 可链出核对其他内容】
 - [24] 全国数据资源统计调查工作组. 全国数据资源调查报告(2024年)[R]. 全国数据资源统计调查工作组, 2024. National Data Resources Statistical Survey Working Group. *National Data Resources Survey Report (2024)*. National Data Resources Statistical Survey Working Group, 2024.【自助补缺】【自助补缺】【自助补缺】
 - [25] Steam 硬件 和 软件 调查 [OL]. <https://store.steampowered.com/hwsurvey/Steam-Hardware-Software-Survey-Welcome-to-Steam>.
Steam Steam Hardware & Software Survey[OL]. <https://store.steampowered.com/hwsurvey/Steam-Hardware-Software-Survey-Welcome-to-Steam>.
 - [26] TANG Z Q, ZHANG F M, ZHOU X J, et al. Pricing model for dynamic resource overbooking in edge computing[J]. *IEEE Transactions on Cloud Computing*, 2023, 11(2): 1970-1984.
 - [27] SABYASACHI A S, KABIR H M D, ABDELMONIEM A M, et al. A resilient auction framework for deadline-aware jobs in cloud spot market [C]// 2017 IEEE 36th Symposium on Reliable Distributed Systems (SRDS), September 26-29, 2017, Hong Kong, China.
 - [28] AL-THEIABAT H, AL-AYYOUB M, ALSMIRAT M, et al. A deep learning approach for Amazon EC2 spot price prediction [C]// 2018 IEEE/ACS 15th International Conference on Computer Systems and Applications (AICCSA), October 28 - November 1, 2018, Aqaba: 1-5.
 - [29] BAUGHMAN M, HAAS C, WOLSKI R, et al. Predicting Amazon spot prices with LSTM networks [C]// Proceedings of the 9th Workshop on Scientific Cloud Computing, Tempe AZ USA. 1-7.
 - [30] LI J C, WAN Q, YU Z P. Research on network security algorithms in distributed computing environment [C]// Proceedings of SPIE Conference on International Conference on Internet of Things and Machine Learning (IoTML 2023), 2023; 82.
 - [31] 杨明烜, 洪学海, 唐宏伟. 基于任务资源需求预测的人工智能算力调度[J]. *高技术通讯*, 2024, 34(5): 475-485.
YANG Mingxuan, HONG Xuehai, TANG Hongwei. Artificial intelligence computing power cluster scheduling based on task resource demand prediction [J]. *Chinese High Technology Letters*, 2024, 34(5): 475-485.
 - [32] GUILLOTEAU Q, RICHARD O, ROBU B, et al. Controlling the injection of best-effort tasks to harvest idle computing grid resources [C]// 2021 25th International Conference on System Theory, Control and Computing (ICSTCC), October 20-23, 2021. Iasi. 334-339.
 - [33] DUAN X, YE K J. Leftover: improving large language model inference efficiency by leveraging idle resources [C]// 2023 International Conference on High Performance Big Data and Intelligent Systems (HDIS), December 6-8, 2023, Macau, China.
 - [34] SUN J J, YAN Y J, WANG Z Y, et al. Privacy-preserving coordinated operation of cross-enterprise data centers [J]. *Applied Energy*, 2025, 383: 125343.
 - [35] 共绩算力. 算了么闲时算力接入平台 [OL]. 北京共绩算力有限公司, 2025. <https://suanleme.cn.Comnergy>. Suanleme Idle Computing Power Access Platform [OL]. Beijing Gongji Technology Co., Ltd, 2025. <https://suanleme.cn>.
 - [36] 共绩算力. 闲时算力调度平台 [OL]. 北京共绩算力有限公司, 2025. <https://suanli.cn.Comnergy>. Idle Computing Power Scheduling Platform [OL]. Beijing Gongji Technology Co., Ltd, 2025. <https://suanli.cn>.【网址有效 . 点击这里, 可链出核

对其他内容]

- [37] 零克云 .GPU 算力租赁[OL]. 零氮云(上海)科技有限公司, 2025. <https://gpulink.cc/computility-market>.【网址有效. 点击这里, 可链出核对其他内容】
- [38] 国网青海省电力公司. 国网青海省电力公司关于 2025 年 9 月代理购电价格的公告[OL]. 国网青海省电力公司, 2025.8. <https://csc-static. sgcc. com. cn: 28888/omg-static/99308281750147514938600207141603.html>.【标题&网址验证 OK. 点击这里, 可链出确认】
- [39] HOLTZMAN A, BUYS J, DU L, et al. The curious case of neural text degeneration[EB/OL]. 2019: arXiv: 1904.09751. <https://arxiv.org/abs/1904.09751>
- [40] WILHELM P, WITTKOPP T, KAO O. Beyond test-time compute strategies: advocating energy-per-token in LLM inference[C]// Proceedings of the 5th Workshop on Machine

Learning and Systems. ACM, 2025: 208-215.

- [41] XIAO C J, CAI J, ZHAO W L, et al. Densing law of LLMs [J]. Nature Machine Intelligence, 2025, 7(11): 1823-1833.

付 智(2000—),男,博士研究生,主要研究方向:算电协同、算力调度。E-mail: fz@suanleme.cn

郑博文(2004—),男,博士研究生,主要研究方向:算电协同、算力负荷预测、分布式算力网络。E-mail: zhengbw22@mails.tsinghua.edu.cn

刘效辰(1994—),男,通信作者,助理教授,特别研究员,博士生导师,主要研究方向:柔性用能建筑、车辆与建筑能源互动、分布式能源资源调控。E-mail: lxc4@tsinghua.edu.cn

(编辑 王梦岩)

A Computing-Power Coordination Method and Practice Based on Idle Computing Resource Scheduling

Fu Zhi^{1,2#}, Zheng Bowen^{1#}, Liu Xiaochen¹, Cheng Wei³, Zhang Tao¹, Liu Xiaohua¹

(1. Department of Building Science, Tsinghua University, Beijing 100084, China; 2. Beijing Gongji Technology Co. Ltd., Beijing 100080, China; 3. China Unicom Guangdong Branch, Guangzhou 510627, China)

Abstract: The continuous growth of data center energy consumption poses severe challenges to power systems, particularly as the real-time response requirements of large language model (LLM) inference tasks give rise to pronounced peak electrical loads. Idle computing resources, which are available at massive scale and exhibit spatiotemporal scheduling flexibility, constitute a promising enabler of computing-power coordination. To fully exploit the flexible regulation capability of idle computing, this paper proposes a computing-power coordination method based on idle computing resource scheduling, aiming to achieve high stability and low cost for computing tasks. First, the nonlinear performance – power characteristics of individual GPUs are analyzed. Then, a temporal-regional scheduling strategy tailored to idle computing is developed. Finally, engineering validation is carried out on a real-world idle computing scheduling platform. The results show that temporal regulation reduces the total power consumption of the computing system by more than 17%, while regional scheduling lowers computing costs by nearly 18% and increases regional green electricity utilization rate by nearly 20%. This study demonstrates the significant effectiveness and scalability of the proposed method in reducing computing energy consumption and promoting renewable energy utilization, providing a viable pathway for the coordinated low-carbon development of next-generation power systems and computing networks.

This work is supported by The Ministry of Industry and Information Technology: Computing Infrastructure Enhancement and Open bidding for selecting the best candidates(Cross-Domain Task Orchestration System for Heterogeneous Computing Power), Beijing Municipal Natural Science Foundation of China(No. QY25032), and Youth Talent Support Program of the China Association for Science and Technology (No. 2023QNRC001).

Key words: Computing-Power Coordination; Idle Computing Resource; Computing Dispatch; Green Computing; Demand Flexibility



附录 A

通过 API 网关以 1 分钟周期监测指定交互命令下的瞬时吞吐量。使用 A 和 B 两种型号 GPU 进行实验, 分别部署 DeepSeek-r1:14b、Phi4:7b 模型和 QwQ:32b 模型, 通过 8 个请求并发操作使 GPU 尽可能持续工作, 功耗基本保持稳定。在功耗变化范围内每隔 10 W 取一个功耗点, 使用 Nvidia 自带工具 nvidia-smi 改变功耗上限进行压测, 并监测每一功耗点对应的吞吐量。

简单命令: Give me a code about deep reinforcement learning to give the auto-driving policy.

表 1 单机“性能-功耗”实验信息
Table 1 Single-machine Performance-Power Experiment information

	实验组号	模型	命令	90% 性能下功耗降低
A 型 GPU 功耗范围: 150 W-450 W	1	DeepSeek-r1:14b	简单命令	23%
	2	DeepSeek-r1:14b	复杂命令	26%
	3	Phi4:7b	简单命令	25%
	4	Phi4:7b	复杂命令	29%
B 型 GPU 功耗范围: 250 W-400 W	5	QwQ:32b	简单命令	16%
	6	QwQ:32b	复杂命令	17%

复杂命令: Design and implement a neuro-symbolic multi-modal autonomous driving system that combines deep reinforcement learning with formal verification. Requirements: Build a hybrid policy network that integrates visual, LiDAR, and HD map data; design a hierarchical reward function balancing safety, comfort, and traffic rule compliance; train in CARLA or AirSim and validate decision logic robustness using formal methods. Provide complete code implementation and optimize the system for real-time inference.

附录 B

$$\min_{\{M_{r,t}\}} J'_t = \sum_{r \in \mathcal{R}} (\theta_{r,t} \bar{P}_{r,t} + y_r)(D_{r,t} + M_{r,t}) + \sum_{\tau=t+1}^{t+H} \sum_{r \in \mathcal{R}} (\hat{\theta}_{r,\tau} \hat{P}_{r,\tau} + y_r)(D_{r,\tau} + M_{r,\tau}) \quad (1)$$

$$+ \sum_{\tau=t}^{t+H} \sum_{r \in \mathcal{R}} (\mu_{\text{in}} M_{r,\tau,\text{in}} + \mu_{\text{out}} M_{r,\tau,\text{out}})$$

$$\text{s.t.} \quad M_{r,\tau} = M_{r,\tau,\text{in}} - M_{r,\tau,\text{out}}, \forall r \in \mathcal{R}, \forall \tau \in [t, t+H] \quad (2)$$

$$D_{r,\tau+1} = D_{r,\tau} + M_{r,\tau}, \forall r \in \mathcal{R}, \forall \tau \in [t, t+H] \quad (3)$$

$$-D_{r,t} \leq M_{r,t} \leq S_{r,t} - D_{r,t}, \forall r \in \mathcal{R} \quad (4)$$

$$-D_{r,\tau} \leq M_{r,\tau} \leq \hat{S}_{r,\tau} - D_{r,\tau}, \forall r \in \mathcal{R}, \forall \tau \in [t+1, t+H] \quad (5)$$

$$\sum_{r \in \mathcal{R}} (D_{r,\tau} + M_{r,\tau}) = N_{\tau}^{\text{Tot}}, \forall \tau \in [t, t+H] \quad (6)$$

$$M_{r,\tau,\text{in}} \geq 0, M_{r,\tau,\text{out}} \geq 0, \forall r \in \mathcal{R}, \forall \tau \in [t, t+H] \quad (7)$$

$$M_{r,\tau}, M_{r,\tau,\text{in}}, M_{r,\tau,\text{out}}, D_{r,\tau} \in \mathbb{Z}, \forall r \in \mathcal{R}, \forall \tau \in [t, t+H] \quad (8)$$

式中: τ 为滚动窗口内的时刻索引; J'_t 为滚动窗口内各时刻期望成本和迁移惩罚项之和; r 为地区编号; $\mathcal{R}$ 为地区集合; $\theta_{r,t}$ 为 t 时刻地区 r 的算价 (综合机柜租赁、供应商利润与电价后的算力使用价格, 参考市场行情取电价的 4 倍); $\bar{P}_{r,t}$ 为 t 时刻地区 r 单台 GPU 平均运行功耗; y_r 为地区 r 单台设备的租赁成本; $D_{r,t}$ 为 t 时刻调度前地区 r 上已有的任务副本数; $M_{r,t}$ 为 t 时刻地区 r 的任务副本净迁移量决策变量 ($M_{r,t} > 0$ 为净迁入, $M_{r,t} < 0$ 为净迁出); H 为滚动窗口长度; $\hat{\theta}_{r,\tau}$ 为 τ 时刻地区 r 的算价预测值; $\hat{P}_{r,\tau}$ 为 τ 时刻地区 r 单台 GPU 平均运行功耗

预测值; $M_{r,\tau,\text{in}}$ 为 τ 时刻地区 r 的非负迁入分量决策变量; $M_{r,\tau,\text{out}}$ 为 τ 时刻地区 r 的非负迁出分量决策变量; μ_{in} 为迁入惩罚系数; μ_{out} 为迁出惩罚系数; $S_{r,t}$ 为 t 时刻地区 r 可接入的任务副本上限; $\hat{S}_{r,\tau}$ 为 τ 时刻地区 r 可接入的任务副本上限预测值; N_t^{Tot} 为 t 时刻用户任务的总副本需求量。

式(2)表示净迁移量的正负分量分解等式;式(3)为各地区任务副本数的状态转移关系;式(4)-式(5)分别限制当前时刻与未来时刻各地区可调迁移量不超过本地可接入资源;式(6)为全平台任务副本数之和满足总需求约束;式(7)为迁入迁出分量的非负性约束;式(8)为各变量的整数性约束。

附录 C

$$\min_{\{\Delta n_{j,t}, M_{r,t}\}} J_t = \sum_{r \in \mathcal{R}} \sum_{j \in \mathcal{B}_{r,t}} (\theta_{r,t} P_{j(s)} + y_r)(n_{j,t} + \Delta n_{j,t}) \quad (1)$$

$$\text{s.t.} \quad P_{j(s)} = g_{j(s)}^{-1}(w_j), \forall j \in \mathcal{B}_{r,t}, \forall r \in \mathcal{R} \quad (2)$$

$$(n_{j,t} + \Delta n_{j,t})w_j = n_{j,t}w_{j,0}, \forall j \in \mathcal{B}_{r,t}, \forall r \in \mathcal{R} \quad (3)$$

$$M_{r,t} = M_{r,t,\text{in}} - M_{r,t,\text{out}}, \forall r \in \mathcal{R} \quad (4)$$

$$D_{r,t} + M_{r,t} = \sum_{j \in \mathcal{B}_{r,t}} n_{j,t}, \forall r \in \mathcal{R} \quad (5)$$

$$\Delta N_{r,t} = \sum_{j \in \mathcal{B}_{r,t}} \Delta n_{j,t}, \forall r \in \mathcal{R} \quad (6)$$

$$-D_{r,t} \leq M_{r,t} \leq S_{r,t} - D_{r,t}, \forall r \in \mathcal{R} \quad (7)$$

$$D_{r,t} + M_{r,t} + \Delta N_{r,t} \leq S_{r,t}, \forall r \in \mathcal{R} \quad (8)$$

$$\sum_{r \in \mathcal{R}} (D_{r,t} + M_{r,t}) = N_t^{\text{Tot}} \quad (9)$$

$$M_{r,t,\text{in}} \geq 0, M_{r,t,\text{out}} \geq 0, \forall r \in \mathcal{R} \quad (10)$$

$$w_j \in (0, w_{j,0}], \forall j \in \mathcal{B}_{r,t}, \forall r \in \mathcal{R} \quad (11)$$

$$n_{j,t}, \Delta n_{j,t}, M_{r,t}, M_{r,t,\text{in}}, M_{r,t,\text{out}}, D_{r,t}, \Delta N_{r,t} \in \mathbb{Z} \quad (12)$$

式中: J_t 为 t 时刻的瞬时运行成本; r 为地区编号; $\mathcal{R}$ 为地区集合; j 为任务编号; $\mathcal{B}_{r,t}$ 为 t 时刻地区 r 承载的任务集合; $\theta_{r,t}$ 为 t 时刻地区 r 的算价(综合机柜租赁、供应商利润与电价后的算力使用价格,取该地区电价的4倍); $j(s)$ 为任务 j 对应的设备 GPU 配置; $P_{j(s)}$ 为任务 j 的单机瞬时功耗; y_r 为地区 r 单台设备的租赁成本; $n_{j,t}$ 为 t 时刻任务 j 使用的 GPU 数; $\Delta n_{j,t}$ 为 t 时刻任务 j 扩容增加的 GPU 数; $g^{-1}(\cdot)$ 为性能-功耗拟合函数的逆函数; w_j 为任务 j 的瞬时吞吐量; $w_{j,0}$ 为任务 j 在优化前的初始瞬时吞吐量; $M_{r,t}$ 为 t 时刻地区 r 的任务副本净迁移量决策变量($M_{r,t} > 0$ 为净迁入, $M_{r,t} < 0$ 为净迁出); $M_{r,t,\text{in}}$ 为 t 时刻地区 r 的非负迁入分量决策变量; $M_{r,t,\text{out}}$ 为 t 时刻地区 r 的非负迁出分量决策变量; $D_{r,t}$ 为 t 时刻调度前地区 r 上已有的任务副本数; $\Delta N_{r,t}$ 为 t 时刻地区 r 的总扩容 GPU 数; $S_{r,t}$ 为 t 时刻地区 r 可接入的任务副本上限; N_t^{Tot} 为 t 时刻用户任务的总副本需求量。

式(2)为单机“性能-功耗”曲线;式(3)保证慢算扩容前后单任务总吞吐量守恒;式(4)为净迁移量的正负分量分解等式;式(5)-式(8)为迁移量与扩容量受到本地资源的限制;式(9)为全平台任务副本数之和满足总需求约束;式(10)为迁入迁出分量的非负性约束;式(11)为单机吞吐量范围;式(12)为各变量的整数性约束。

附录 D 详细调度过程记录如下：

(1)12:20 重庆 6 张 GPU 离线,调度系统将重庆(第一优先级)溢出的 5 个任务迁移至福建(第二优先级)、1 个任务迁移至河南(第三优先级);12:45 重庆 6 张 GPU 恢复上线,调度系统将 6 个任务迁移回重庆。


(2)13:15 福建 8 张 GPU 离线,调度系统将福建(第二优先级)溢出的 3 个任务迁移至河南(第三优先级);13:45 福建 1 张 GPU 恢复上线、14:00 福建 7 张 GPU 恢复上线,调度系统分别将 1 个任务和 2 个任务从河南迁移回福建。

(3)15:30 福建 5 张 GPU 离线、重庆 5 张 GPU 离线,调度系统将福建(第一优先级)溢出的 5 个任务迁移至河南(第三优先级);16:00 福建、重庆各 5 张 GPU 恢复上线,调度系统将 5 个任务从河南迁移回福建。


针对地区电价变化,调整不同地区的优先级,触发调度系统对任务的重新分配。如图 6 中时刻 14:00 和 16:00,因电价变化导致最低电价地区发生变更,第一优先级地区随之改变,从而触发了算力地域调度。

附录 E


某公司在单地区的请求数据逐时请求数中值、标准差、变异系数如下图所示。数据选取时段为 9 月至 12 月,呈现出明显的日周期性和周周期性,以一周为周期进行统计分析,推理请求在中午 12 时和晚间 21 时左右分别出现峰值,而在凌晨(0:00—7:00)处于低谷;推理请求在白天相对更为稳定,夜间波动性更大。



(a) 某公司 LLM 推理逐时请求数中值



(b) 某公司 LLM 推理逐时请求数标准差



(c) 某公司 LLM 推理逐时请求变异系数

图 1 某公司 LLM 推理逐时请求分析